第4章 K近邻

分类需要什么？

1. 数据：
   - 将对象表示为量化的一组特征
   - 给定类别标签
2. 对象间相似性的度量

K近邻（KNN）分类

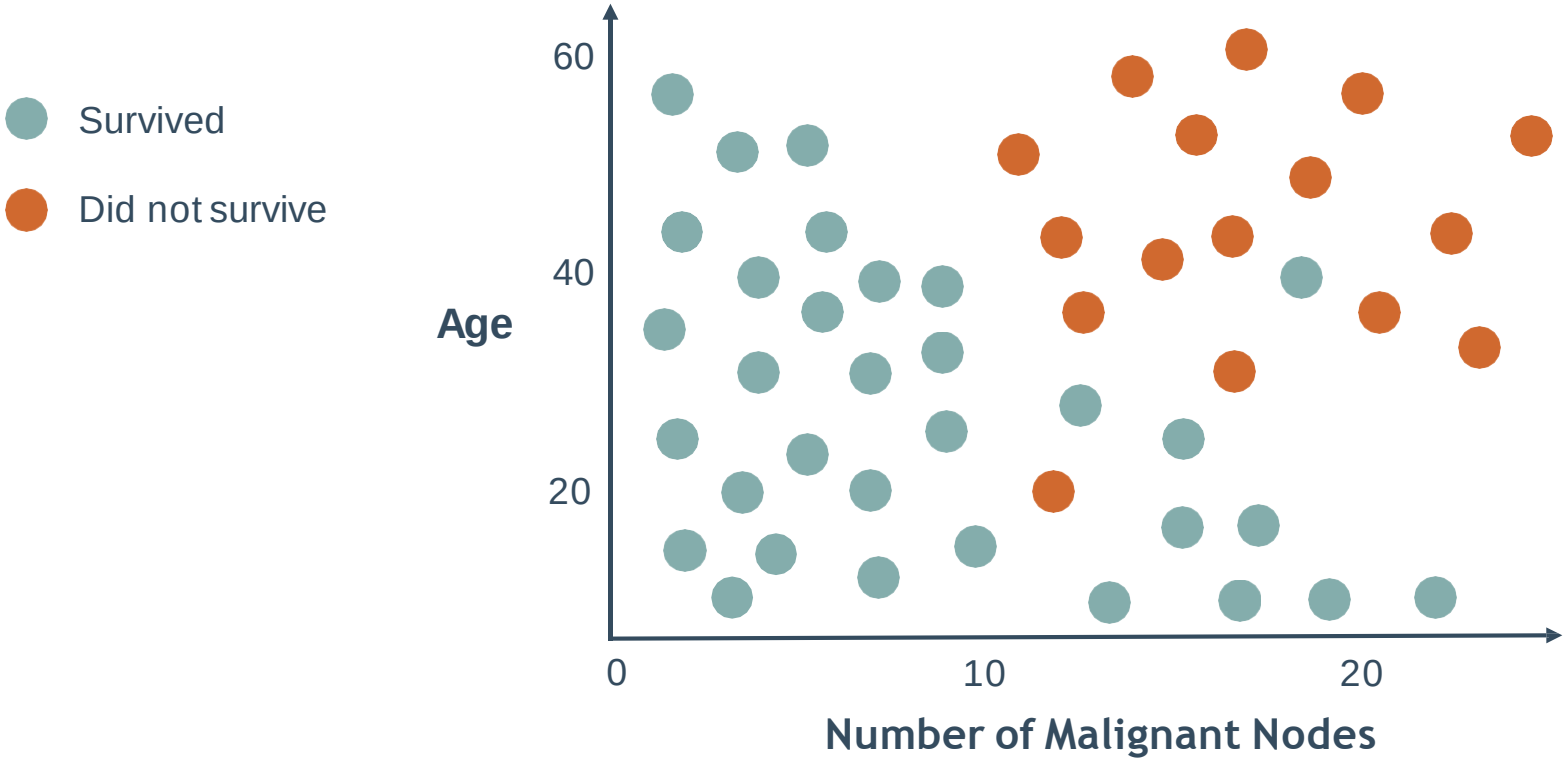
Survived
Did not survive
60
40
20
Age
0
10
20
Number of Malignant Nodes

K近邻（KNN）分类

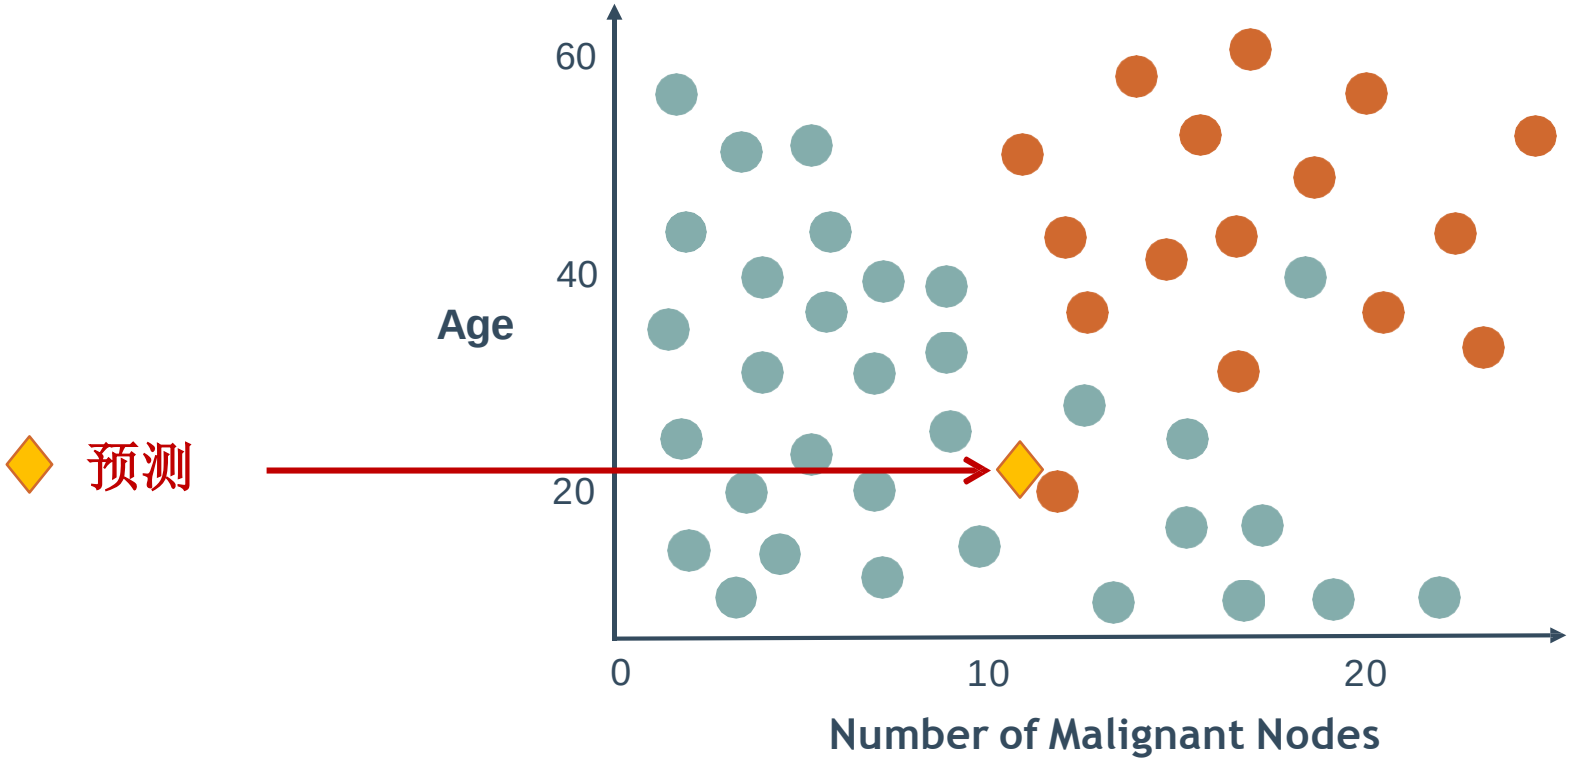

K近邻（KNN）分类

近朱者赤
近墨者黑

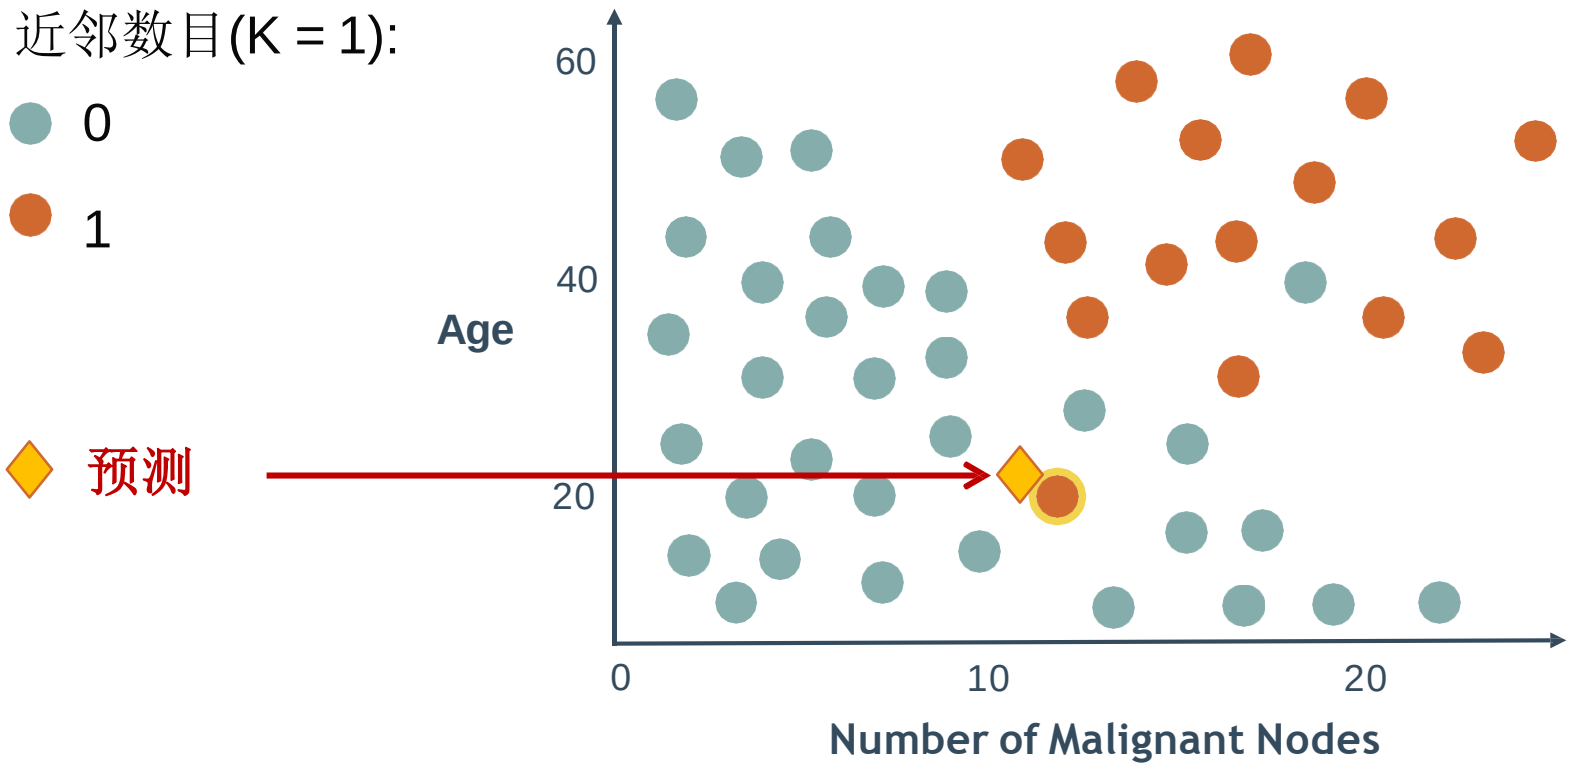

K近邻（KNN）分类

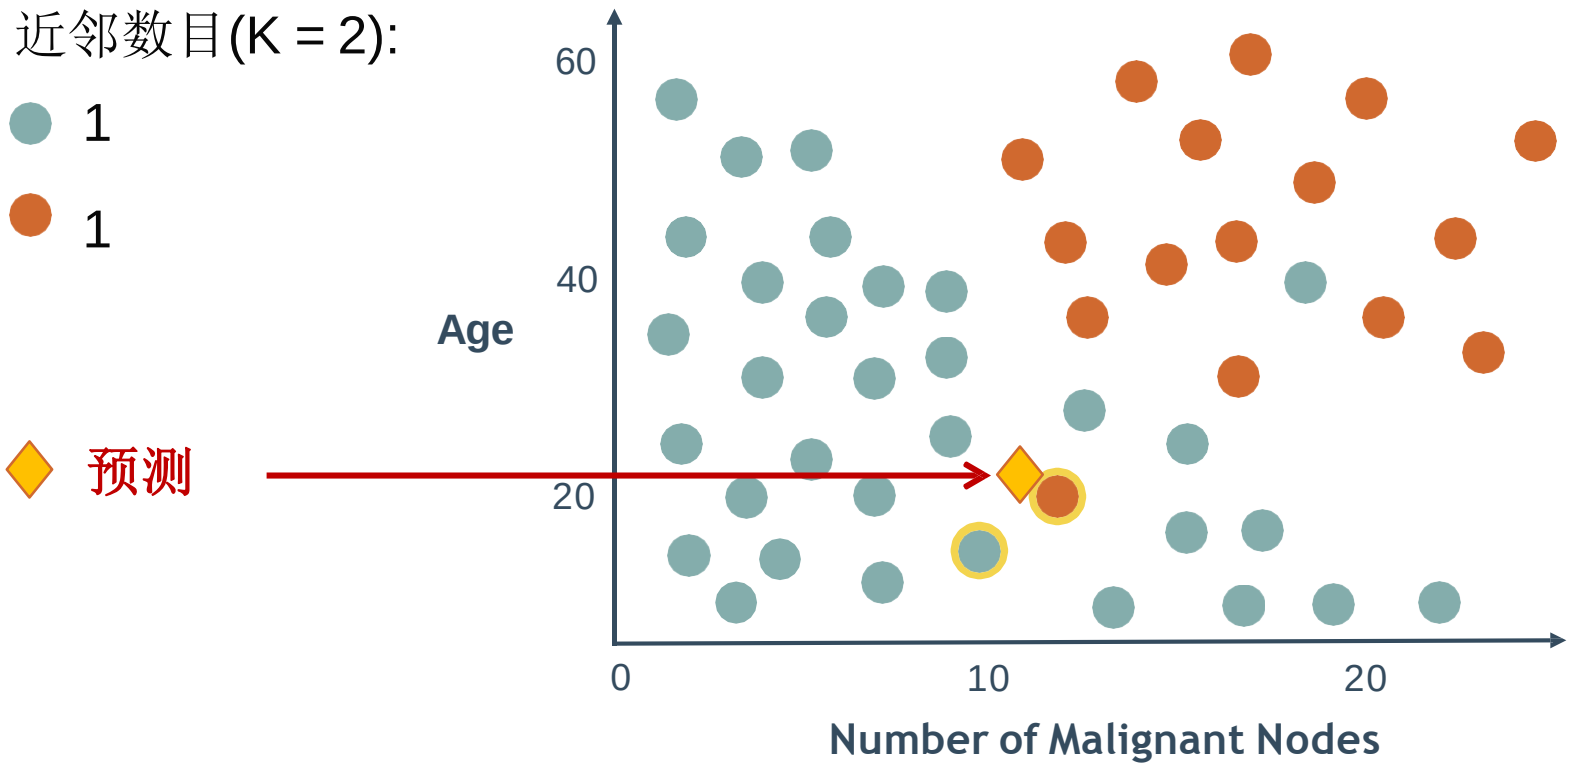

K近邻（KNN）分类

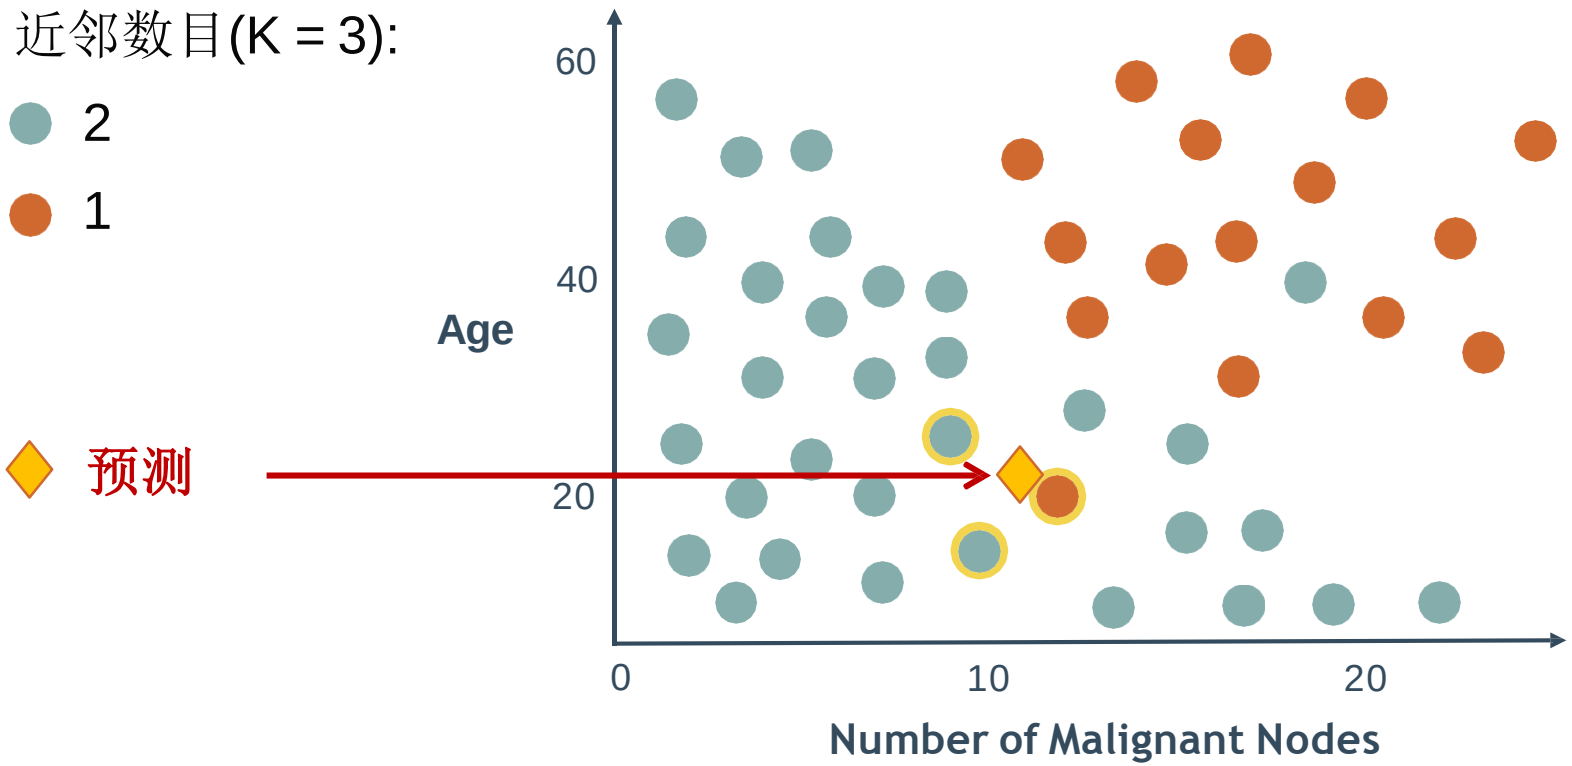

K近邻（KNN）分类

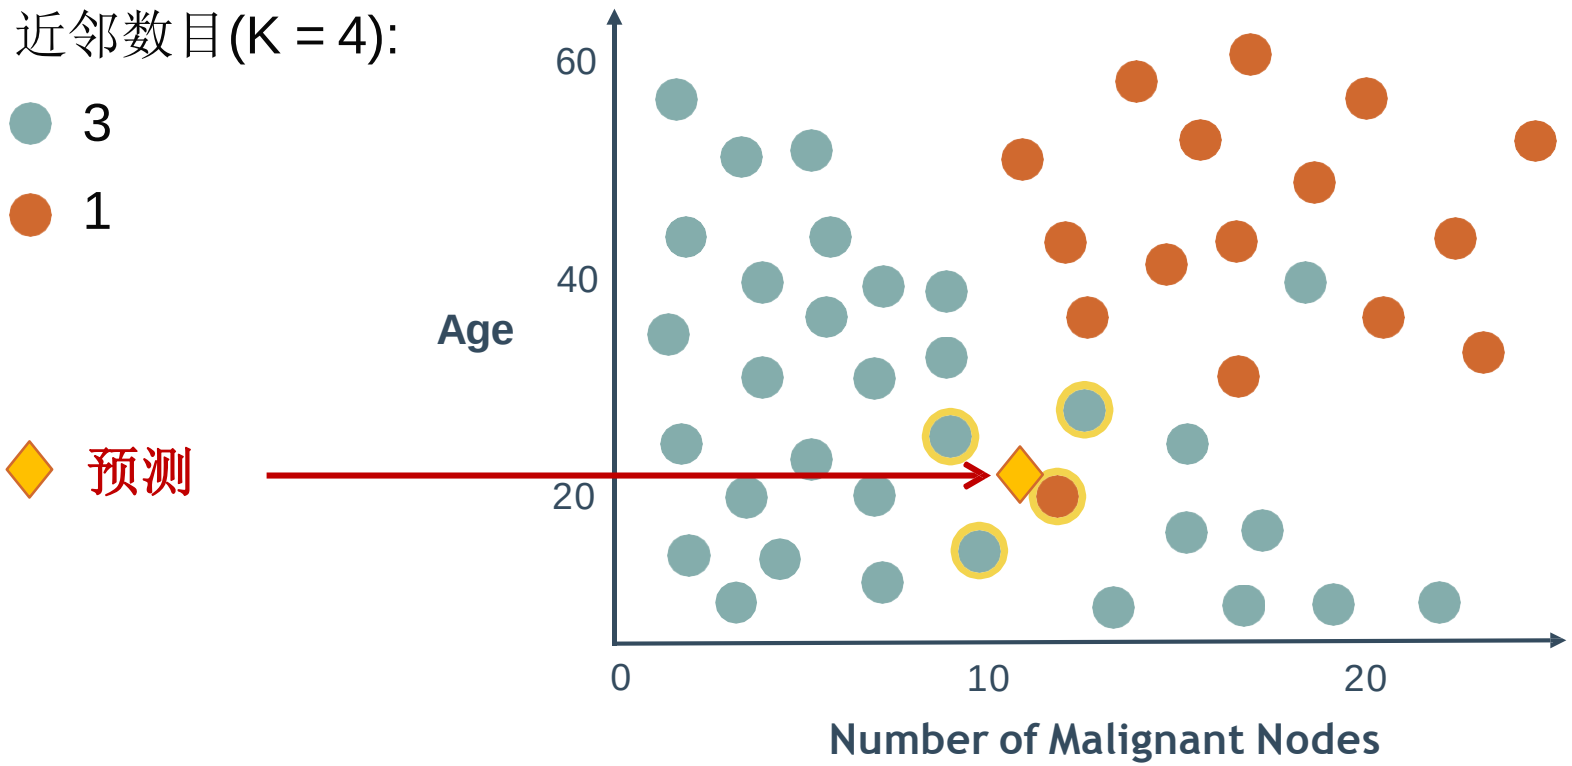

K近邻模型需要选择

- 正确的“K”值
- 如何度量相邻两点之间的相似性/距离？

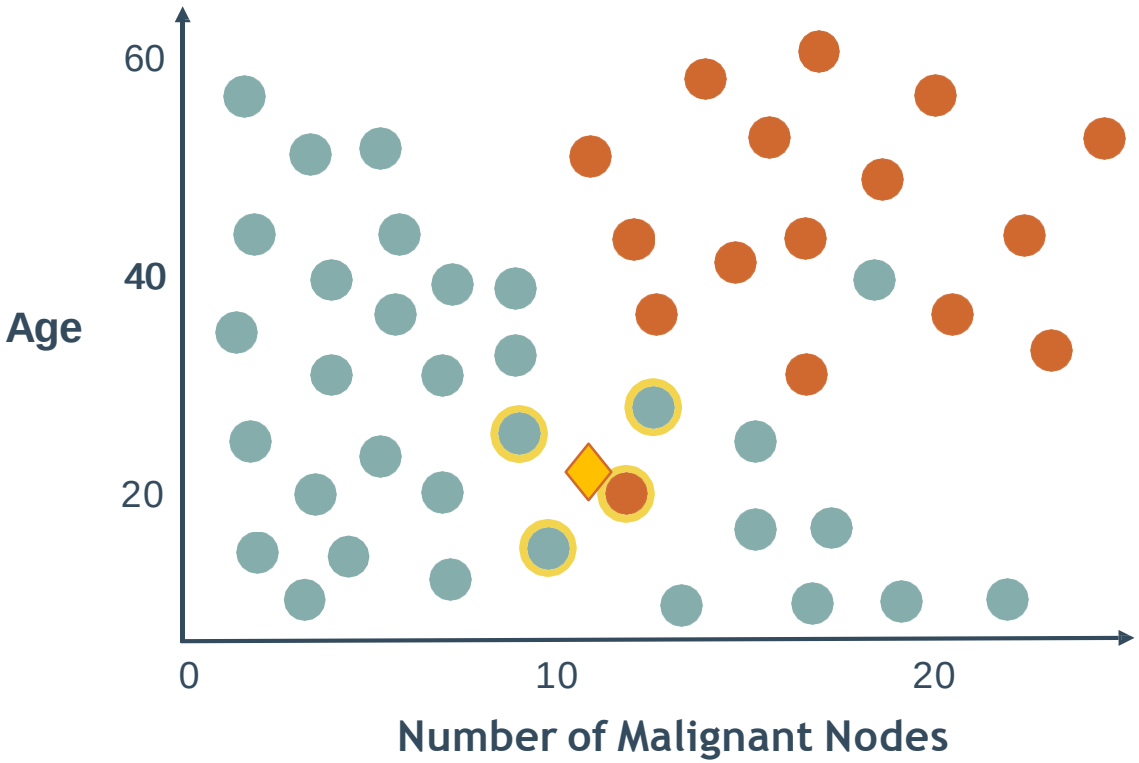

K值的选择

K近邻模型的判定边界

K = 1

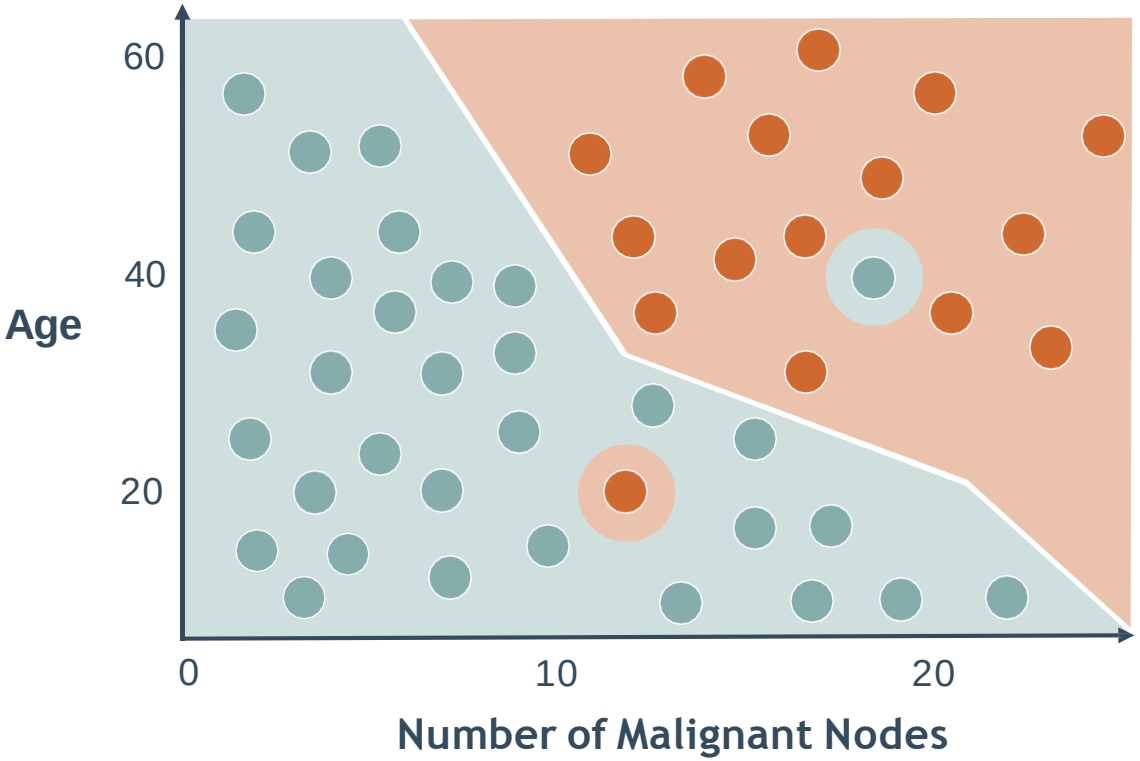

K近邻模型的判定边界

K = All

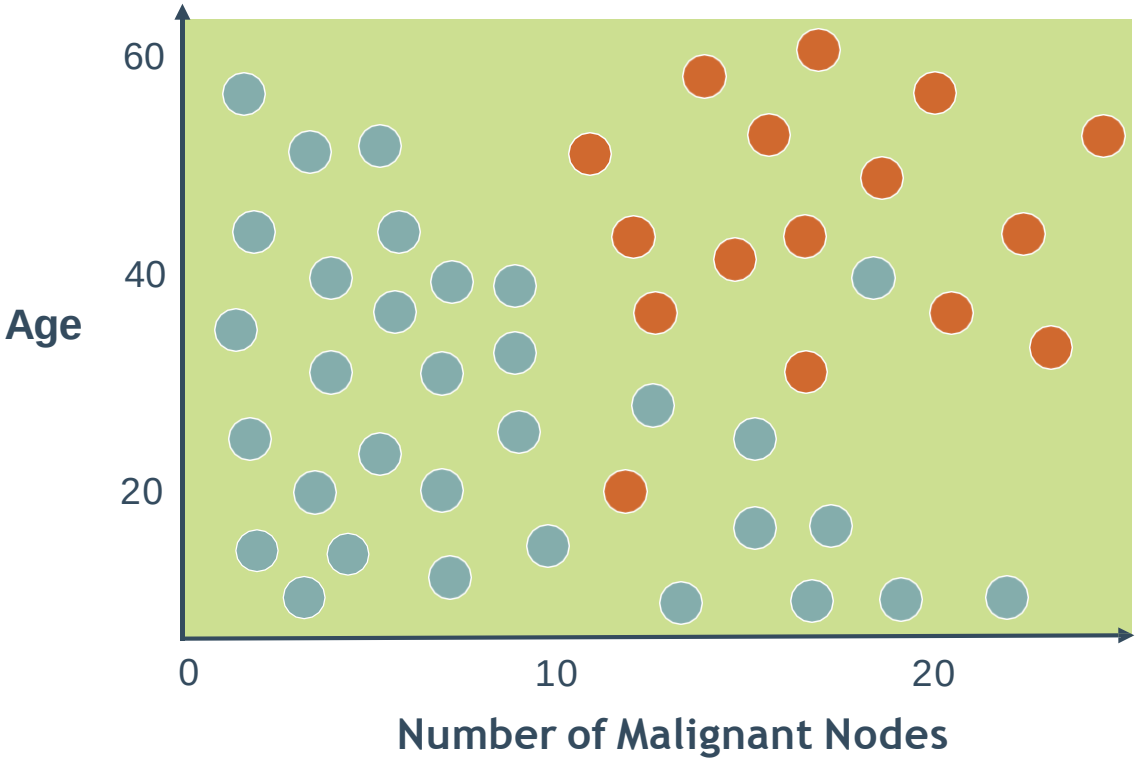

K值的大小会影响判定边界

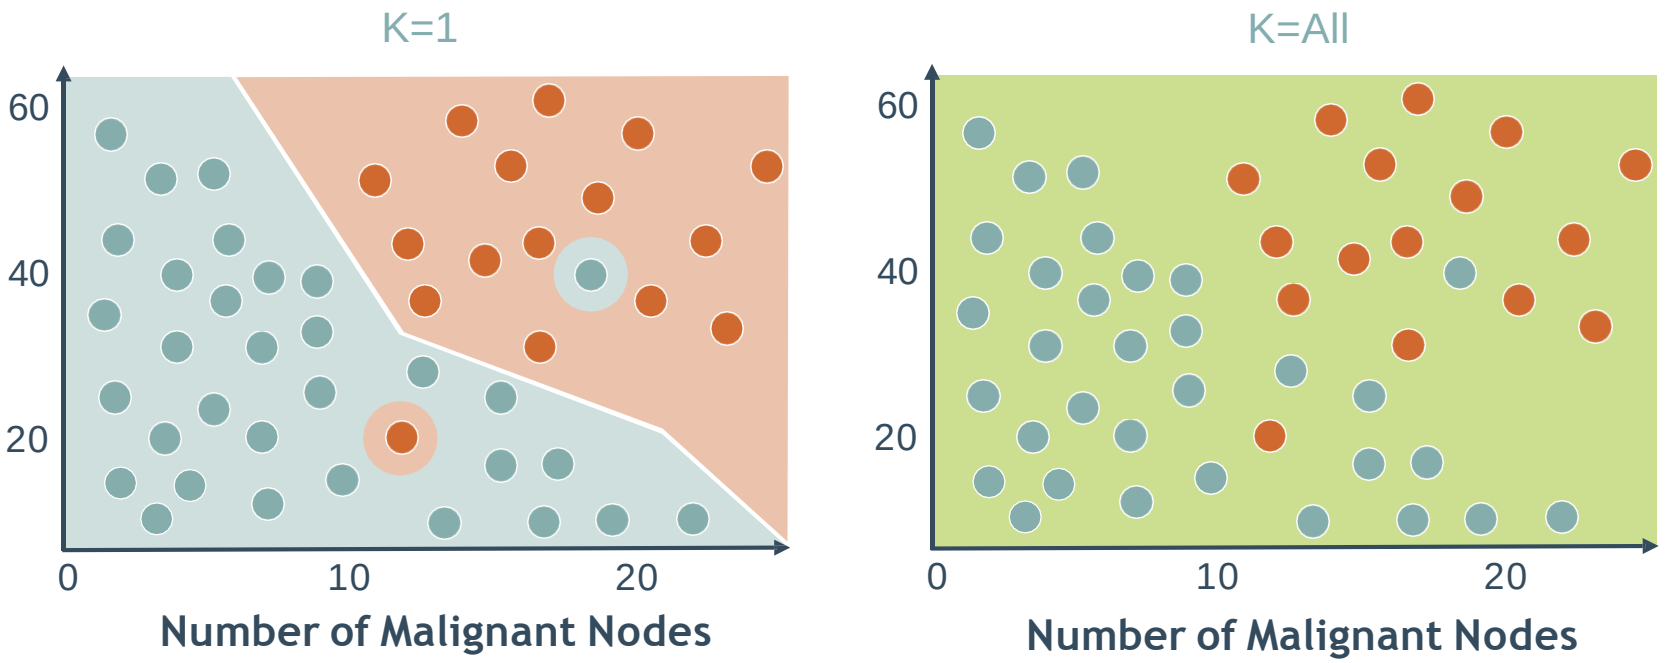

距离的度量

K近邻模型中的距离测度

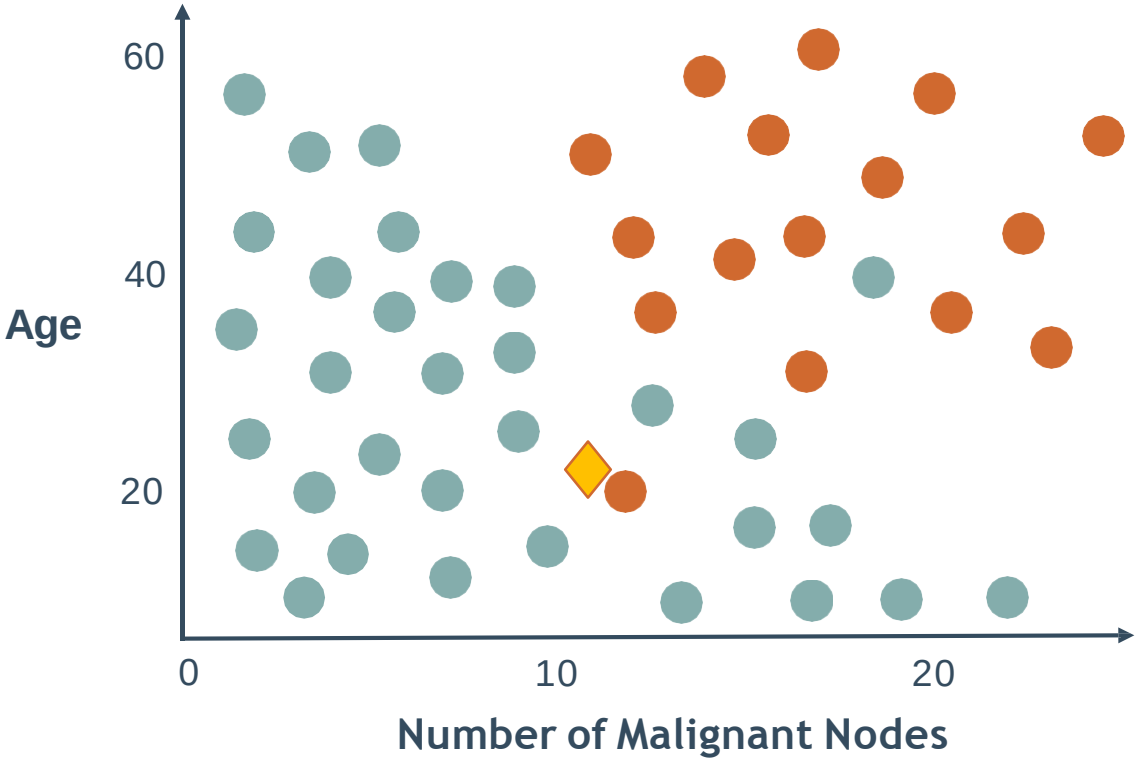

K近邻模型中的距离测度

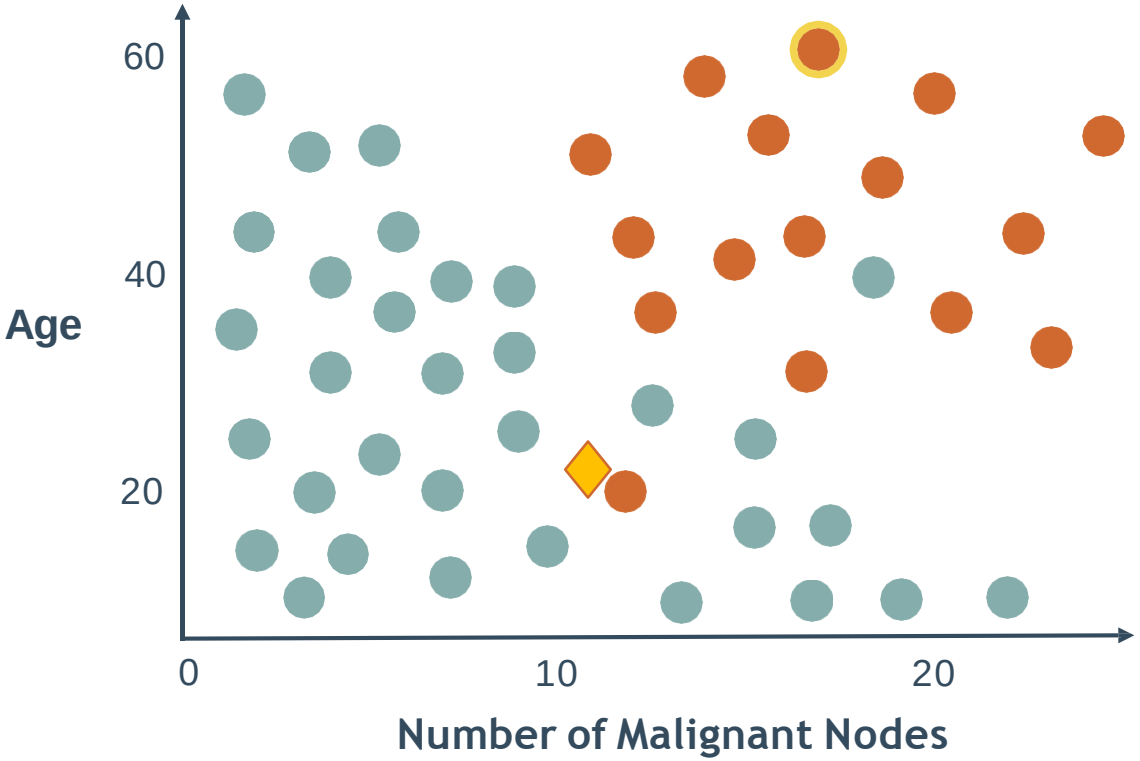

欧几里得距离

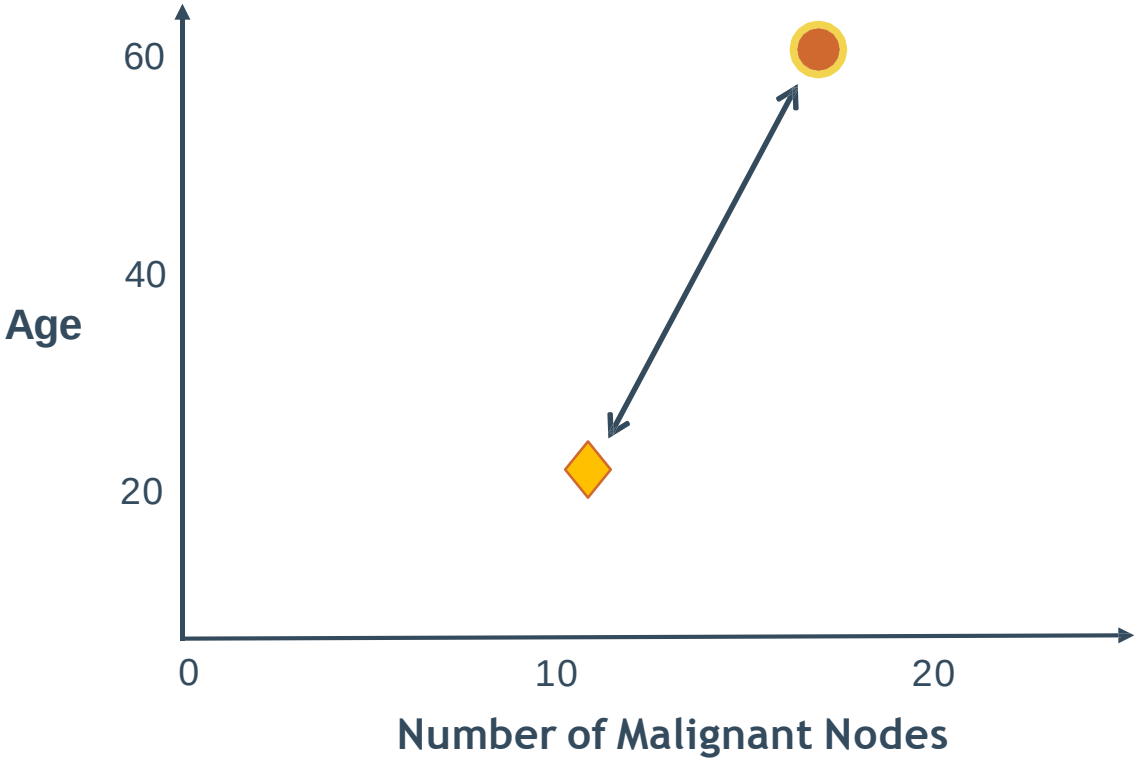

欧几里得距离（L2距离）

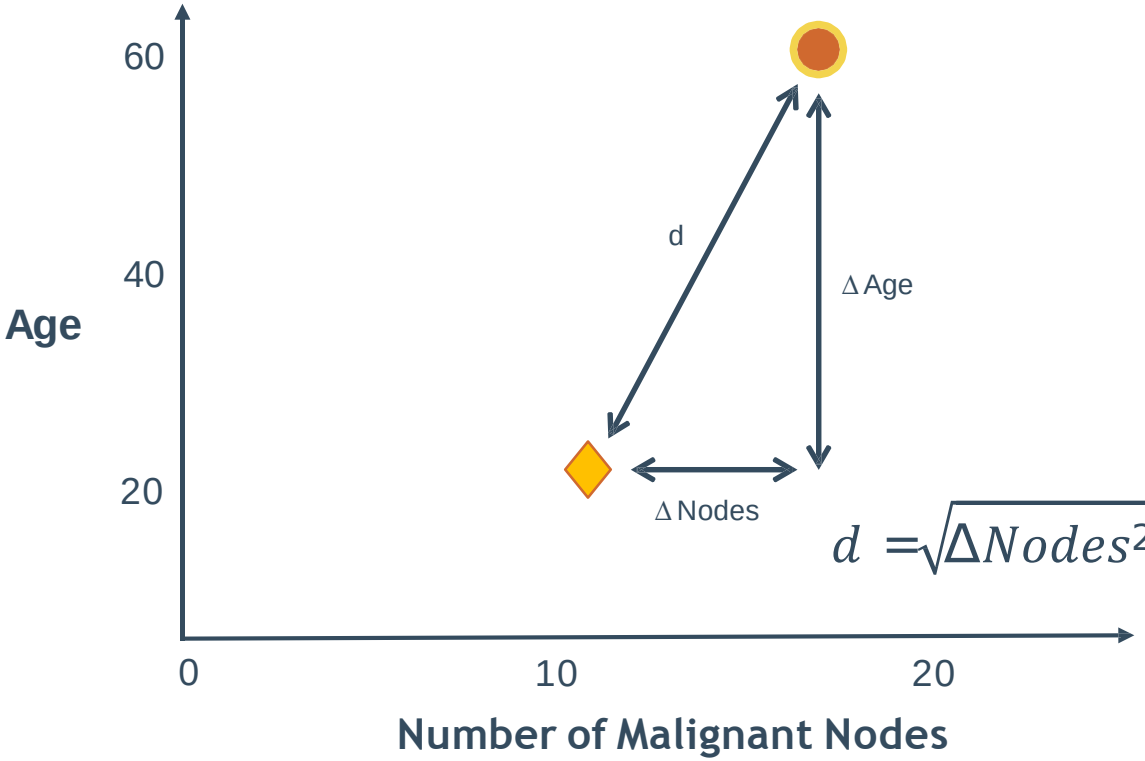

$$d = \sqrt{\Delta Nodes^2 + \Delta Age^2}$$

曼哈顿距离（L1或街区距离）

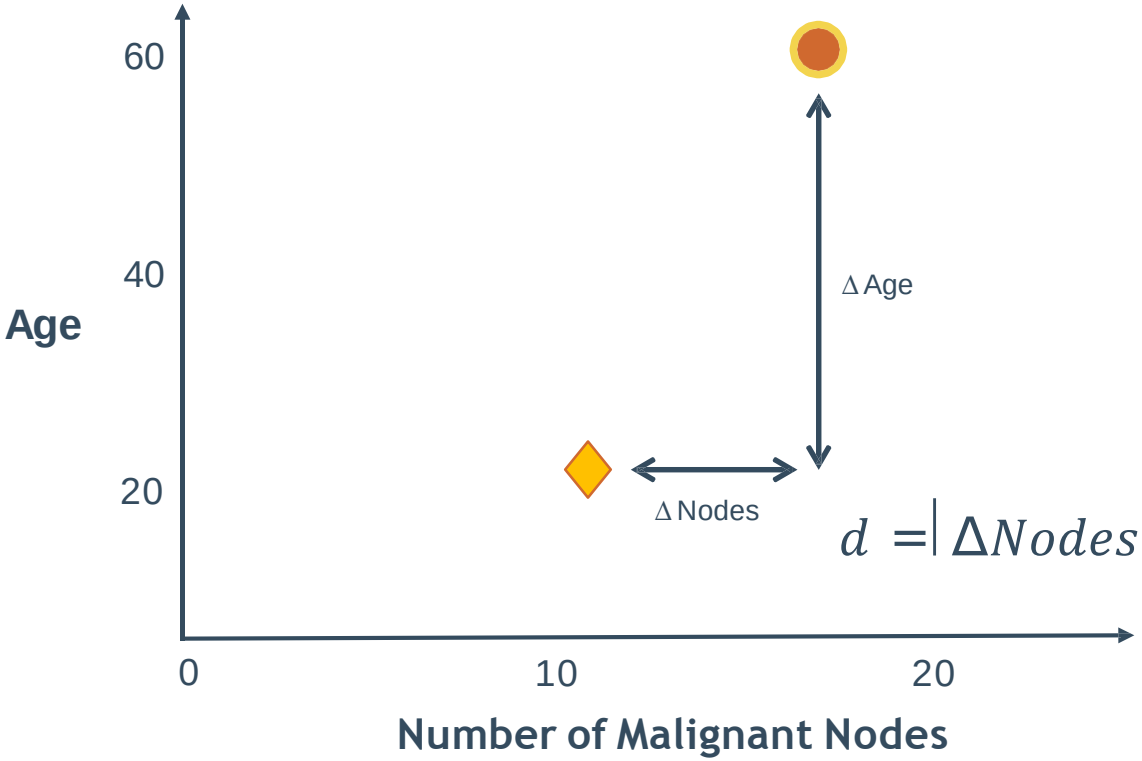

$$d = |\Delta Nodes| + |\Delta Age|$$

闵可夫斯基距离

$$dist(x_i, x_j) = \left(\sum_{u=1}^{n} |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}}$$

数据缩放

缩放比例对计算距离非常重要

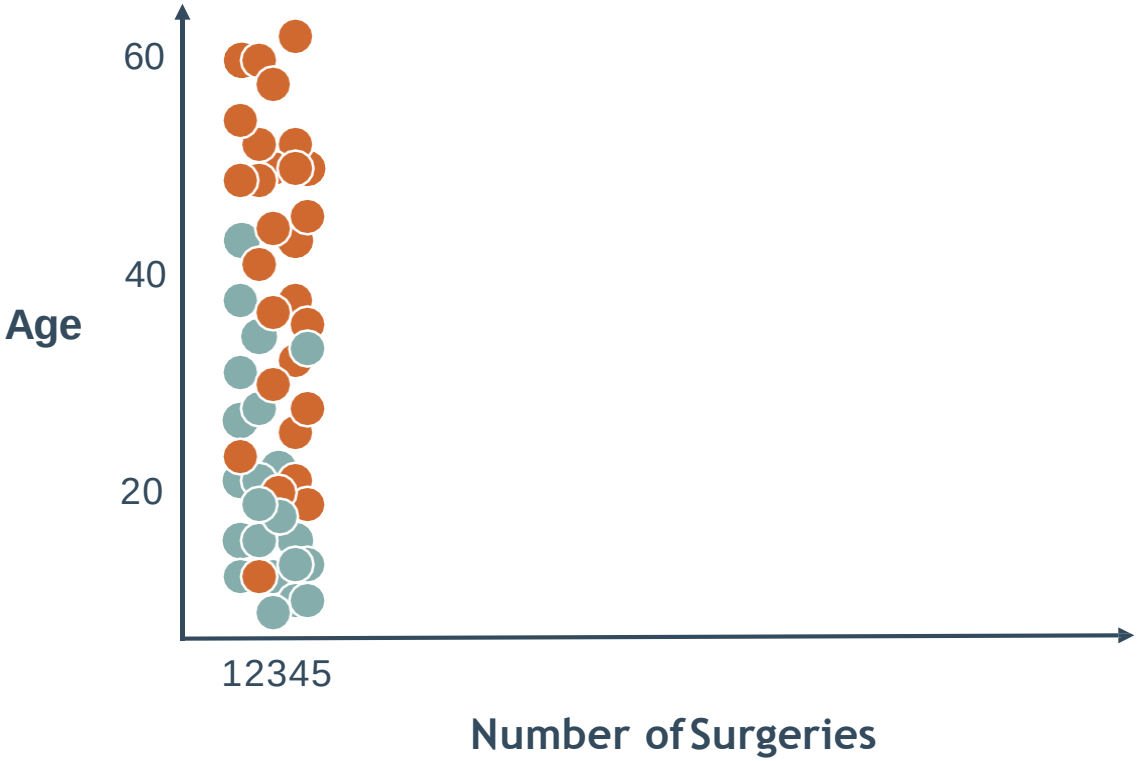

缩放比例对计算距离非常重要

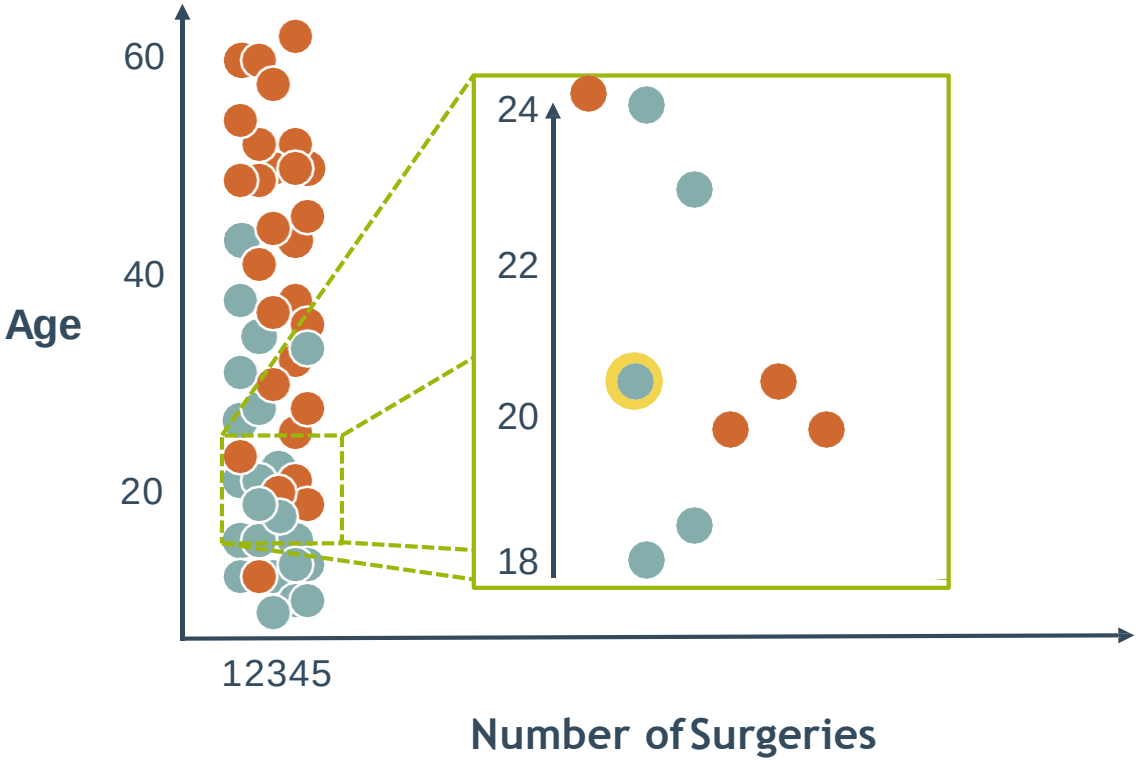

缩放比例对计算距离非常重要

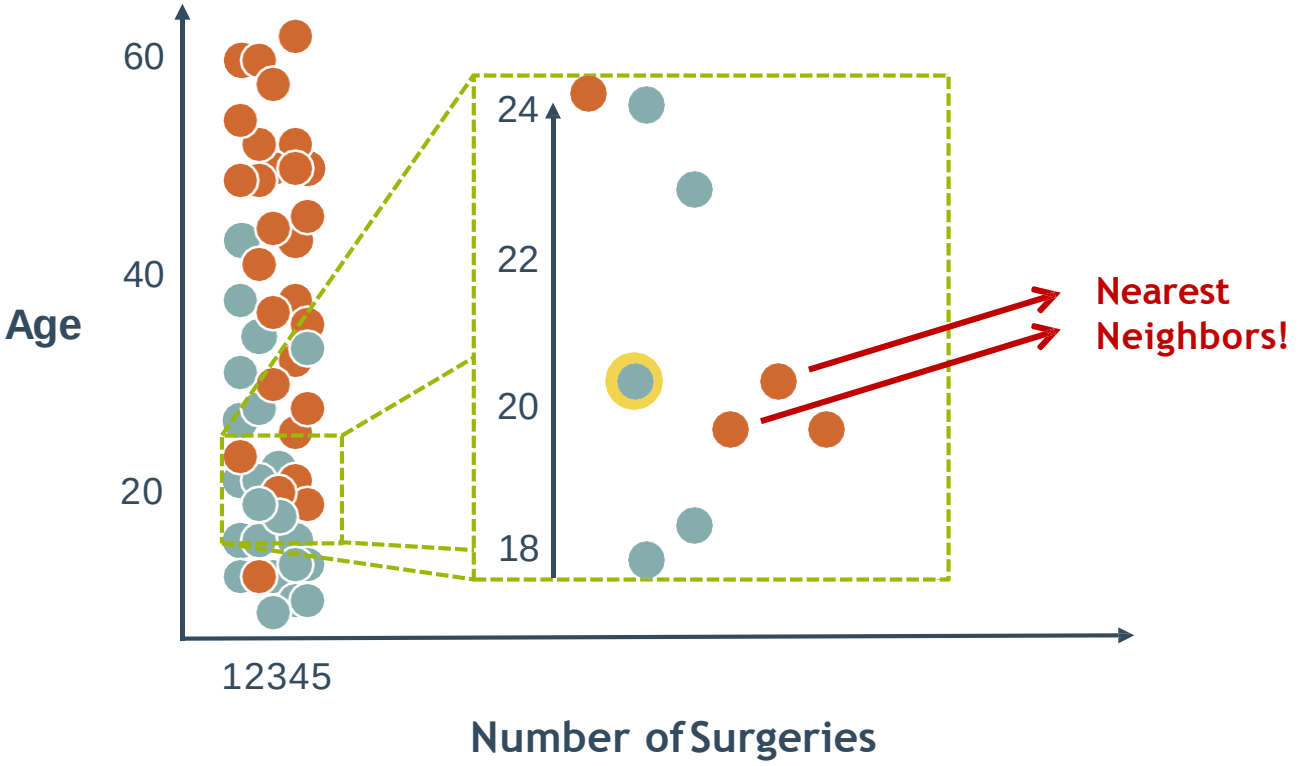

缩放比例对计算距离非常重要

"特征缩放"

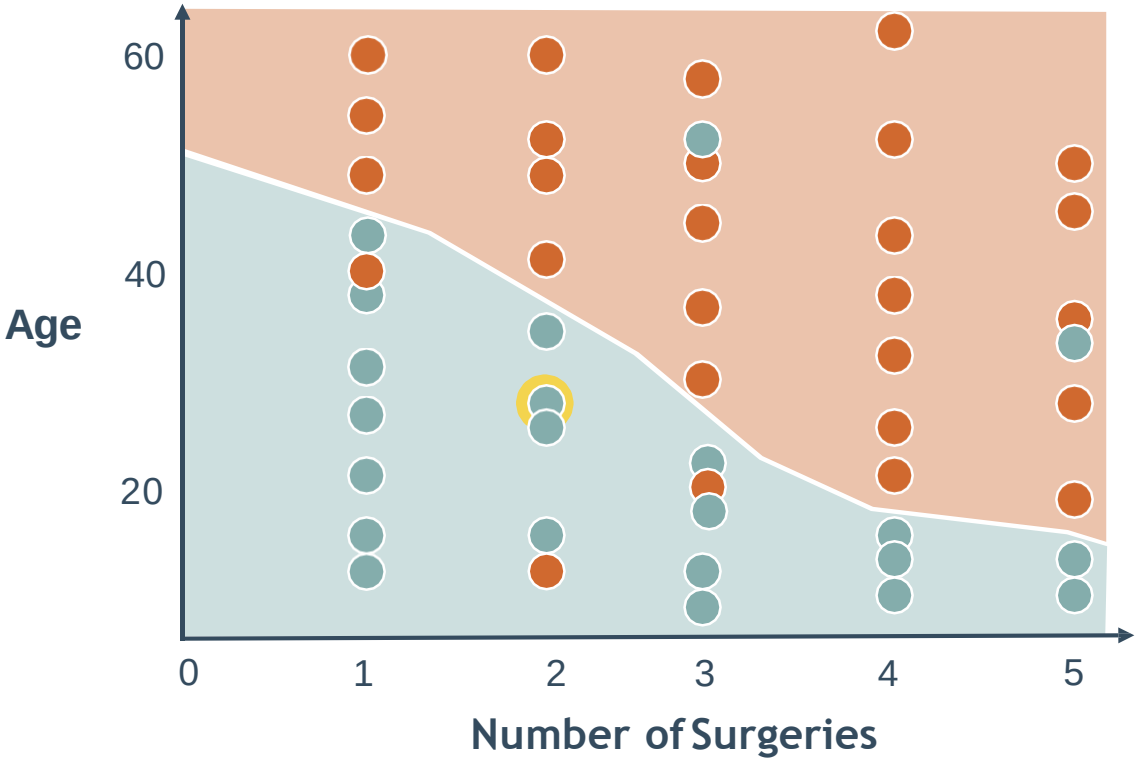

缩放比例对计算距离非常重要

"特征缩放"

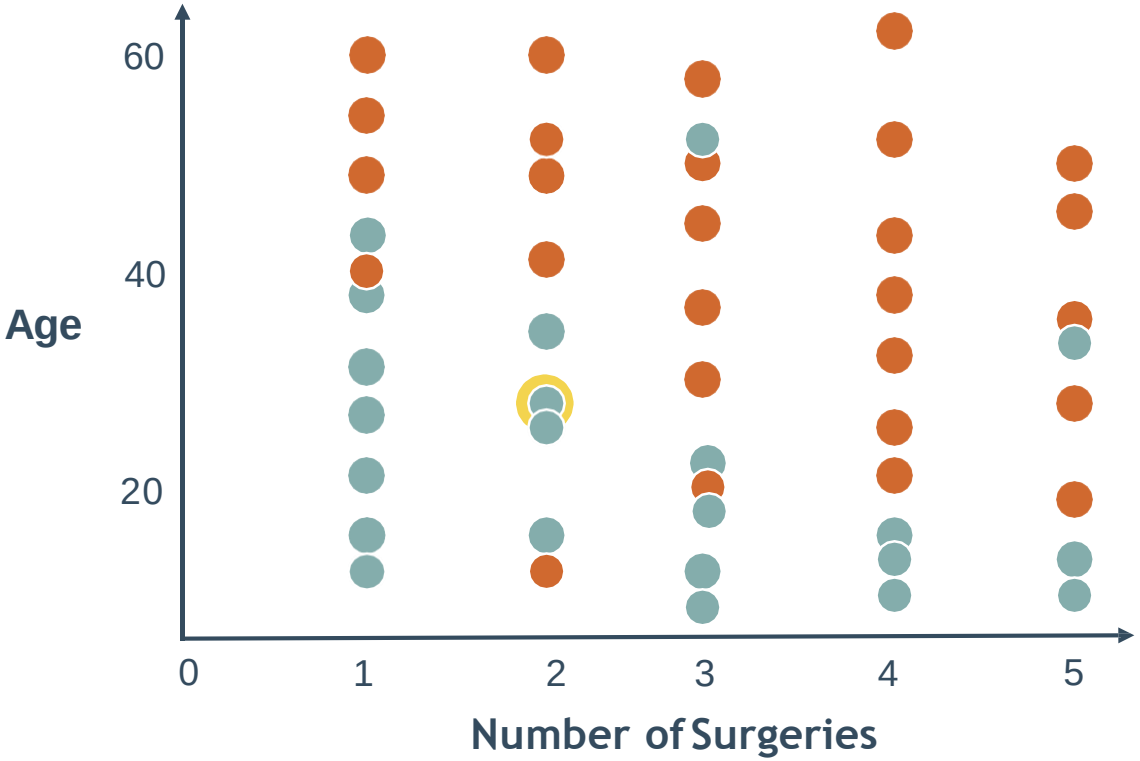

缩放比例对计算距离非常重要

"特征缩放"

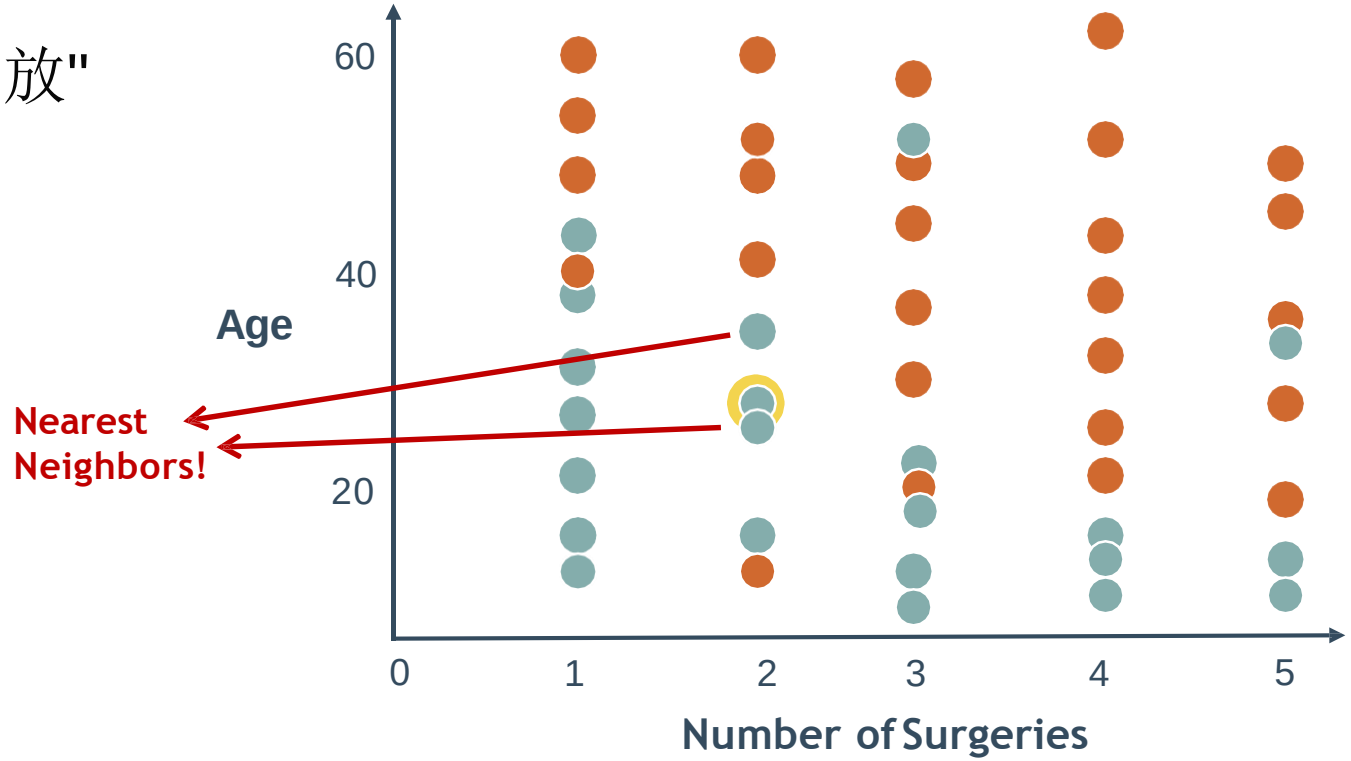

特征缩放的不同方法

- **Standard Scaler：**即标准化，尽量将数据转化为均值为0，方差为1的数据，形如标准正态分布（高斯分布）。

$$\frac{x_i - x_{mean}}{x_{std}}$$

- **Minimum-Maximum Scaler：**将数据缩放到某一给定范围（通常是[0, 1]）。

$$\frac{x_i - min(x_i)}{max(x_i) - min(x_i)}$$

- **Maximum Absolute Value Scaler：**通过除以最大绝对值，将数据缩放到[-1, 1]。

$$z = \frac{x_i}{max(|x_i|))}$$

- 使各特征的数值都处于同一数量级上。

特征缩放的语法

导入包含缩放方法的类：

```
from sklearn.preprocessing import StandardScaler
```

创建该类的一个对象：

```
StdSc = StandardScaler()
```

拟合缩放的参数，然后对数据做转换：

```
StdSc = StdSc.fit(X_data)
X_scaled = StdSc.transform(X_data)
```

或者 `X_scaled = StdSc.fit_transform(X_data)`

特征缩放的语法

导入包含缩放方法的类：

```
from sklearn.preprocessing import StandardScaler
```

创建该类的一个对象：

```
StdSc = StandardScaler()
```

拟合缩放的参数，然后对数据做转换：

```
StdSc = StdSc.fit(X_data)
X_scaled = StdSc.transform(X_data)
```

其他缩放方法: MinMaxScaler, MaxAbsScaler.

KNN多分类、KNN回归

K近邻多分类的判定边界

K = 5

- Full remission
- Partial remission
- Did not survive

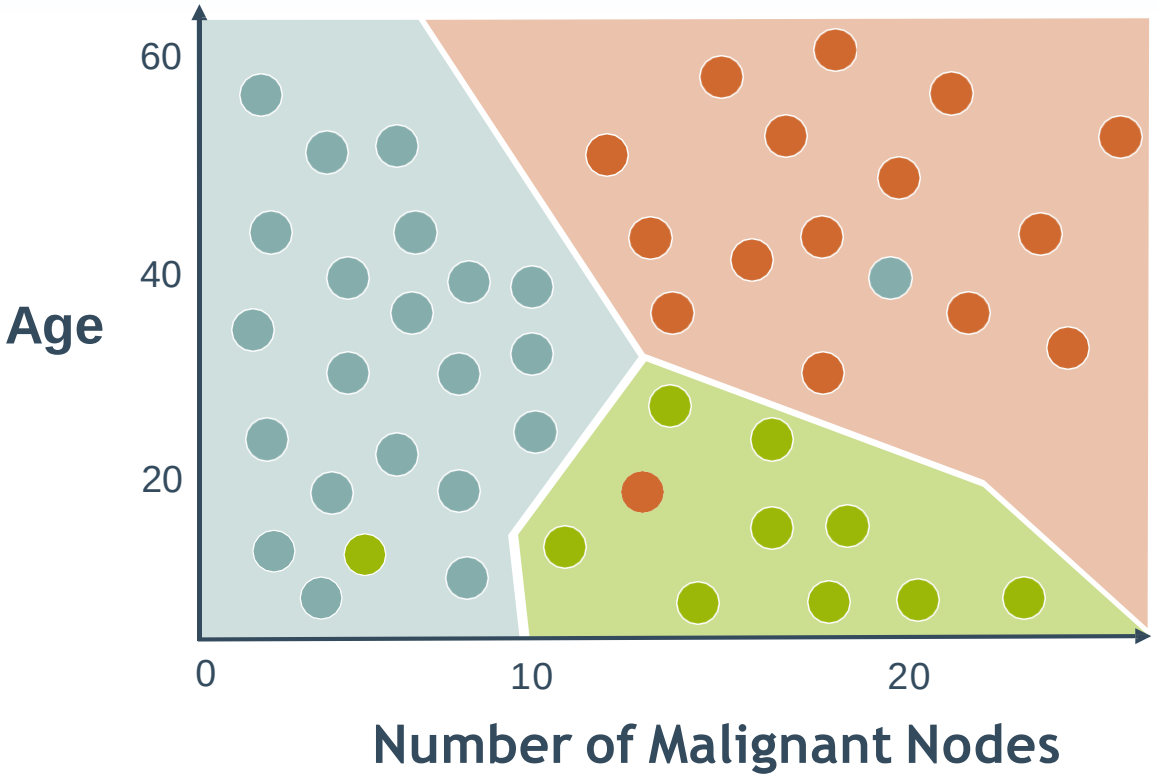

投票决定：少数服从多数，近邻中哪个类别的点最多就分为该类。

加权投票法：根据距离的远近，对近邻的投票进行加权，距离越近则权重越大（权重为距离平方的倒数）

K近邻回归

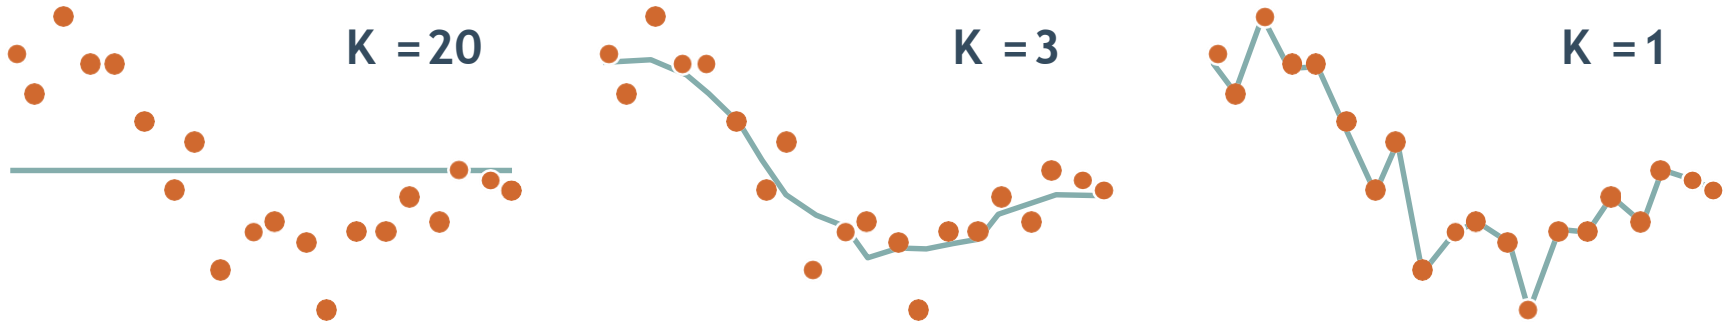

KNN模型特点及语法

K近邻模型的特点

- 建模快，因为它只是简单地存储数据
- 运行速度慢，因为需要计算很多的距离
- 占用内存多，如果数据集大的话

K近邻模型的语法

导入包含分类方法的类：

```
from sklearn.neighbors import KNeighborsClassifier
```

创建该类的一个对象：

```
KNN = KNeighborsClassifier(n_neighbors=3)
```

拟合数据集，即训练KNN模型，并用训练好的模型预测数据的标签：

```
KNN = KNN.fit(X_data, y_data)
y_predict = KNN.predict(X_data)
```

http://scikit-learn.org/stable/modules/generated/sklearn.neighbors.KNeighborsClassifier.html

K近邻模型的语法

导入包含分类方法的类：

```
from sklearn.neighbors import KNeighborsClassifier
```

创建该类的一个对象：

```
KNN = KNeighborsClassifier(n_neighbors=3)
```

拟合数据集，即训练KNN模型，并用训练好的模型预测数据的标签：

```
KNN = KNN.fit(X_data, y_data)
y_predict = KNN.predict(X_data)
```

这种 fit 和 predict/transform 语法会贯穿整个课程

K近邻模型的语法

导入包含分类方法的类：

```
from sklearn.neighbors import KNeighborsClassifier
```

创建该类的一个对象：

```
KNN = KNeighborsClassifier(n_neighbors=3)
```

拟合数据集，即训练KNN模型，并用训练好的模型预测数据的标签：

```
KNN = KNN.fit(X_data, y_data)
y_predict = KNN.predict(X_data)
```

回归使用KNeighborsRegressor

案例研究：鸢尾花数据集

150个鸢尾花样例

来自3个不同的属种

- Setosa, Versicolor, Virginica
- 每种50个样例

用4个特征度量

- 花萼的长度和宽度，花瓣的长度和宽度

分类问题：给定一株鸢尾花，判定其属种

鸢尾花数据集

Samples 样例
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

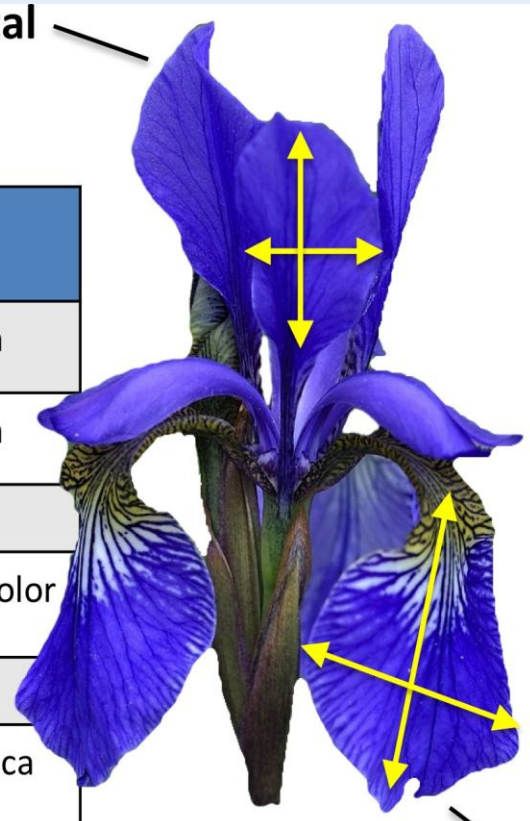

Features 特征
(attributes, measurements, dimensions)

Class labels
(targets)
类别标签

典型的机器学习过程

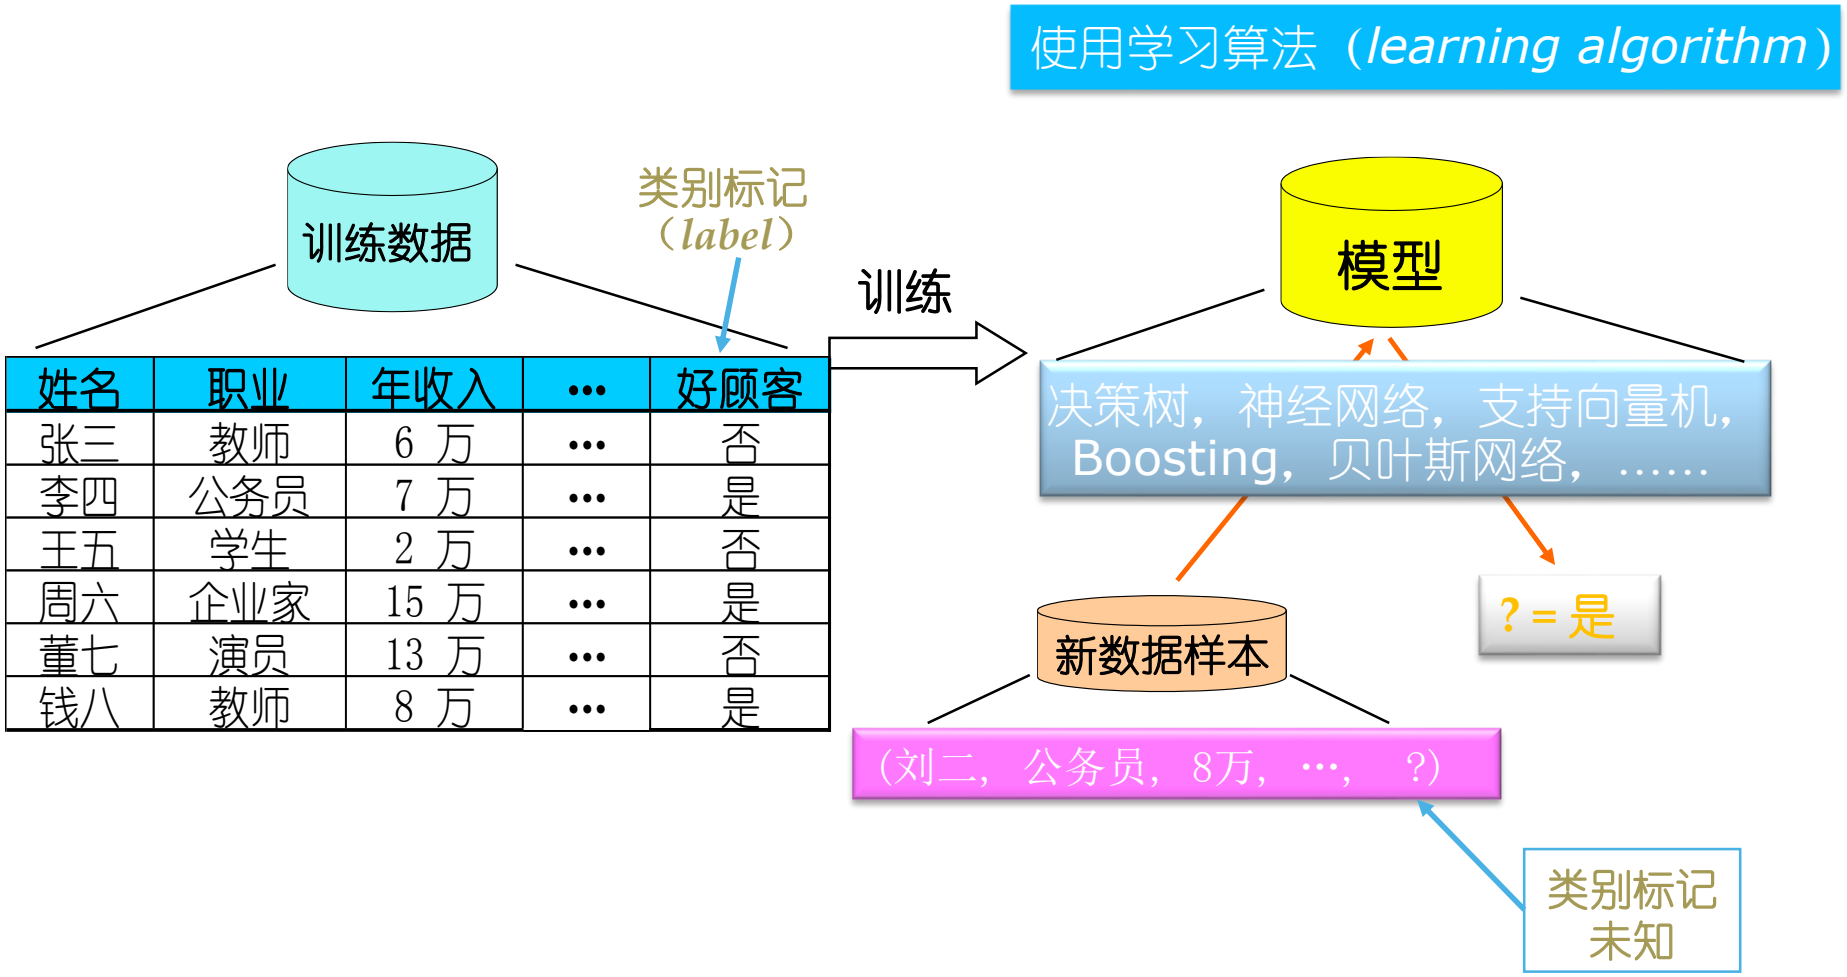

姓名	职业	年收入	…	好顾客
张三	教师	6 万	…	否
李四	公务员	7 万	…	是
王五	学生	2 万	…	否
周六	企业家	15 万	…	是
董七	演员	13 万	…	否
钱八	教师	8 万	…	是
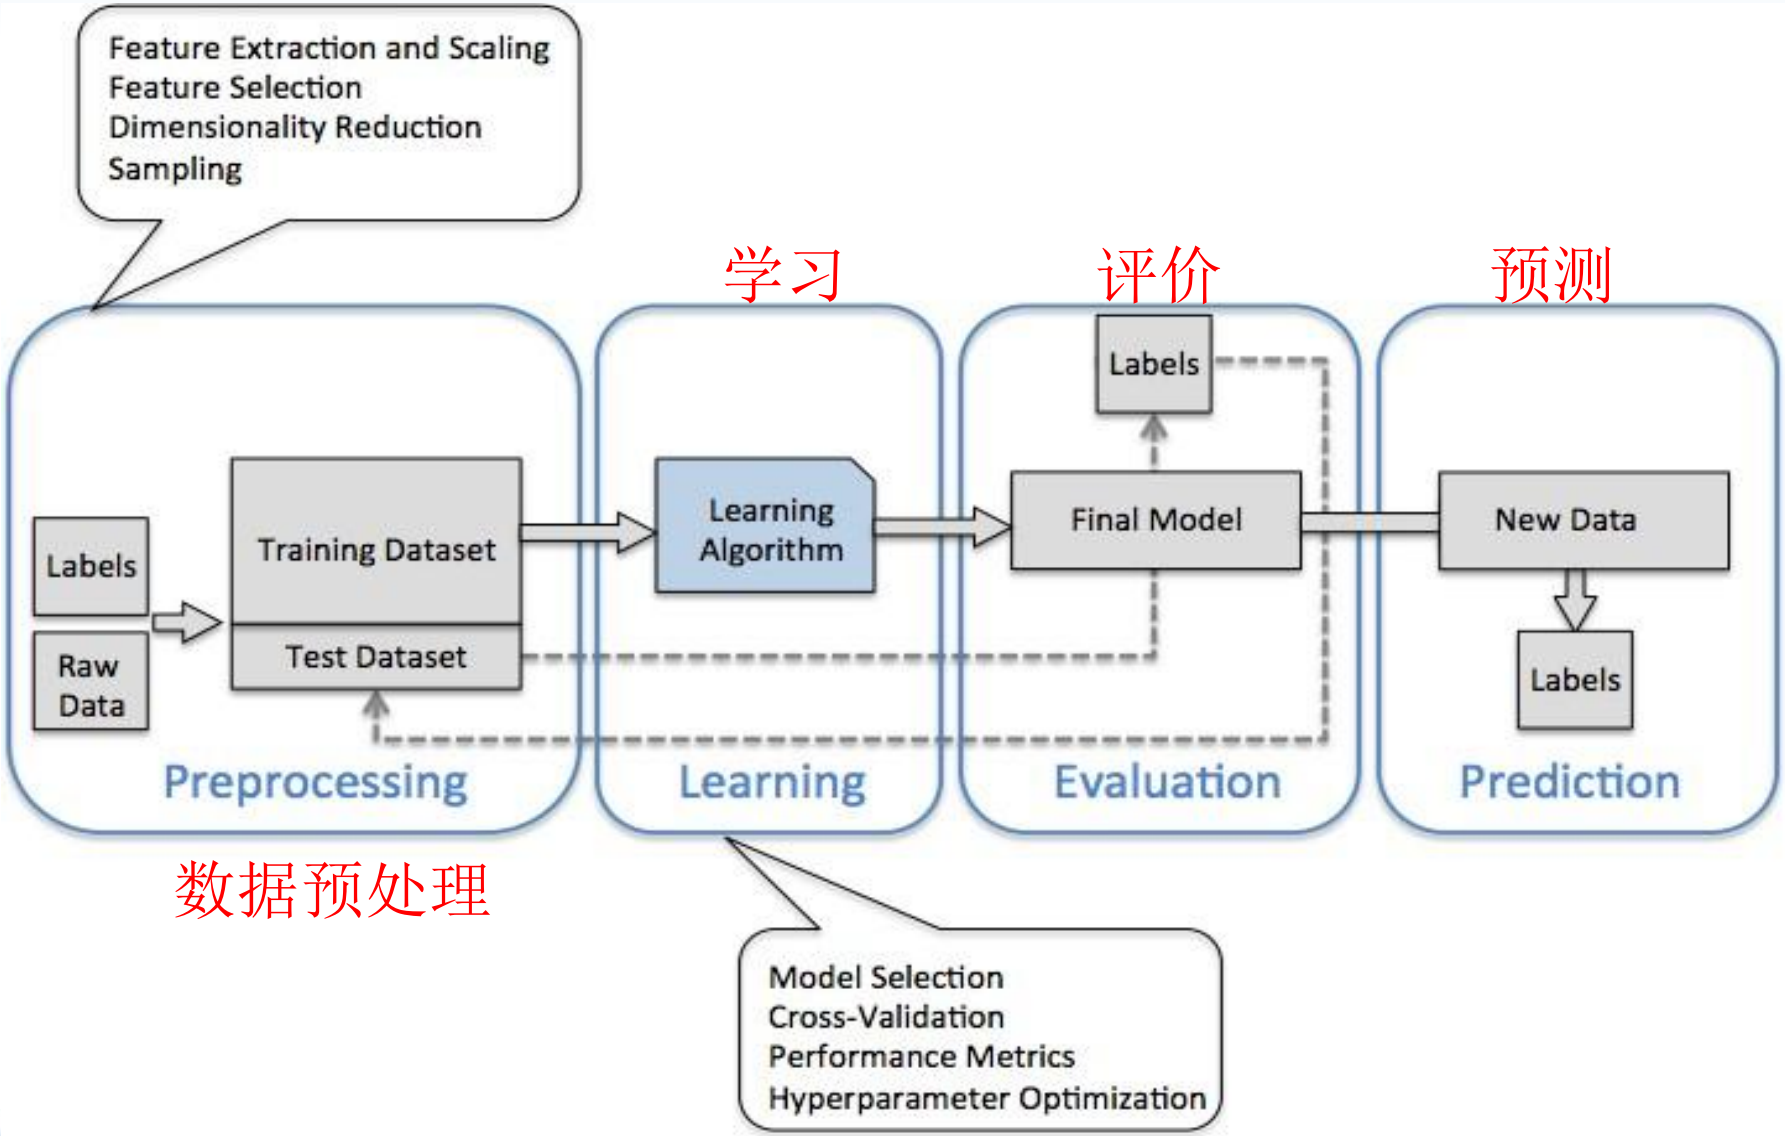
创建机器学习应用路线图