第6章 线性回归

基本形式

线性模型：学得一个通过属性的线性组合来进行预测的函数。

一般形式

$$f(\boldsymbol{x}) = w_1 x_1 + w_2 x_2 + \ldots + w_d x_d + b$$

$\boldsymbol{x} = (x_1; x_2; \ldots; x_d)$ 是由d个属性描述的示例，其中 x_i 是 $\boldsymbol{x}$ 在第 i 个属性上的取值

向量形式

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathrm{T}} \boldsymbol{x} + b$$

其中

$$\boldsymbol{w} = (w_1; w_2; \ldots; w_d)$$

线性模型

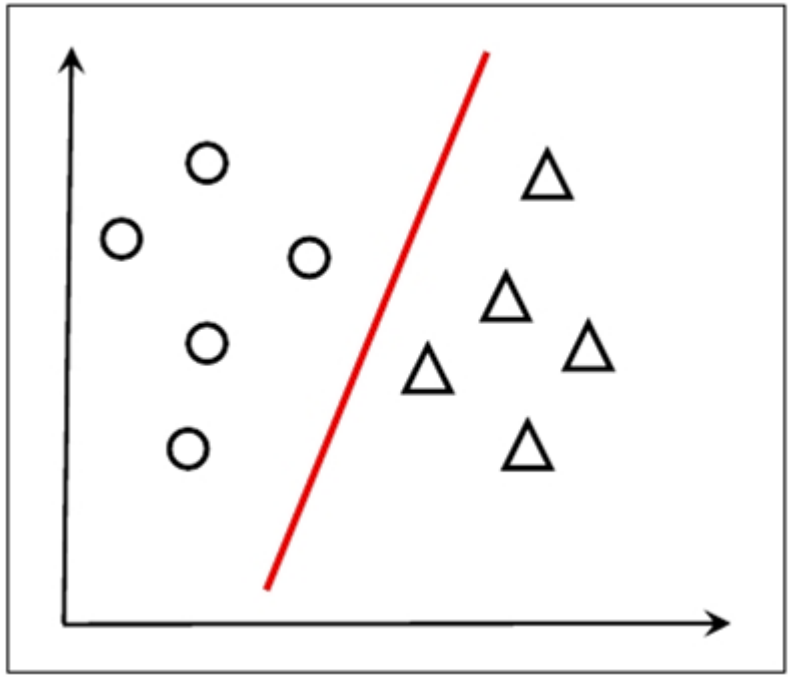

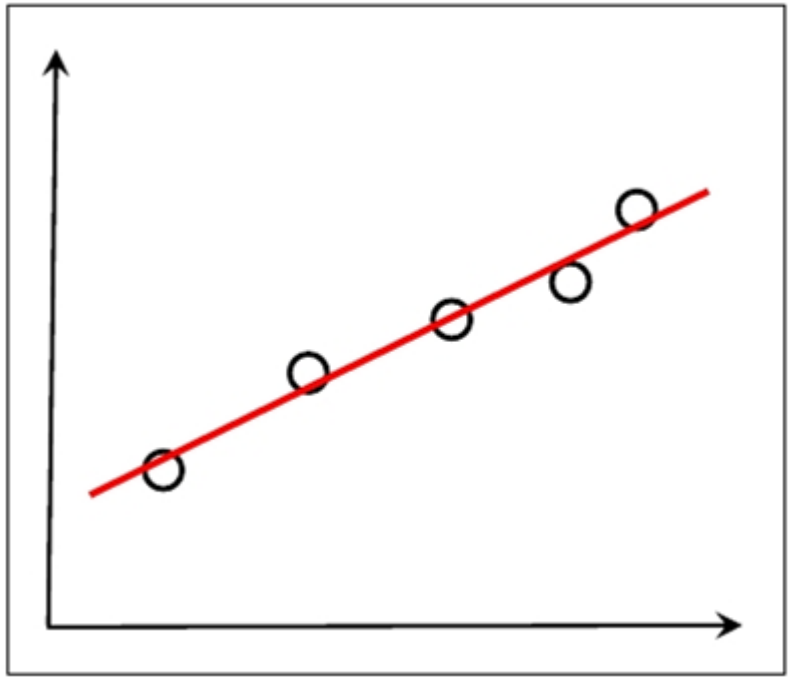

线性模型优点

- 形式简单、易于建模
- 可解释性
- 非线性模型的基础
- 引入层级结构或高维映射

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	沉闷	是
3	乌黑	蜷缩	浊响	是
4	青绿	蜷缩	沉闷	是
5	浅白	蜷缩	浊响	是
6	青绿	稍蜷	浊响	是
7	乌黑	稍蜷	浊响	是
8	乌黑	稍蜷	浊响	是
9	乌黑	稍蜷	沉闷	否
10	青绿	硬挺	清脆	否
11	浅白	硬挺	清脆	否
12	浅白	蜷缩	浊响	否
13	青绿	稍蜷	浊响	否
14	浅白	稍蜷	沉闷	否
15	乌黑	稍蜷	浊响	否
16	浅白	蜷缩	浊响	否
17	青绿	蜷缩	沉闷	否

综合考虑色泽、根蒂和敲声来判断西瓜好不好

$$f_{\text{好瓜}}(\boldsymbol{x}) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$

其中根蒂的系数最大，表明根蒂最要紧；而敲声的系数比色泽大，说明敲声比色泽更重要

6.1 线性回归

给定数据集 $D=\{(\boldsymbol{x}_1,y_1),(\boldsymbol{x}_2,y_2),\ldots,(\boldsymbol{x}_m,y_m)\}$

其中 $\boldsymbol{x}_i=(x_{i1};x_{i2};\ldots;x_{id})$ $y_i\in\mathbb{R}$,

线性回归（linear regression）

学得一个线性模型以尽可能准确地预测实值输出标记

$$f(\boldsymbol{x})=w_1x_1+w_2x_2+\ldots+w_dx_d+b$$

$$f(\boldsymbol{x})=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}+b$$

$$f(\boldsymbol{x}) = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

离散属性处理

- 有“序”关系
  连续化为连续值

浅白，青绿，乌黑 → 0，0.5，1

- 无“序”关系
  有k个属性值，则转换为k维向量

西瓜、南瓜、冬瓜 → (0,0,1), (0,1,0), (1,0,0)

```
'青绿', '蜷缩', '浊响', '清晰', '凹陷', '硬滑'
'乌黑', '蜷缩', '沉闷', '清晰', '凹陷', '硬滑'
'乌黑', '蜷缩', '浊响', '清晰', '凹陷', '硬滑'
'青绿', '蜷缩', '沉闷', '清晰', '凹陷', '硬滑'
'浅白', '蜷缩', '浊响', '清晰', '凹陷', '硬滑'
'青绿', '稍蜷', '浊响', '清晰', '稍凹', '软粘'
'乌黑', '稍蜷', '浊响', '稍糊', '稍凹', '软粘'
```

线性回归

单一属性的线性回归目标

$$f(x_i) = wx_i + b \text{ 使得 } f(x_i) \simeq y_i$$

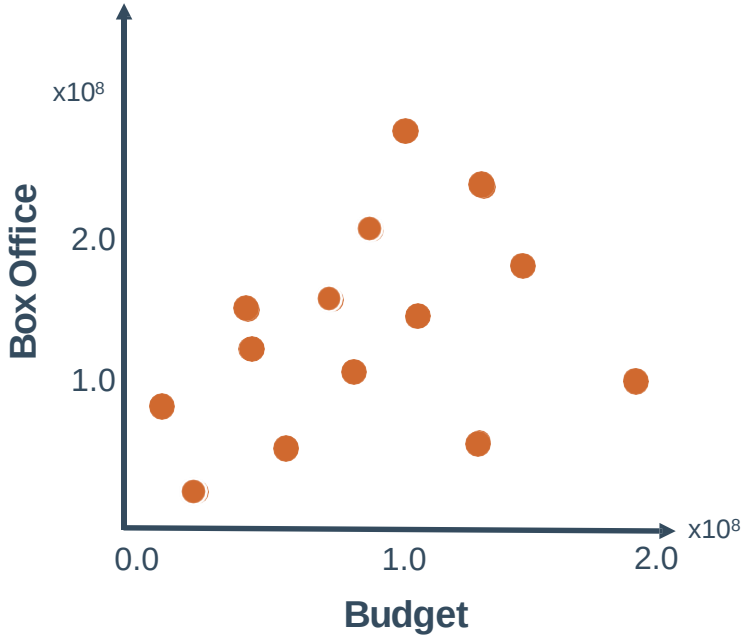

$$y_\beta(x) = \beta_0 + \beta_1 x$$

线性回归

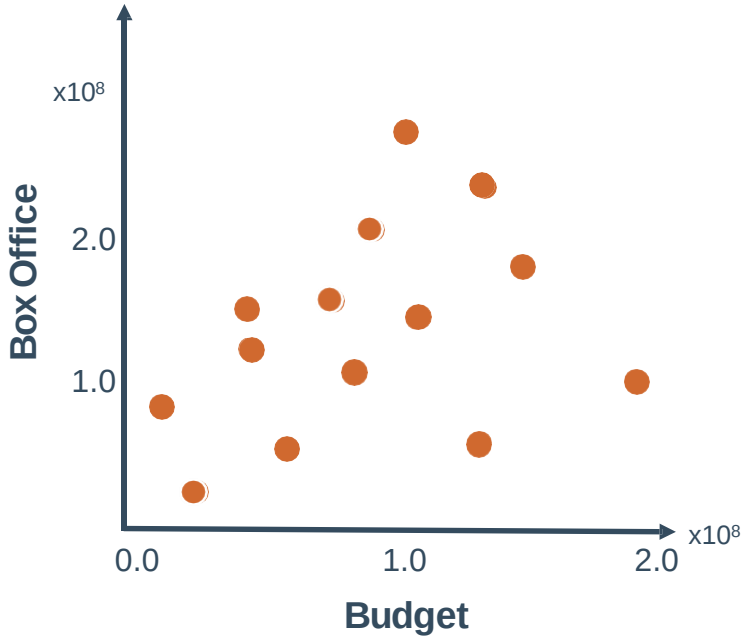

$$y_\beta(x) = \beta_0 + \beta_1 x$$

box office revenue

coefficient 0

coefficient 1

movie budget

线性回归

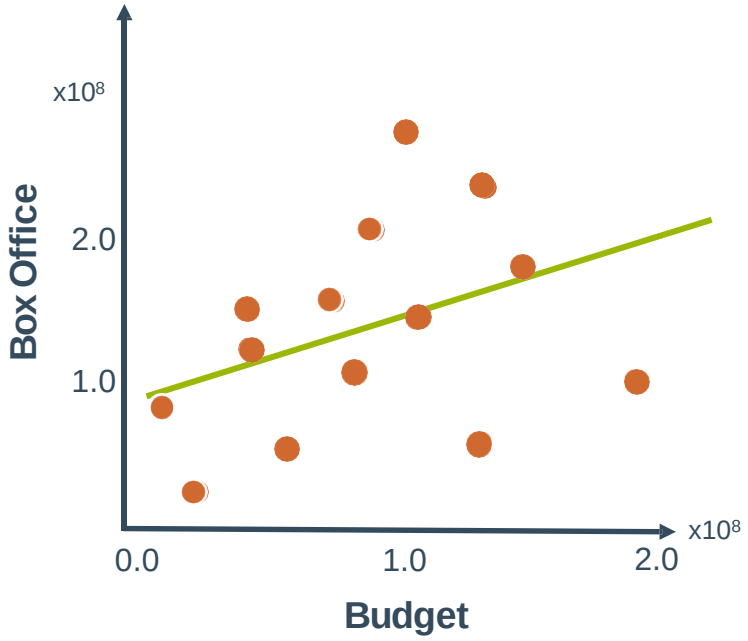

$$y_\beta(x) = \beta_0 + \beta_1 x$$

β_0= 80 million, β_1= 0.6

使用线性回归预测

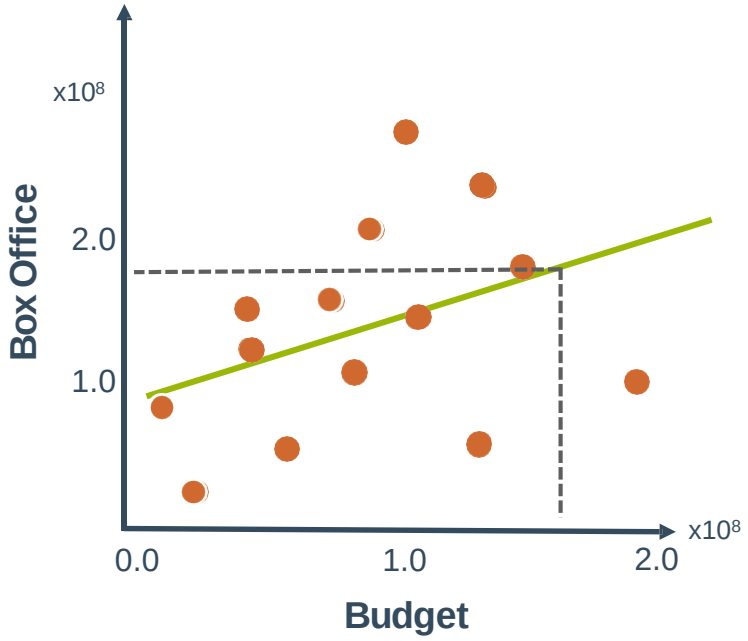

$$y_\beta(x) = \beta_0 + \beta_1 x$$

β_0= 80 million, β_1= 0.6

给定1.6亿的预算，预测票房收益为1.76亿

6.2 损失函数

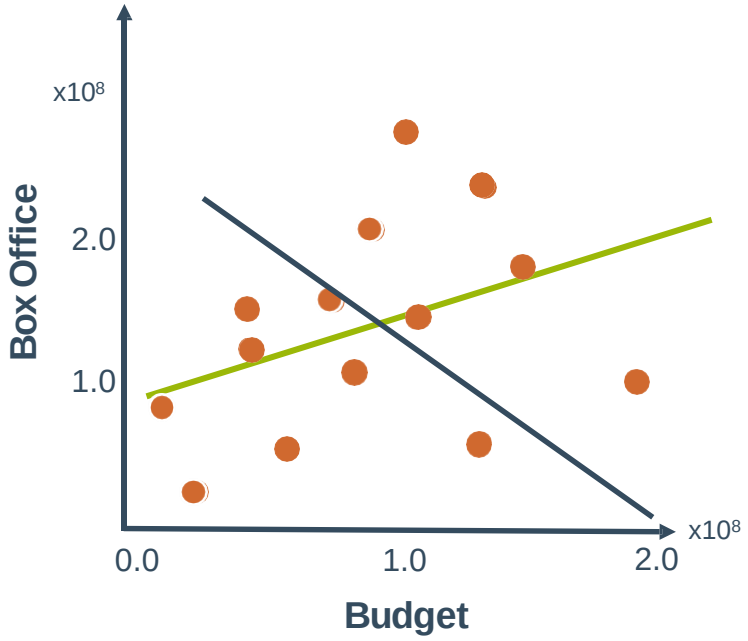

哪个模型拟合得更好？

计算残差

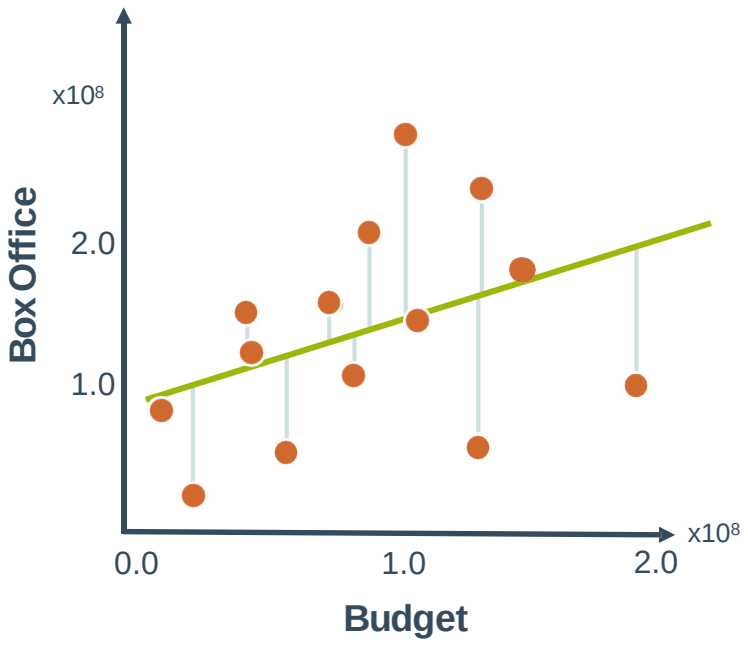

$$y_\beta\left(x_{obs}^{(i)}\right) - y_{obs}^{(i)}$$

Predicted value

Observed value

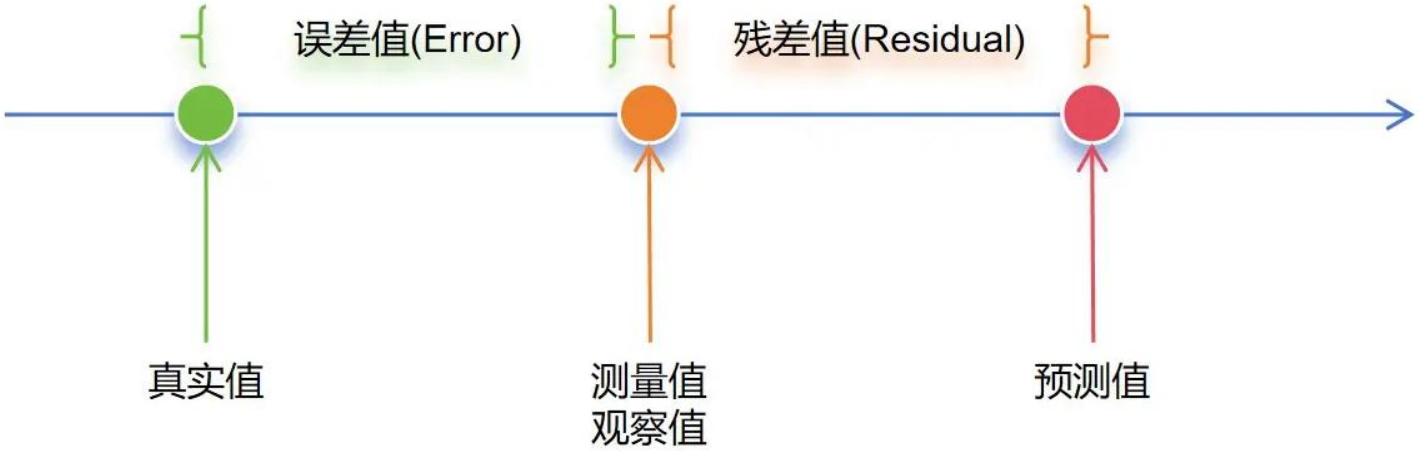

计算残差

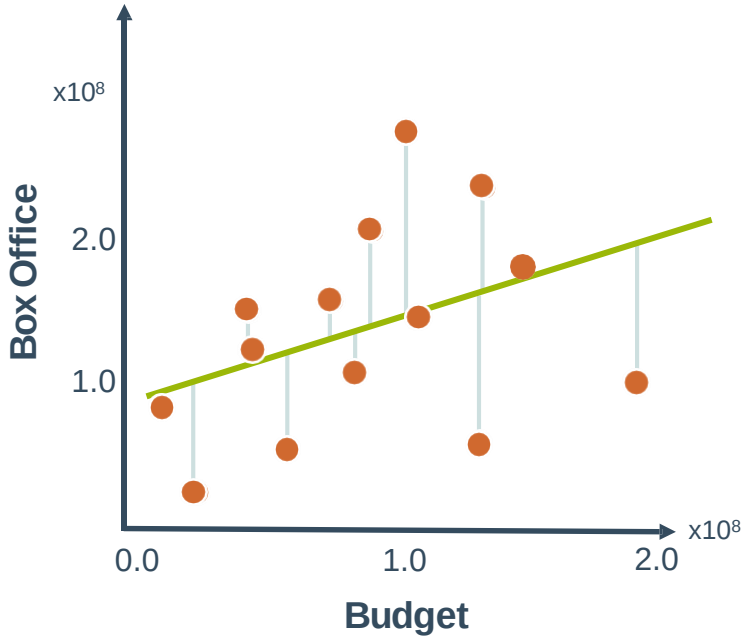

$$\left(\beta_0 + \beta_1 x_{obs}^{(i)}\right) - y_{obs}^{(i)}$$

均方误差（Mean Squared Error, MSE）

$$\frac{1}{m}\sum_{i=1}^{m}\left(\left(\beta_0+\beta_1 x_{obs}^{(i)}\right)-y_{obs}^{(i)}\right)^2$$

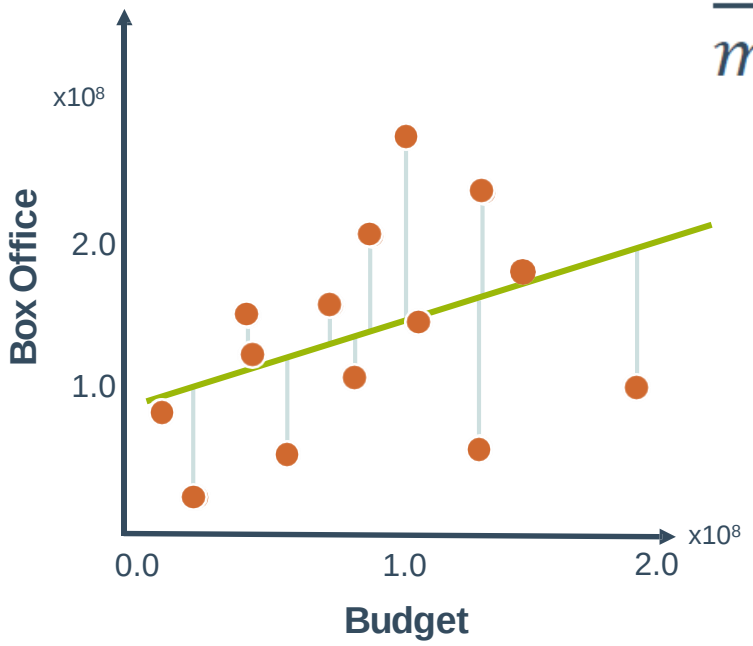

最小均方误差

$$\min_{\beta_0,\beta_1} \frac{1}{m}\sum_{i=1}^{m}\left(\left(\beta_0 + \beta_1 x_{obs}^{(i)}\right) - y_{obs}^{(i)}\right)^2$$

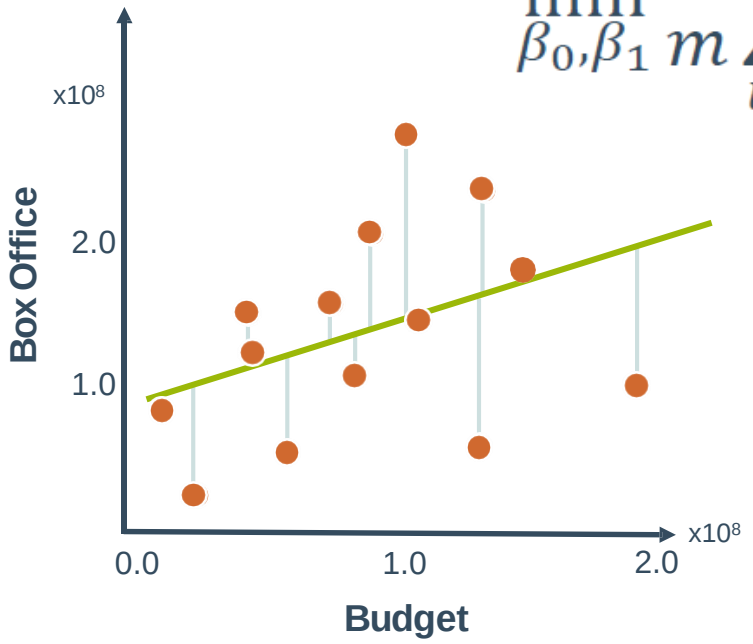

代价函数

$$J(\beta_0, \beta_1) = \frac{1}{2m}\sum_{i=1}^{m}\left(\left(\beta_0 + \beta_1 x_{obs}^{(i)}\right) - y_{obs}^{(i)}\right)^2$$

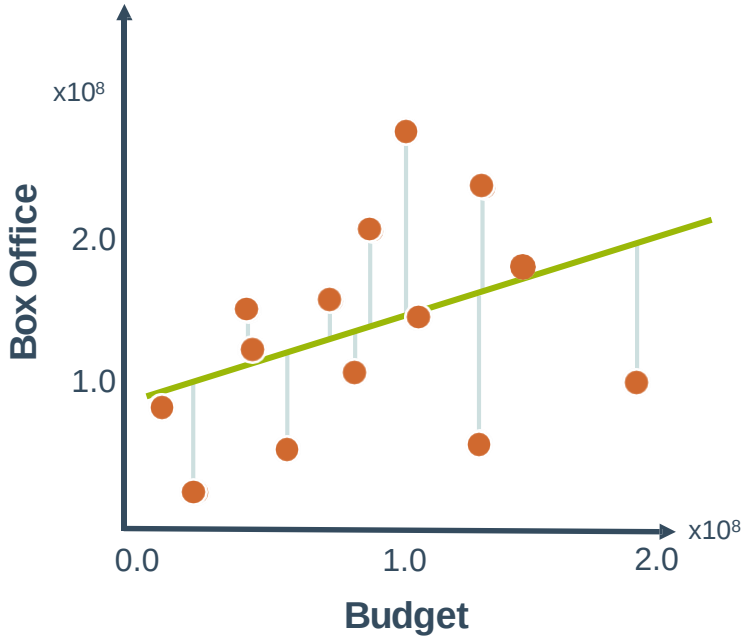

其他评价指标

平均绝对误差（Mean Absolute Error, MAE）：

$$\frac{1}{m}\sum_{i=1}^{m}\left|y_\beta\left(x^{(i)}\right)-y_{obs}^{(i)}\right|$$

均方误差（**Mean Squared Error, MSE**）

均方根误差（Root Mean Squared Error, RMSE）：

$$\sqrt{\frac{1}{m}\sum_{i=1}^{m}\left(y_\beta\left(x^{(i)}\right)-y_{obs}^{(i)}\right)^2}$$

$$\frac{1}{m}\sum_{i=1}^{m}\left(\left(\beta_0+\beta_1 x_{obs}^{(i)}\right)-y_{obs}^{(i)}\right)^2$$

MAE is the easiest to understand, because it's the average error.
MSE is more popular than MAE, because MSE "punishes" larger errors.
RMSE is even more popular than MSE, because RMSE is interpretable in the "y" units.

其他评价指标

残差平方和（SSE）：

$$\sum_{i=1}^{m}\left(y_\beta(x^{(i)})-y_{obs}^{(i)}\right)^2$$

总离差平方和（TSS）：

$$\sum_{i=1}^{m}\left(\overline{y_{obs}}-y_{obs}^{(i)}\right)^2$$

决定系数（R2）：

$$1-\frac{SSE}{TSS}$$

线性回归求解

单一属性的线性回归目标

$$f(x_i) = wx_i + b \text{ 使得 } f(x_i) \simeq y_i$$

$$(w^*, b^*) = \arg\min_{(w,b)} \sum_{i=1}^{m} (f(x_i) - y_i)^2$$

$$= \arg\min_{(w,b)} \sum_{i=1}^{m} (y_i - wx_i - b)^2$$

参数/模型估计：最小二乘法（least square method）

线性回归 – 最小二乘法

最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^{m} (y_i - wx_i - b)^2$$

分别对 w 和 b 求导，可得

$$\frac{\partial E_{(w,b)}}{\partial w} = 2\left(w\sum_{i=1}^{m} x_i^2 - \sum_{i=1}^{m}(y_i - b)\,x_i\right)$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2\left(mb - \sum_{i=1}^{m}(y_i - wx_i)\right)$$

线性回归 - 最小二乘法

得到闭式（closed-form）解

$$w = \frac{\sum_{i=1}^{m} y_i \left(x_i - \bar{x}\right)}{\sum_{i=1}^{m} x_i^2 - \frac{1}{m}\left(\sum_{i=1}^{m} x_i\right)^2}$$

$$b = \frac{1}{m}\sum_{i=1}^{m}\left(y_i - w x_i\right)$$

其中

$$\bar{x} = \frac{1}{m}\sum_{i=1}^{m} x_i$$

通用求解方法

$$\text{argmin}\ J(\beta_0, \beta_1) = \frac{1}{2m}\sum_{i=1}^{m}\left(\left(\beta_0 + \beta_1 x_{obs}^{(i)}\right) - y_{obs}^{(i)}\right)^2$$

导数

偏导数

方向导数

梯度

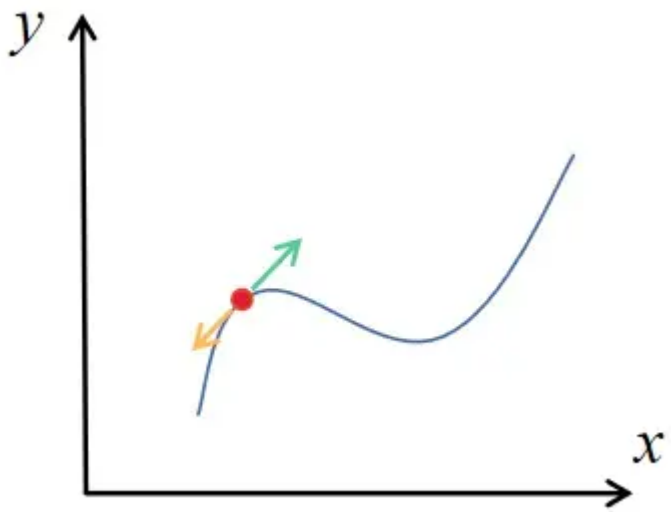

求解

$$J(\beta_0,\beta_1)=\frac{1}{2m}\sum_{i=1}^{m}\left(\left(\beta_0+\beta_1 x_{obs}^{(i)}\right)-y_{obs}^{(i)}\right)^2$$

梯度表示某一函数在该点处的方向导数沿着该方向取得最大值，即函数在该点处沿着该方向（此梯度的方向）变化最快，变化率最大（为该梯度的模）。

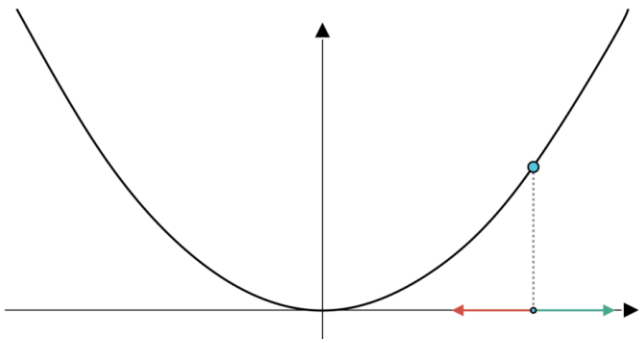

梯度下降法

$$x_1 = x_0 - \eta\nabla f(x_0)$$

$$x_2 = x_1 - \eta\nabla f(x_1)$$

$$x_3 = x_2 - \eta\nabla f(x_2)$$

$$x_4 = x_3 - \eta\nabla f(x_3)$$

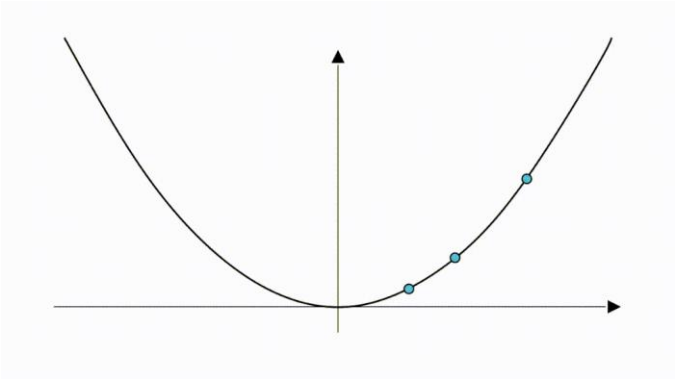

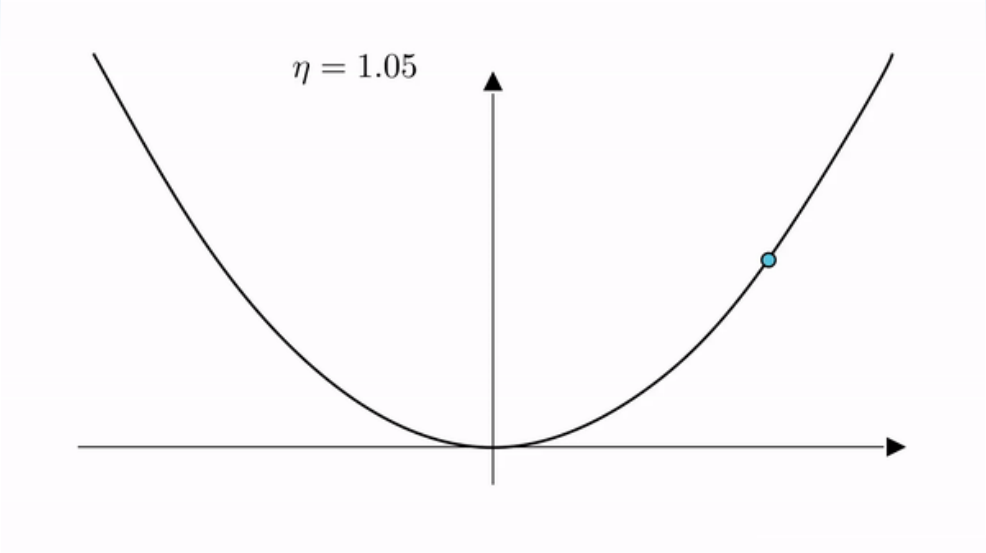
$\eta = 1.05$

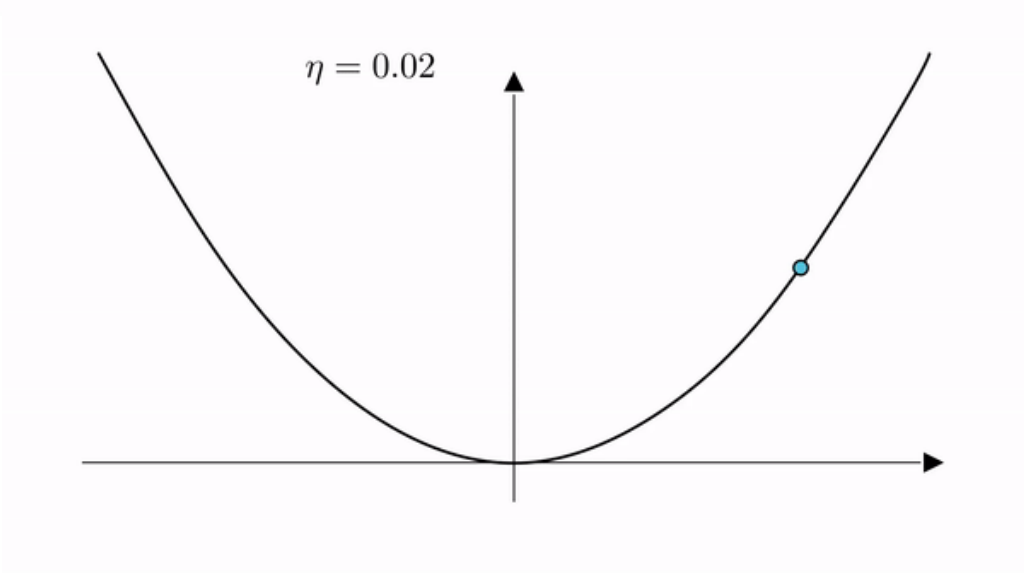
$\eta = 0.02$

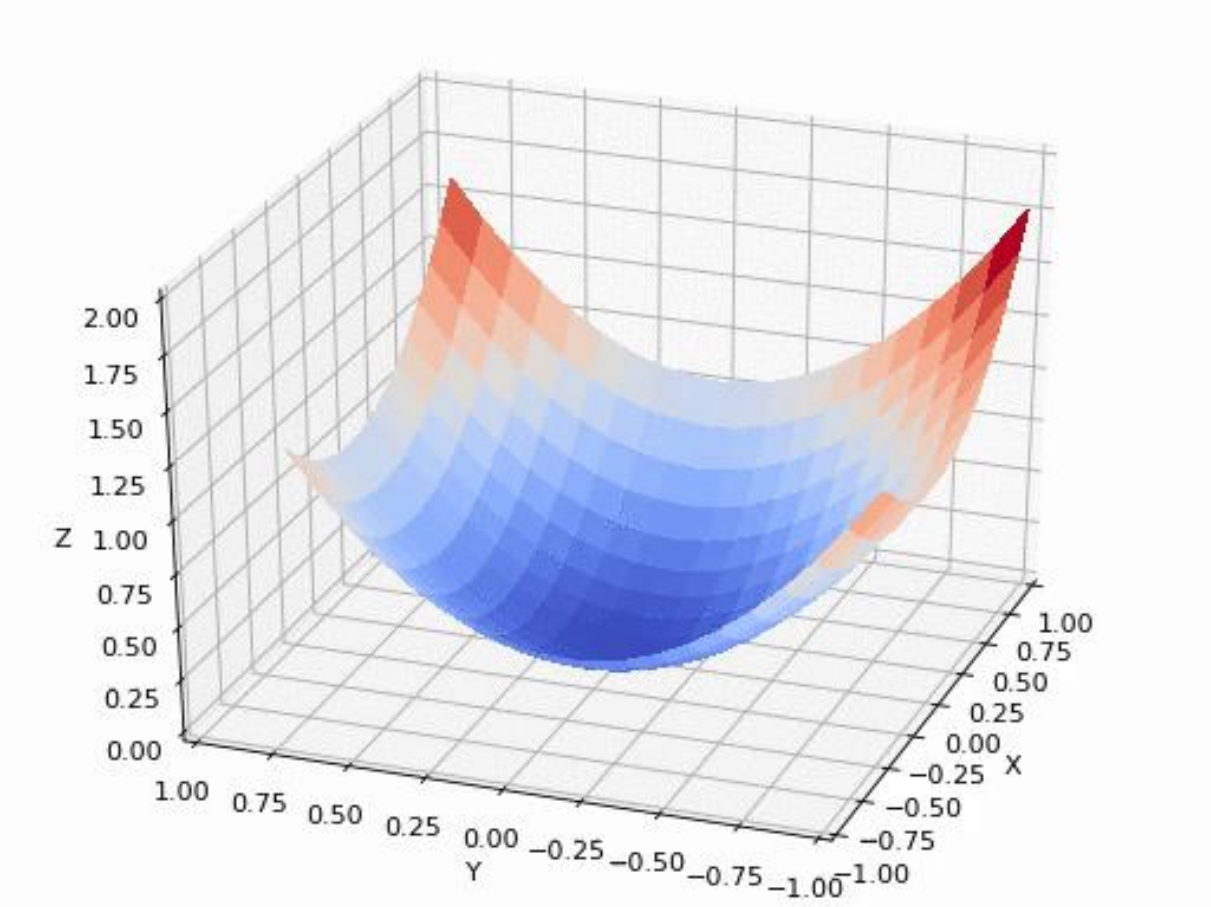
Z
2.00
1.75
1.50
1.25
1.00
0.75
0.50
0.25
0.00
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00
Y
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00
X

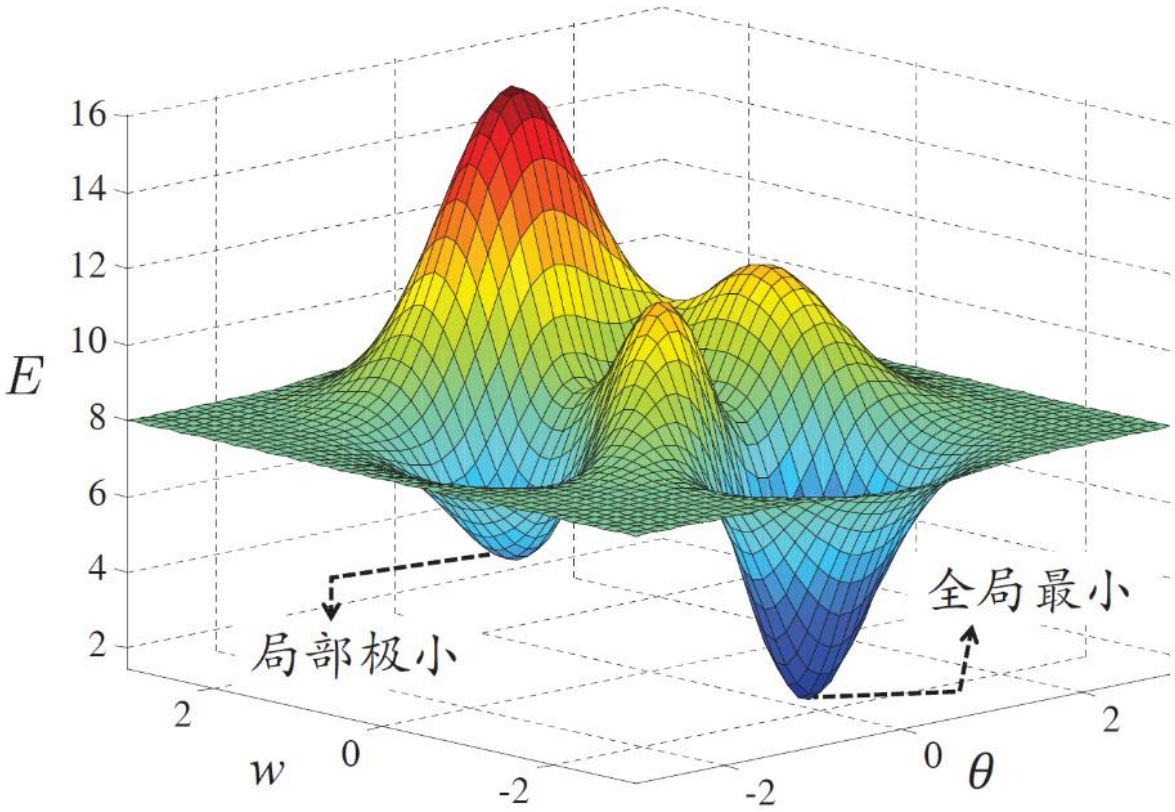
16
14
12
10
8
6
4
2
E
局部极小
全局最小
2
0
-2
w
-2
0
2
θ

线性回归的语法

导入包含回归方法的类：

```
from sklearn.linear_model import LinearRegression
```

创建该类的一个对象：

```
LR = LinearRegression()
```

训练模型拟合数据，并预测：

```
LR = LR.fit(X_train, y_train)
y_predict = LR.predict(X_test)
```

http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html

多元线性回归

考虑多个特征的线性组合

$$y_\beta(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots + \beta_n x_n$$

多元线性回归

给定数据集

$$D=\{(\boldsymbol{x}_1,y_1),(\boldsymbol{x}_2,y_2),\ldots,(\boldsymbol{x}_m,y_m)\}$$

$$\boldsymbol{x}_i=(x_{i1};x_{i2};\ldots;x_{id})\quad y_i\in\mathbb{R}$$

多元线性回归目标

$$f(\boldsymbol{x}_i)=\boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i+b\ \text{使得}\ f(\boldsymbol{x}_i)\simeq y_i$$

多元线性回归

把 $\boldsymbol{w}$ 和 b 吸收入向量形式 $\hat{\boldsymbol{w}} = (\boldsymbol{w}; b)$ ，数据集表示为

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \boldsymbol{x}_1^{\mathrm{T}} & 1 \\ \boldsymbol{x}_2^{\mathrm{T}} & 1 \\ \vdots & \vdots \\ \boldsymbol{x}_m^{\mathrm{T}} & 1 \end{pmatrix}$$

$$\boldsymbol{y} = (y_1; y_2; \ldots; y_m)$$

$$f(\boldsymbol{x}_i) = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x}_i + b \Longrightarrow f(\boldsymbol{x}_i) = \mathbf{X}\hat{\boldsymbol{w}}$$

多元线性回归 – 最小二乘法

最小二乘法（least square method）

$$\hat{\boldsymbol{w}}^* = \arg\min_{\hat{w}} \left(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}}\right)^{\mathrm{T}} \left(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}}\right)$$

令 $E_{\hat{\boldsymbol{w}}} = \left(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}}\right)^{\mathrm{T}} \left(\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}}\right)$ ，对$\hat{\boldsymbol{w}}$求导得到

$$\frac{\partial E_{\hat{\boldsymbol{w}}}}{\partial \hat{\boldsymbol{w}}} = 2\mathbf{X}^{\mathrm{T}} \left(\mathbf{X}\hat{\boldsymbol{w}} - \boldsymbol{y}\right)$$

令上式为零可得$\hat{\boldsymbol{w}}$最优解的闭式解

[推导]：将 $E_{\hat{w}} = (\boldsymbol{y} - \mathbf{X}\hat{w})^{\mathrm{T}}(\boldsymbol{y} - \mathbf{X}\hat{w})$ 展开可得

$$E_{\hat{w}} = \boldsymbol{y}^{\mathrm{T}}\boldsymbol{y} - \boldsymbol{y}^{\mathrm{T}}\mathbf{X}\hat{w} - \hat{w}^{\mathrm{T}}\mathbf{X}^{\mathrm{T}}\boldsymbol{y} + \hat{w}^{\mathrm{T}}\mathbf{X}^{\mathrm{T}}\mathbf{X}\hat{w}$$

对 $\hat{w}$ 求导可得

$$\frac{\partial E_{\hat{w}}}{\partial \hat{w}} = \frac{\partial \boldsymbol{y}^{\mathrm{T}}\boldsymbol{y}}{\partial \hat{w}} - \frac{\partial \boldsymbol{y}^{\mathrm{T}}\mathbf{X}\hat{w}}{\partial \hat{w}} - \frac{\partial \hat{w}^{\mathrm{T}}\mathbf{X}^{\mathrm{T}}\boldsymbol{y}}{\partial \hat{w}} + \frac{\partial \hat{w}^{\mathrm{T}}\mathbf{X}^{\mathrm{T}}\mathbf{X}\hat{w}}{\partial \hat{w}}$$

由矩阵微分公式 $\dfrac{\partial \boldsymbol{a}^{\mathrm{T}}\boldsymbol{x}}{\partial \boldsymbol{x}} = \dfrac{\partial \boldsymbol{x}^{\mathrm{T}}\boldsymbol{a}}{\partial \boldsymbol{x}} = \boldsymbol{a}, \dfrac{\partial \boldsymbol{x}^{\mathrm{T}}\mathbf{A}\boldsymbol{x}}{\partial \boldsymbol{x}} = (\mathbf{A} + \mathbf{A}^{\mathrm{T}})\boldsymbol{x}$ 可得

$$\frac{\partial E_{\hat{w}}}{\partial \hat{w}} = 0 - \mathbf{X}^{\mathrm{T}}\boldsymbol{y} - \mathbf{X}^{\mathrm{T}}\boldsymbol{y} + (\mathbf{X}^{\mathrm{T}}\mathbf{X} + \mathbf{X}^{\mathrm{T}}\mathbf{X})\hat{w}$$

$$\boxed{\frac{\partial E_{\hat{w}}}{\partial \hat{w}} = 2\mathbf{X}^{\mathrm{T}}(\mathbf{X}\hat{w} - \boldsymbol{y})}$$

$$(\boldsymbol{A}+\boldsymbol{B})^{\mathrm{T}} = \boldsymbol{A}^{\mathrm{T}} + \boldsymbol{B}^{\mathrm{T}}$$

$$(\boldsymbol{AB})^{\mathrm{T}} = \boldsymbol{B}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}$$

多元线性回归 – 满秩讨论

$$\frac{\partial E_{\hat{\boldsymbol{w}}}}{\partial \hat{\boldsymbol{w}}} = 2\mathbf{X}^{\mathrm{T}}(\mathbf{X}\hat{\boldsymbol{w}} - \boldsymbol{y})$$

$\mathbf{X}^{\mathrm{T}}\mathbf{X}$ 是满秩矩阵或正定矩阵，则

$$\hat{\boldsymbol{w}}^* = \left(\mathbf{X}^{\mathrm{T}}\mathbf{X}\right)^{-1}\mathbf{X}^{\mathrm{T}}\boldsymbol{y}$$

其中$\left(\mathbf{X}^{\mathrm{T}}\mathbf{X}\right)^{-1}$是 $\mathbf{X}^{\mathrm{T}}\mathbf{X}$ 的逆矩阵，线性回归模型为

$$f\left(\hat{\boldsymbol{x}}_i\right) = \hat{\boldsymbol{x}}_i^{\mathrm{T}}\left(\mathbf{X}^{\mathrm{T}}\mathbf{X}\right)^{-1}\mathbf{X}^{\mathrm{T}}\boldsymbol{y}$$

$\mathbf{X}^{\mathrm{T}}\mathbf{X}$不是满秩矩阵

- 根据归纳偏好选择解
- 引入正则化

6.3 广义线性回归

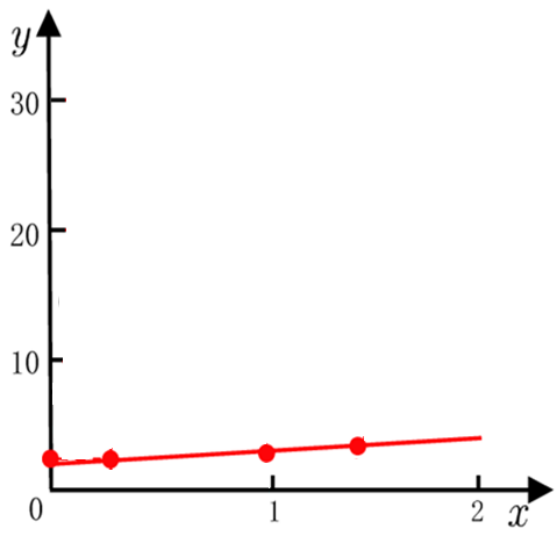

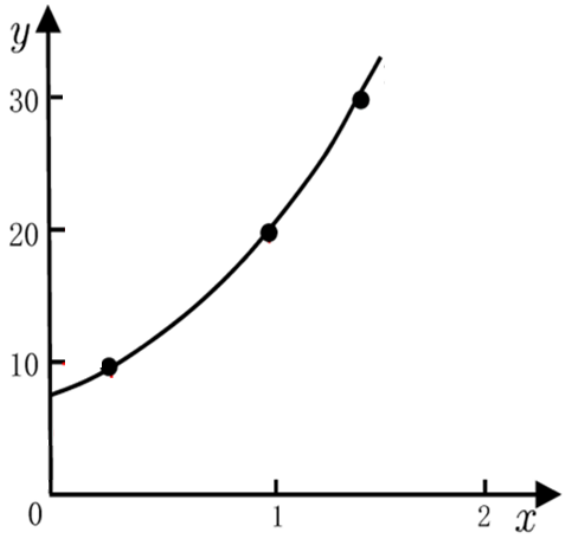

对数线性回归

输出标记的对数为线性模型逼近的目标

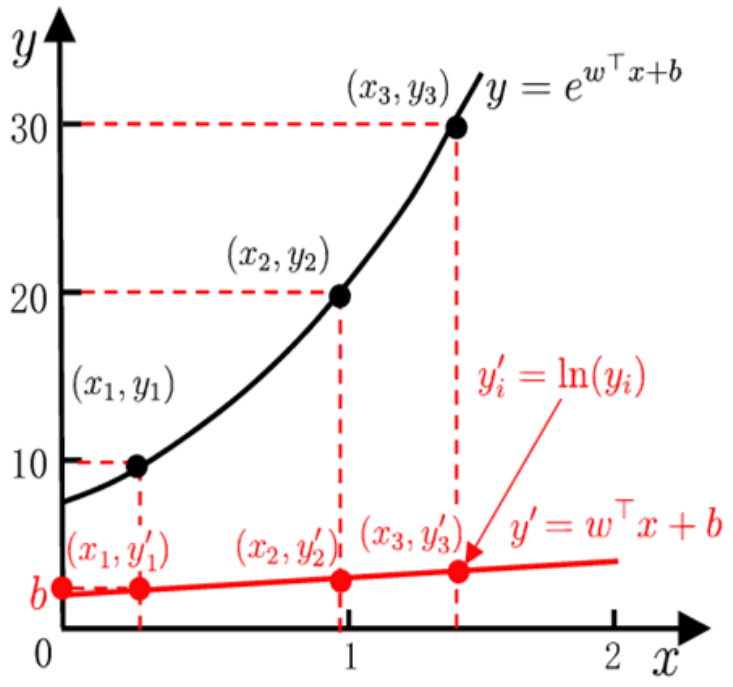

$$\ln y = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

$$\Updownarrow$$

$$y' = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b$$

增加多项式特征

- 通过增加多项式特征来捕捉更高阶的数据特征

$$y_\beta(x) = \beta_0 + \beta_1 x + \beta_2 x^2$$

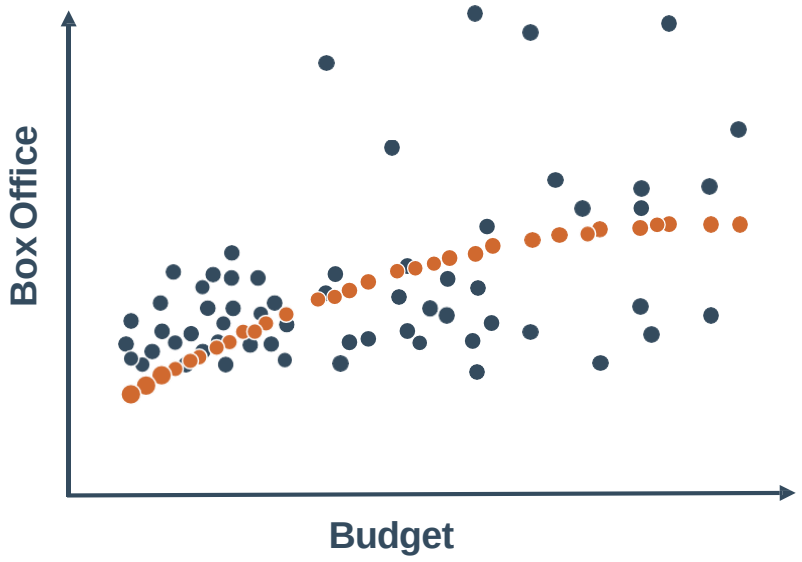

增加多项式特征

- 通过增加多项式特征来捕捉更高阶的数据特征
- “线性回归”意味着特征间的线性组合

$$y_\beta(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

增加多项式特征

- 通过增加多项式特征来捕捉更高阶的数据特征
- “线性回归”意味着特征间的线性组合

$$y_\beta(x) = \beta_0 + \beta_1 \log(x)$$

增加多项式特征

- 可以选择变量间的交互项： $y_\beta(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2$

增加多项式特征

- 可以选择变量间的交互项： $y_\beta(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2$

- 如何选择正确的函数形式：➡检查每个变量与结果之间的关系

生成多项式特征的语法

导入包含转换方法的类：

```
from sklearn.preprocessing import PolynomialFeatures
```

创建该类的一个对象：

```
polyFeat = PolynomialFeatures(degree=2)
```

创建多项式特征，并转换数据：

```
polyFeat = polyFeat.fit(X_data)
x_poly = polyFeat.transform(X_data)
```

或者 `x_poly = polyFeat.fit_transform(X_data)`

http://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.PolynomialFeatures.html

6.4 正则化

模型复杂度与误差

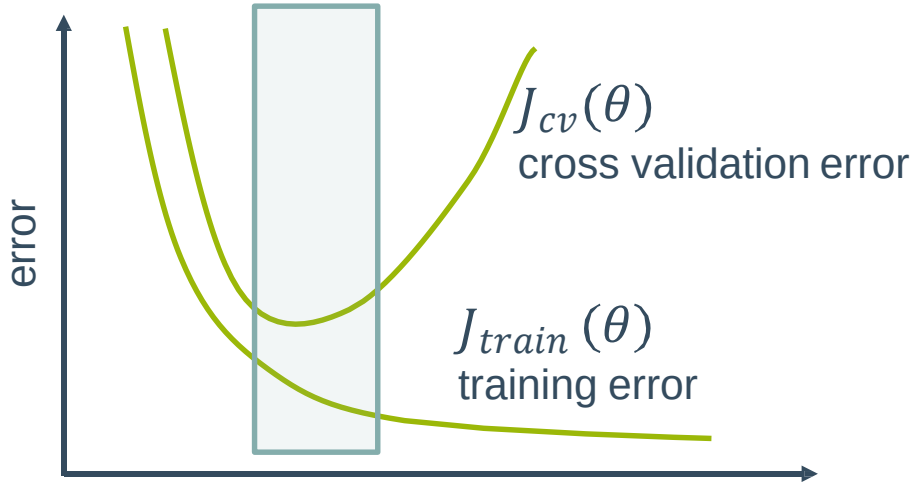

防止欠拟合与过拟合

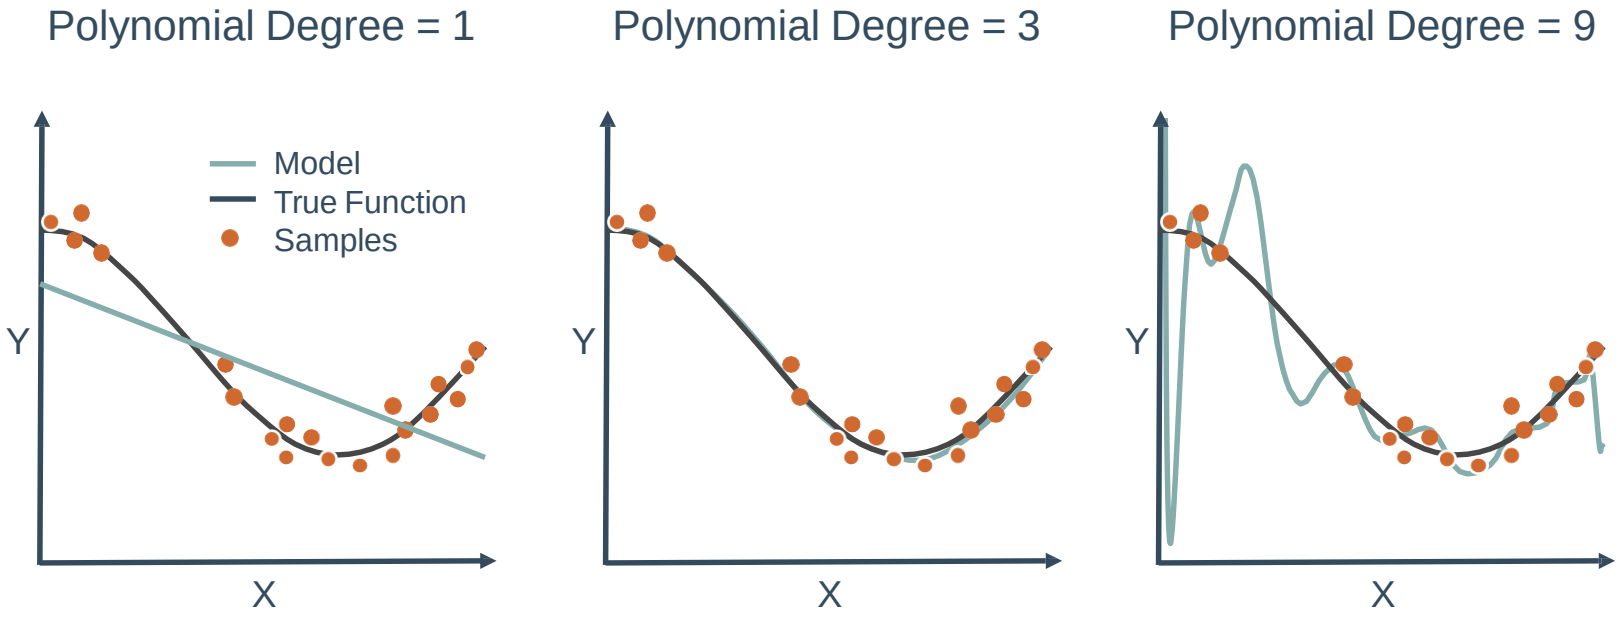

如何用一个9次多项式拟合数据，并防止过拟合？

防止欠拟合与过拟合

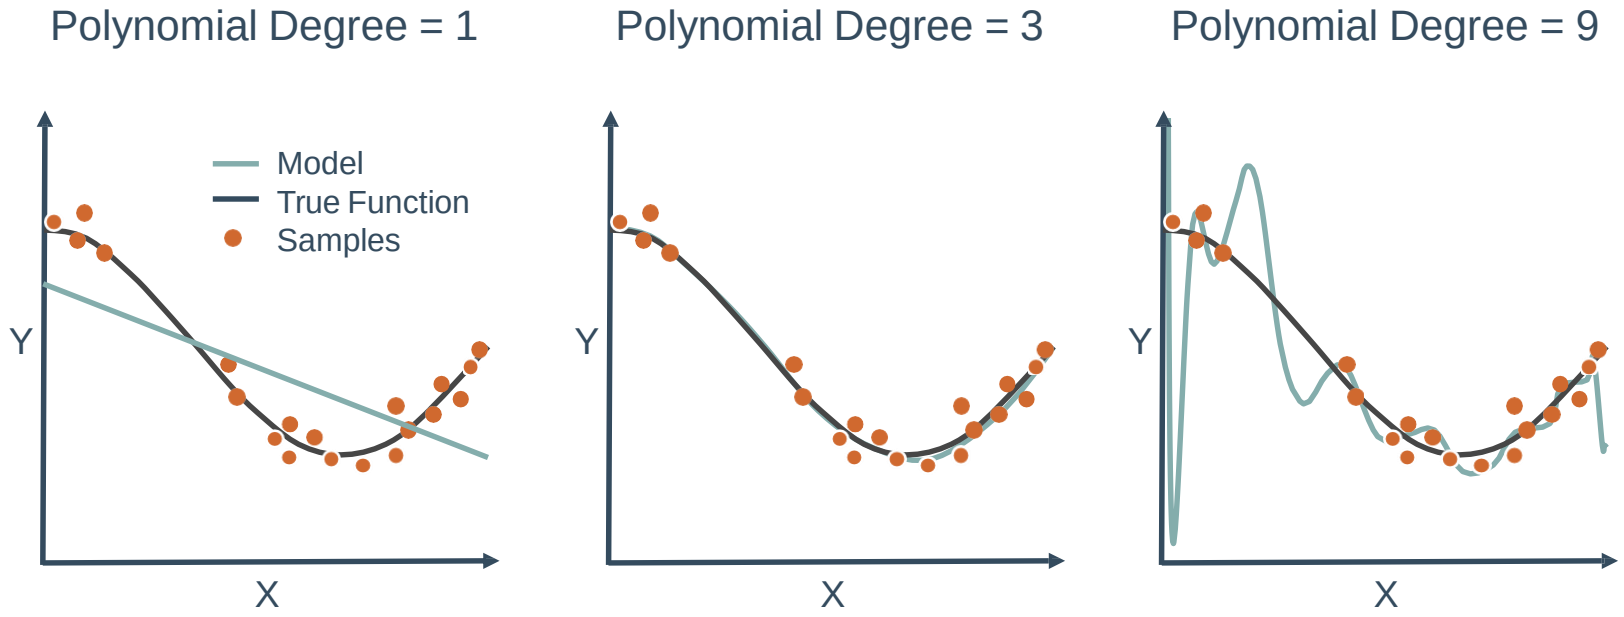

$$J(\beta) = \frac{1}{2m}\sum_{i=1}^{m}\left(y_\beta\left(x^{(i)}\right) - y^{(i)}\right)^2$$

正则化（regularization）

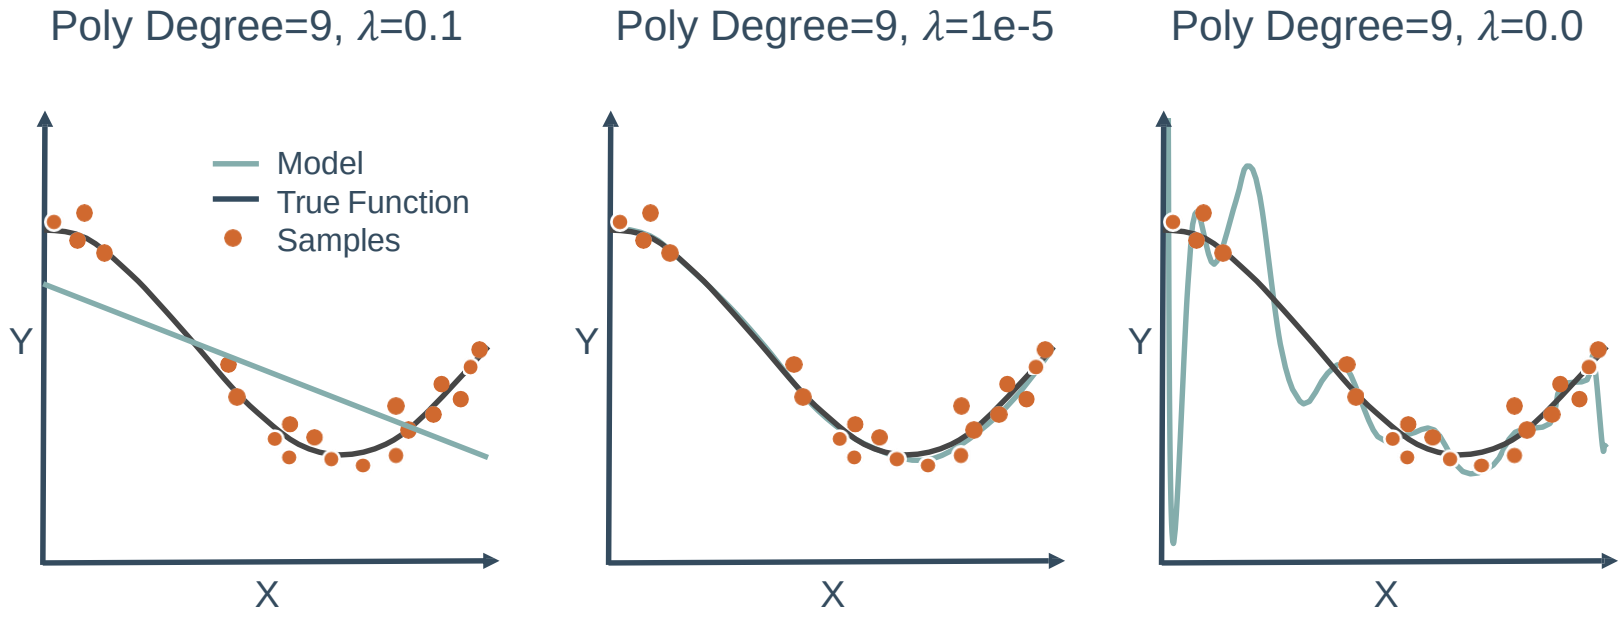

$$J(\beta) = \frac{1}{2m}\sum_{i=1}^{m}\left(y_\beta\left(x^{(i)}\right) - y^{(i)}\right)^2 + \lambda\sum_{j=1}^{n}\beta_j^2$$

岭回归（Ridge Regression）(L2)

$$J(\beta) = \frac{1}{2m}\sum_{i=1}^{m}\left(y_\beta\left(x^{(i)}\right) - y^{(i)}\right)^2 + \lambda\sum_{j=1}^{n}\beta_j^2$$

- 惩罚项收缩了所有系数的大小
- 越大的系数被惩罚得越多，因为惩罚的是平方

岭回归对模型参数的效果

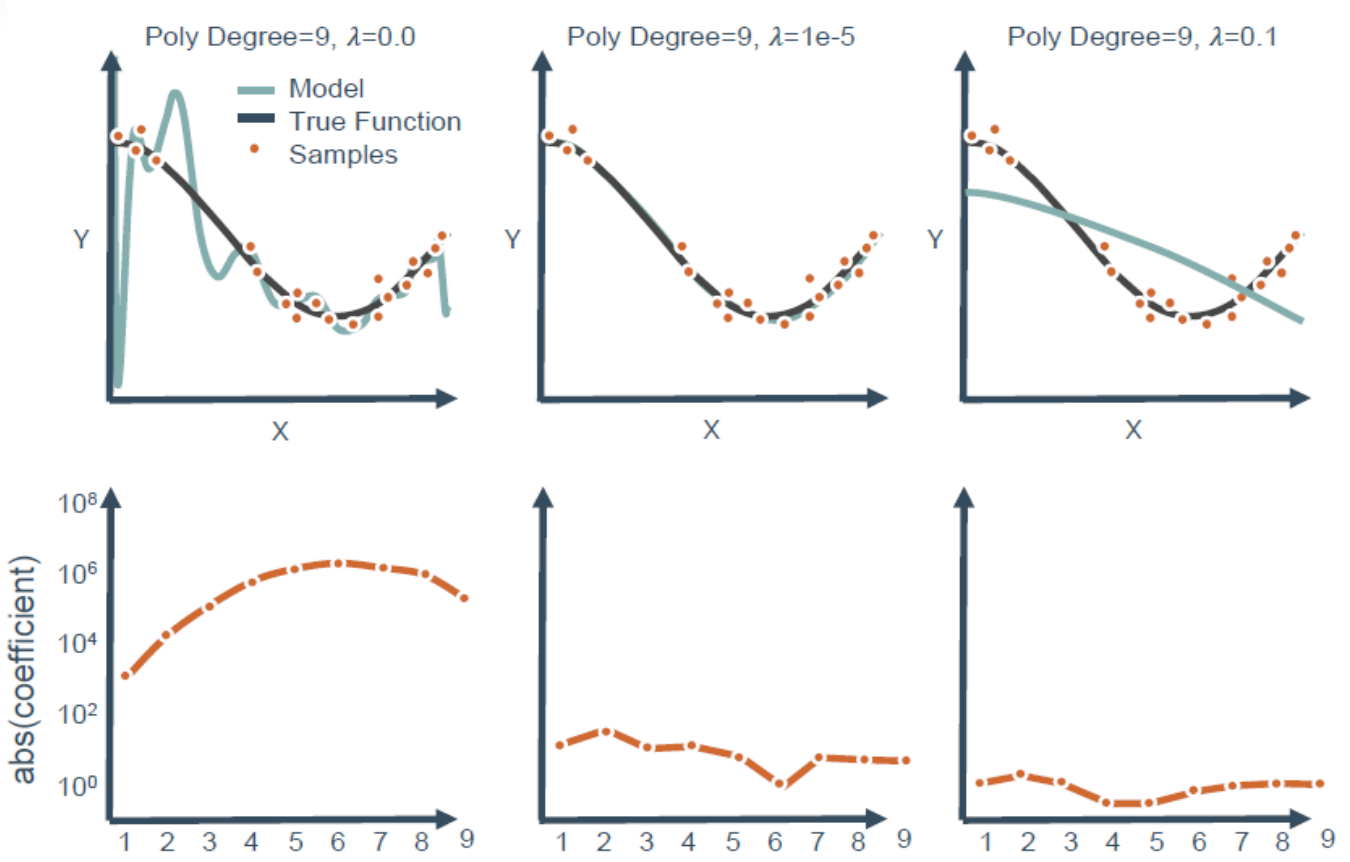

$$J(\beta) = \frac{1}{2m}\sum_{i=1}^{m}\left(y_\beta\left(x^{(i)}\right) - y^{(i)}\right)^2 + \lambda\sum_{j=1}^{n}\beta_j^2$$

套索回归（Lasso Regression）(L1)

$$J(\beta) = \frac{1}{2m}\sum_{i=1}^{m}\left(y_\beta\left(x^{(i)}\right) - y^{(i)}\right)^2 + \lambda\sum_{j=1}^{n}|\beta_j|$$

- 惩罚项有选择地收缩了某些系数
- 可以被用来做特征选择
- 比岭回归收敛速度慢

套索回归对模型参数的效果

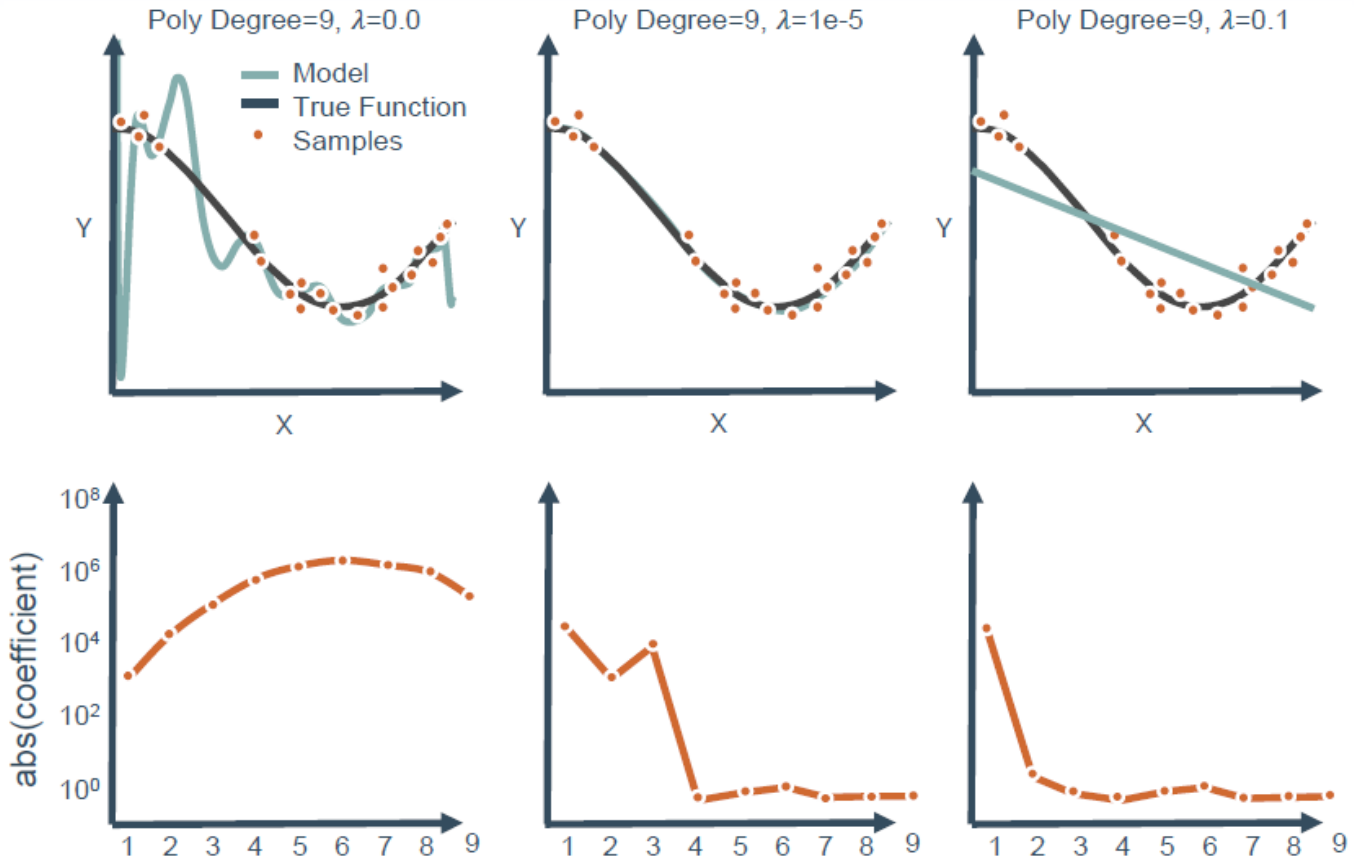

$$J(\beta) = \frac{1}{2m}\sum_{i=1}^{m}\left(y_\beta\left(x^{(i)}\right) - y^{(i)}\right)^2 + \lambda\sum_{j=1}^{n}|\beta_j|$$

范数

衡量向量大小的函数，norm

$$\|\boldsymbol{x}\|_p = \left(\sum_i |x_i|^p\right)^{\frac{1}{p}}$$

$$\|\boldsymbol{x}\|_1 = \sum_i |x_i|.$$

L1与L2正则化

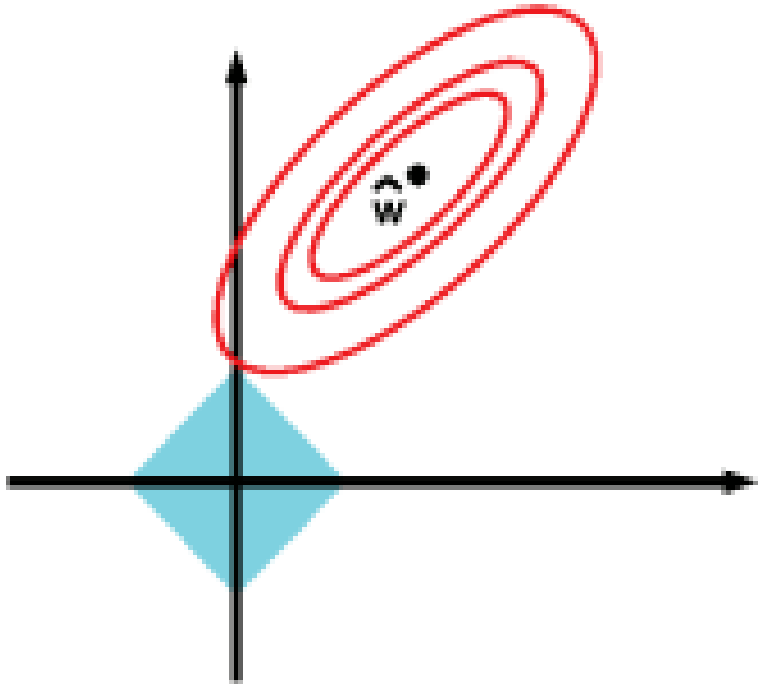

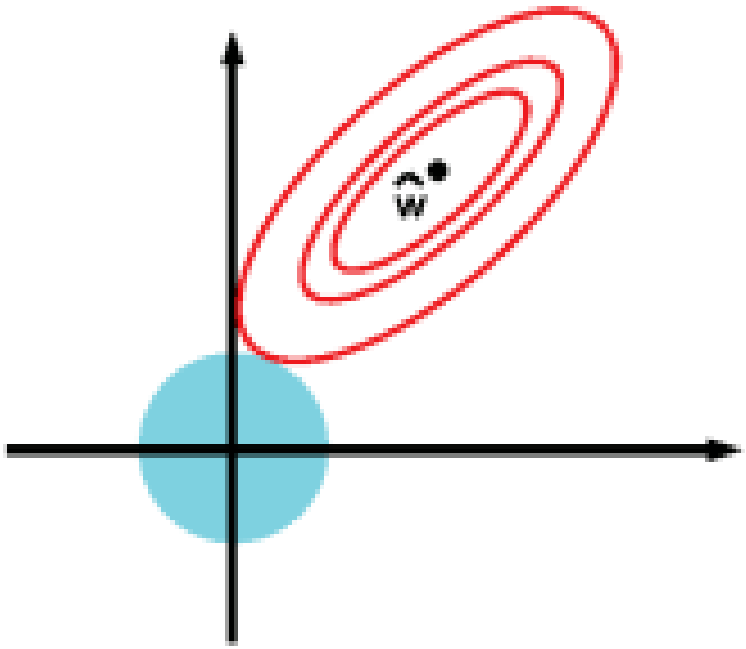

ElasticNet正则化

$$J(\beta)=\frac{1}{2m}\sum_{i=1}^{m}\left(y_{\beta}\left(x^{(i)}\right)-y^{(i)}\right)^{2}+\lambda_{1}\sum_{j=1}^{n}|\beta_{j}|+\lambda_{2}\sum_{j=1}^{n}\beta_{j}^{2}$$

- 岭回归和套索回归的综合，用以平衡稀疏和平滑两个问题
- 需要调节额外的参数，来分配L1和L2正则化惩罚项的比例

6.5 超参数调优

- 正则化系数（λ_1 和λ_2）是根据经验决定的

使用测试数据调节 λ?

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity			Cuaron	PG-13	91
6	2013-06-21	Monsters University			nlon	G	107
7	2013-12-13	The Hobbit: The Deso			ckson	PG-13	161
8	2013-05-24	Fast & Furious 6			n	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods			MiccoChris Sanders	PG	98
14	2013-06-28	The Heat			g	R	117
15	2013-08-07	We're the Millers			Marshall Thurber	R	110
16	2013-12-13	American Hustle			Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

训练数据

测试数据

超参数及其优化

- 正则化系数（λ_1 和λ_2）是根据经验决定的
- 想让模型泛化---不要使用测试数据集来调节λ_1 和λ_2

使用测试数据集调节 λ?

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3			Shane Black	PG-13	129
2	2013-11-22	Frozen			hris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2			CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel			er	PG-13	143
5	2013-10-04	Gravity			n	PG-13	91
6	2013-06-21	Monsters Univer				G	107
7	2013-12-13	The Hobbit: The				PG-13	161
8	2013-05-24	Fast & Furious 6				PG-13	130
9	2013-03-08	Oz The Great an				PG	127
10	2013-05-16	Star Trek Into Da				PG-13	123
11	2013-11-08	Thor: The Dark V				PG-13	120
12	2013-06-21	World War Z			er	PG-13	116
13	2013-03-22	The Croods			MiccoChris Sanders	PG	98
14	2013-06-28	The Heat			g	R	117
15	2013-08-07	We're the Millers			Marshall Thurber	R	110
16	2013-12-13	American Hustle			. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

超参数及其优化

- 正则化系数（λ_1 和λ_2）是根据经验决定的
- 想让模型泛化---不要使用测试数据集来调节λ_1 和λ_2
- 划分出另一个数据集来调节超参数---验证集（validation set）

用交叉验证来调节λ

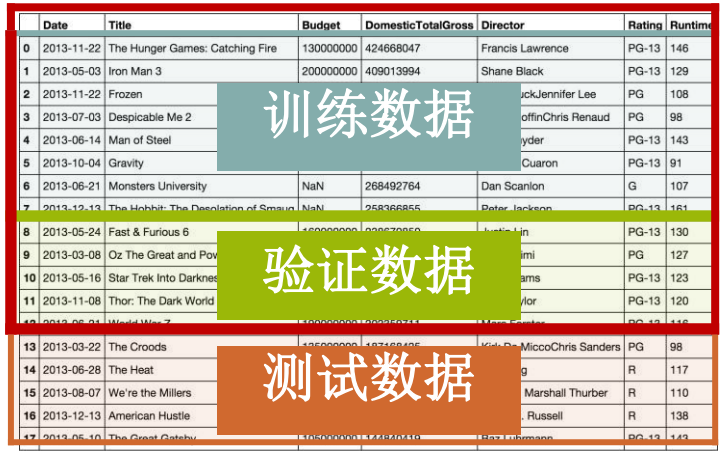

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen			uckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2			offinChris Renaud	PG	98
4	2013-06-14	Man of Steel			yder	PG-13	143
5	2013-10-04	Gravity			Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
8	2013-05-24	Fast & Furious 6				PG-13	130
9	2013-03-08	Oz The Great and Pov			mi	PG	127
10	2013-05-16	Star Trek Into Darknes			ams	PG-13	123
11	2013-11-08	Thor: The Dark World			lor	PG-13	120
13	2013-03-22	The Croods			MiccoChris Sanders	PG	98
14	2013-06-28	The Heat			g	R	117
15	2013-08-07	We're the Millers			Marshall Thurber	R	110
16	2013-12-13	American Hustle			Russell	R	138

交叉验证

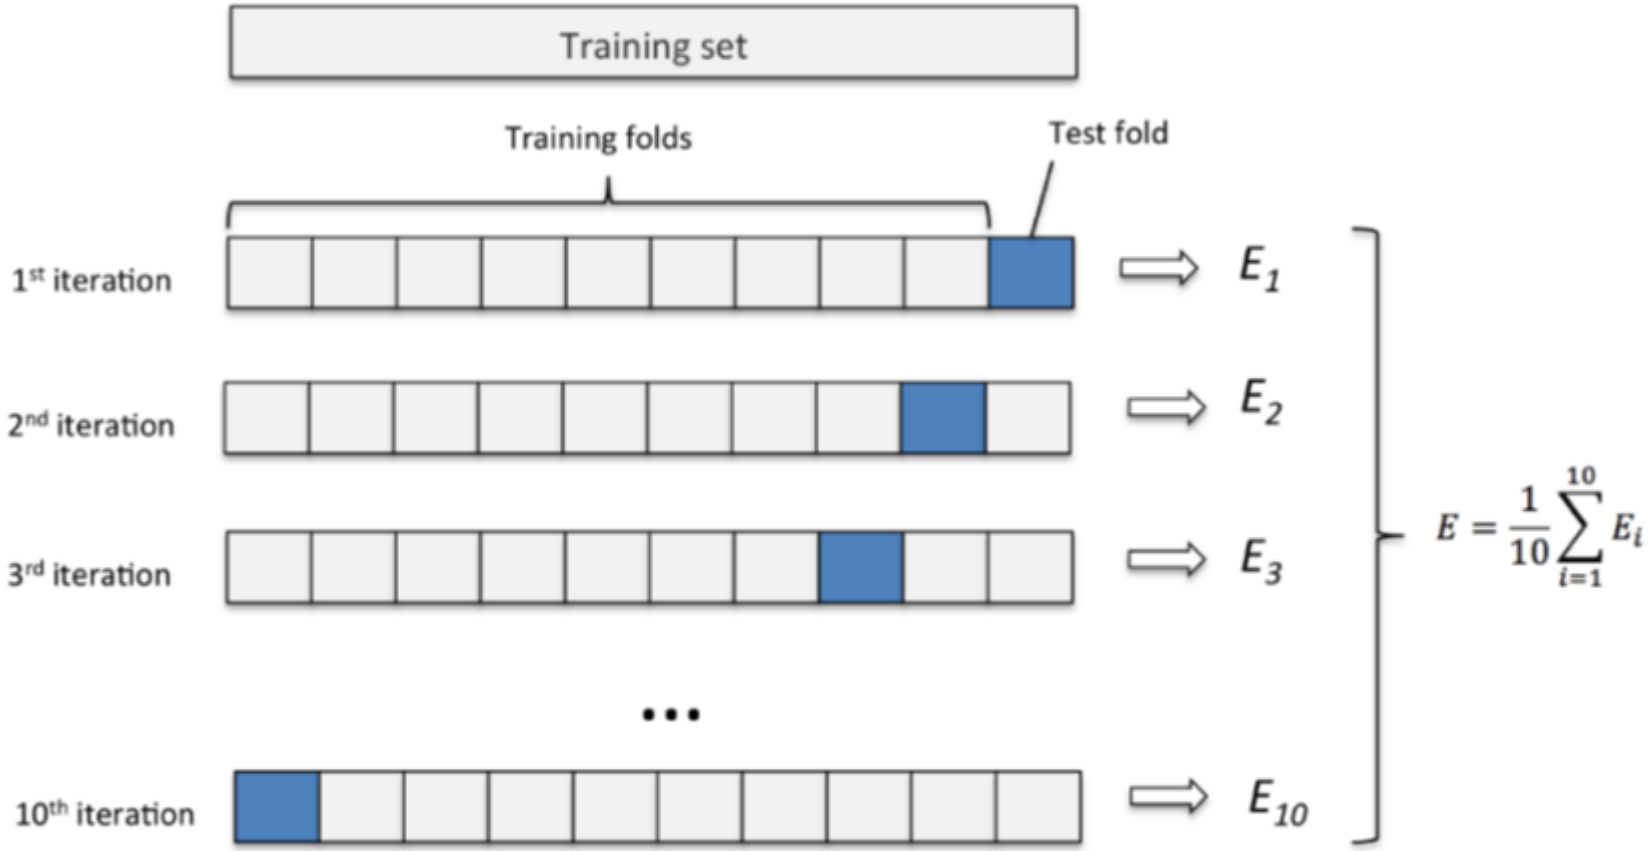
Training set
Training folds
Test fold
1st iteration
2nd iteration
3rd iteration
10th iteration
E_1
E_2
E_3
E_{10}
$E = \frac{1}{10}\sum_{i=1}^{10} E_i$

岭回归的语法

导入包含回归方法的类：

```
from sklearn.linear_model import Ridge
```

创建该类的一个对象：

```
RR = Ridge(alpha=1.0)
```

拟合训练数据，并在测试数据上预测：

```
RR = RR.fit(X_train, y_train)
y_predict = RR.predict(X_test)
```

岭回归的语法

导入包含回归方法的类：

```
from sklearn.linear_model import Ridge
```

创建该类的一个对象：

```
RR = Ridge(alpha=1.0)
```

正则化参数

拟合训练数据，并在测试数据上预测：

```
RR = RR.fit(X_train, y_train)

y_predict = RR.predict(X_test)
```

http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html

岭回归的语法

导入包含回归方法的类：

```
from sklearn.linear_model import RidgeCV
```

创建该类的一个对象：

```
RRcv = RidgeCV(alphas=[1e-3, 1e-2, 1e-1, 1], cv=4)
```

拟合训练数据，并在测试数据上预测：

```
RRcv = RRcv.fit(X_train, y_train)
y_predict = RRcv.predict(X_test)
```

RidgeCV 使用交叉验证自动确定alpha的值

http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.RidgeCV.html

套索回归的语法

导入包含回归方法的类：

```
from sklearn.linear_model import Lasso
```

创建该类的一个对象：

```
LR = Lasso(alpha=1.0)
```

正则化参数

拟合训练数据，并在测试数据上预测：

```
LR = LR.fit(X_train, y_train)

y_predict = LR.predict(X_test)
```

http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Lasso.html

套索回归的语法

导入包含回归方法的类：

```
from sklearn.linear_model import LassoCV
```

创建该类的一个对象：

```
LRcv = LassoCV(alphas=[1e-3, 1e-2, 1e-1, 1], cv=4)
```

拟合训练数据，并在测试数据上预测：

```
LRcv = LRcv.fit(X_train, y_train)
y_predict = LRcv.predict(X_test)
```

LassoCV 使用交叉验证自动确定alpha的值

http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LassoCV.html

ElasticNet回归的语法

导入包含回归方法的类：

```
from sklearn.linear_model import ElasticNet
```

创建该类的一个对象：

```
EN = ElasticNet(alpha=1.0, l1_ratio=0.5)
```

l1_ratio把alpha的值分配给L1/L2

拟合训练数据，并在测试数据上预测：

```
EN = EN.fit(X_train, y_train)

y_predict = EN.predict(X_test)
```

http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.ElasticNet.html

ElasticNet回归的语法

导入包含回归方法的类：

```
from sklearn.linear_model import ElasticNetCV
```

创建该类的一个对象：

```
ENcv = ElasticNetCV(alphas=[1e-3, 1e-2, 1e-1, 1], cv=5)
```

拟合训练数据，并在测试数据上预测：

```
ENcv = ENcv.fit(X_train, y_train)

y_predict = ENcv.predict(X_test)
```

ElasticNetCV 使用交叉验证自动确定alpha和l1_ratio的值

http://scikit-learn.org/stable/modules/generated/sklearn.linear_model.ElasticNetCV.html

6.6 波士顿房价预测

该数据集包含美国马萨诸塞州波士顿住房价格的有关信息，只有506个样例。

- CRIM--城镇人均犯罪率 ------【城镇人均犯罪率】
- ZN - 占地面积超过25,000平方英尺的住宅用地比例。 ------【住宅用地所占比例】
- INDUS - 每个城镇非零售业务的比例。 ------【城镇中非商业用地占比例】
- CHAS - Charles River虚拟变量（如果是河道，则为1;否则为0 ------【查尔斯河虚拟变量，用于回归分析】
- NOX - 一氧化氮浓度（每千万份） ------【环保指标】
- RM - 每间住宅的平均房间数 ------【每栋住宅房间数】
- AGE - 1940年以前建造的自住单位比例 ------【1940年以前建造的自住单位比例 】
- DIS -波士顿的五个就业中心加权距离 ------【与波士顿的五个就业中心加权距离】
- RAD - 径向高速公路的可达性指数 ------【距离高速公路的便利指数】
- TAX - 每10,000美元的全额物业税率 ------【每一万美元的不动产税率】
- PTRATIO - 城镇的学生与教师比例 ------【城镇中教师学生比例】
- B - 1000（Bk - 0.63）^ 2其中Bk是城镇黑人的比例 ------【城镇中黑人比例】
- LSTAT - 人口状况下降% ------【房东属于低等收入阶层比例】
- MEDV - 自有住房的中位数报价, 单位1000美元 ------【自住房屋房价中位数】