第7章 逻辑回归

癌症病人治疗5年之后的状况

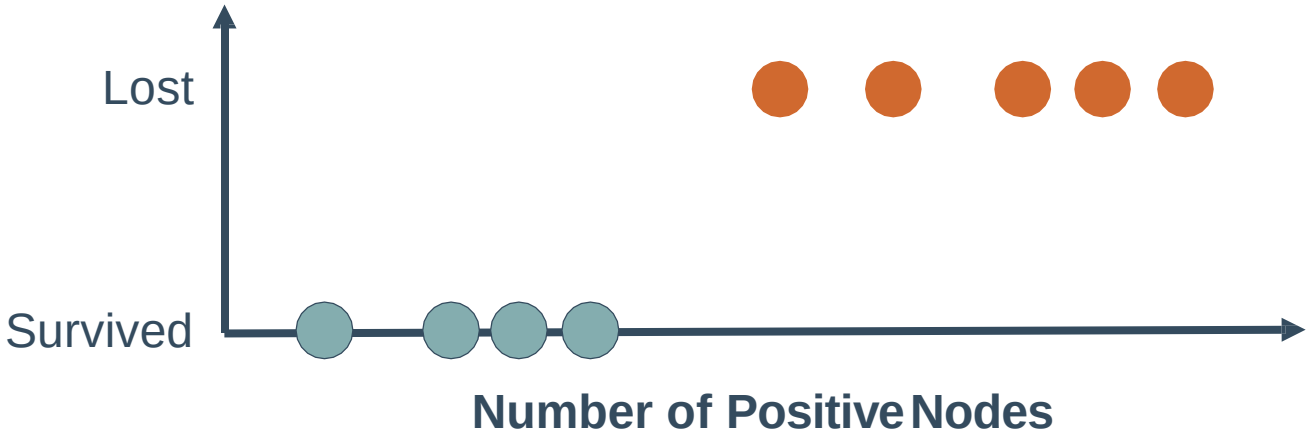

线性回归做分类？

癌症病人治疗5年之后的状况

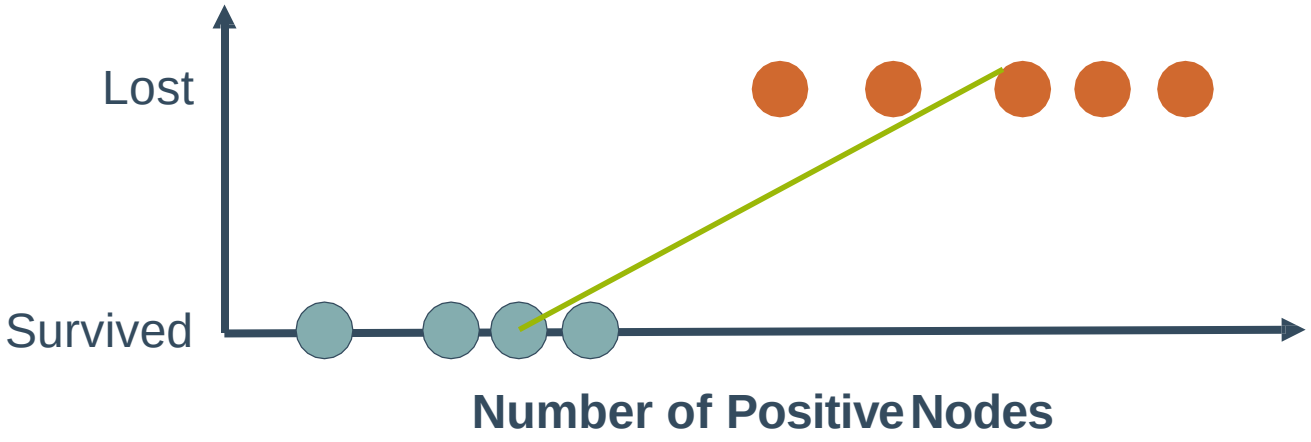

$$y_\beta(x) = \beta_0 + \beta_1 x$$

线性回归做分类？

癌症病人治疗5年之后的状况

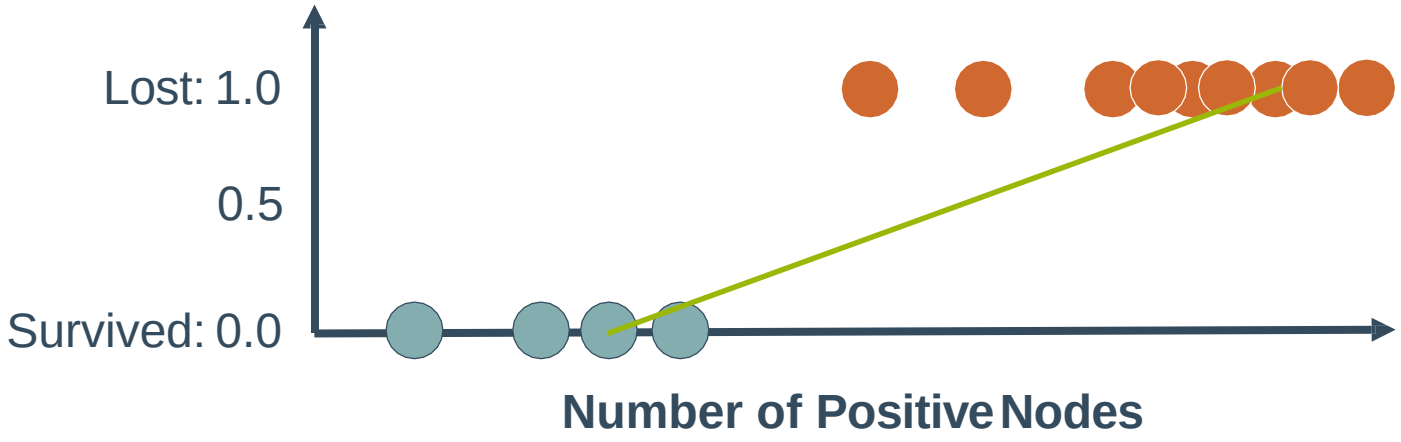

$$y_\beta(x) = \beta_0 + \beta_1 x$$

线性回归做分类？

癌症病人治疗5年之后的状况

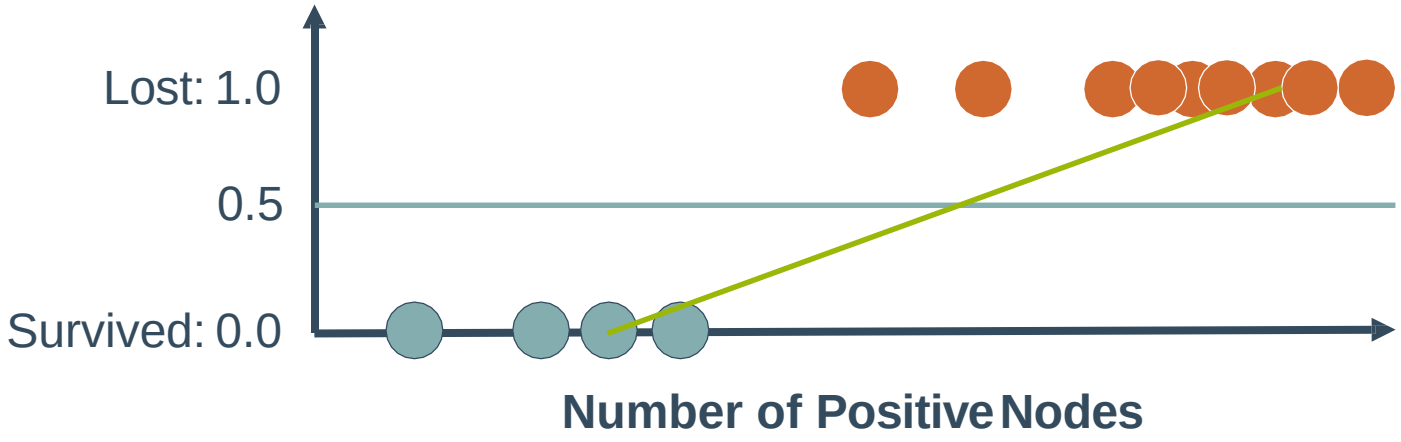

如果模型输出结果 > 0.5：预测 lost
如果模型输出结果 < 0.5：预测 survived

线性回归做分类？

癌症病人治疗5年之后的状况

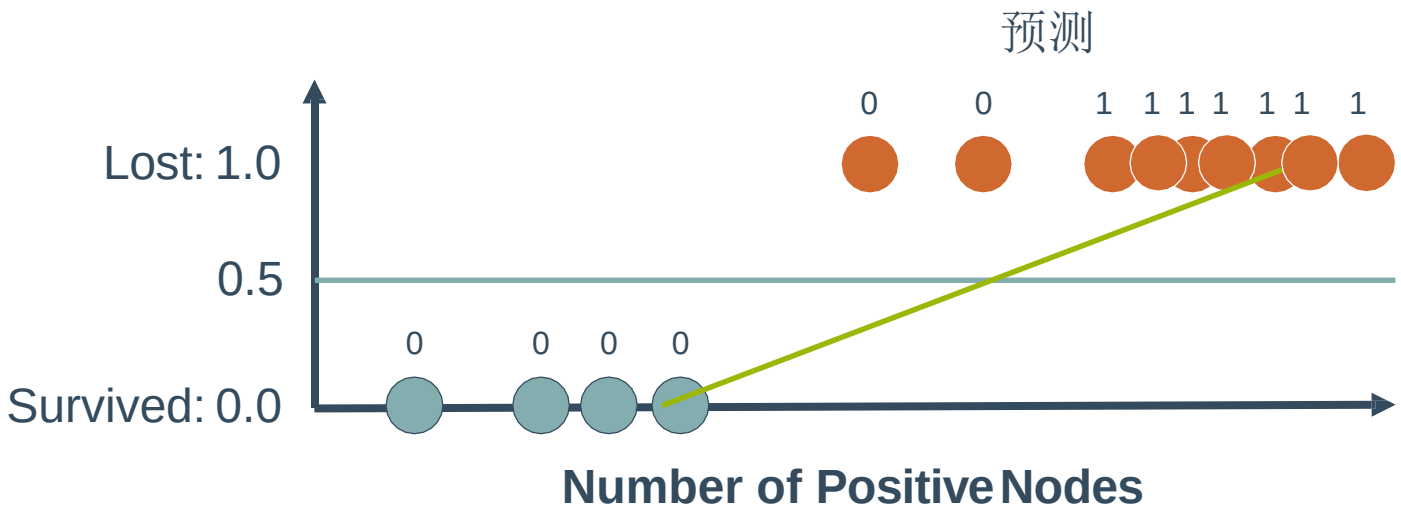

如果模型输出结果 > 0.5：预测 lost
如果模型输出结果 < 0.5：预测 survived

预测值与输出标记

$$z = \boldsymbol{w}^{\mathrm{T}}\boldsymbol{x} + b \qquad y \in \{0, 1\}$$

寻找函数将分类标记与线性回归模型输出联系起来

最理想的函数——单位阶跃函数

$$y = \begin{cases} 0, & z < 0; \\ 0.5, & z = 0; \\ 1, & z > 0, \end{cases}$$

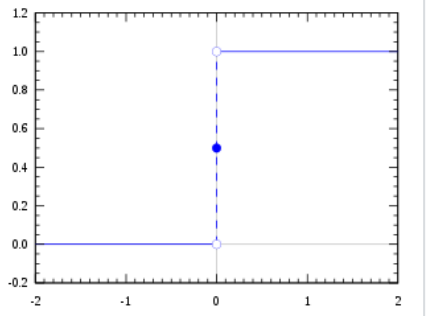

预测值大于零就判为正例，小于零就判为反例，预测值为临界值零则可任意判别

logistic函数

单位阶跃函数缺点

- 不连续

$$y = \frac{1}{1+e^{-z}}$$

替代函数——logistic函数，sigmoid函数，逻辑斯蒂函数

- 单调可微、任意阶可导

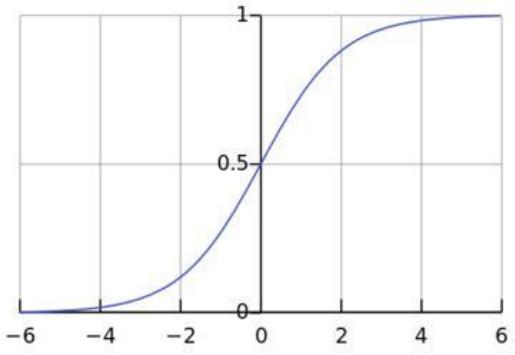

单位阶跃函数与logistic函数的比较

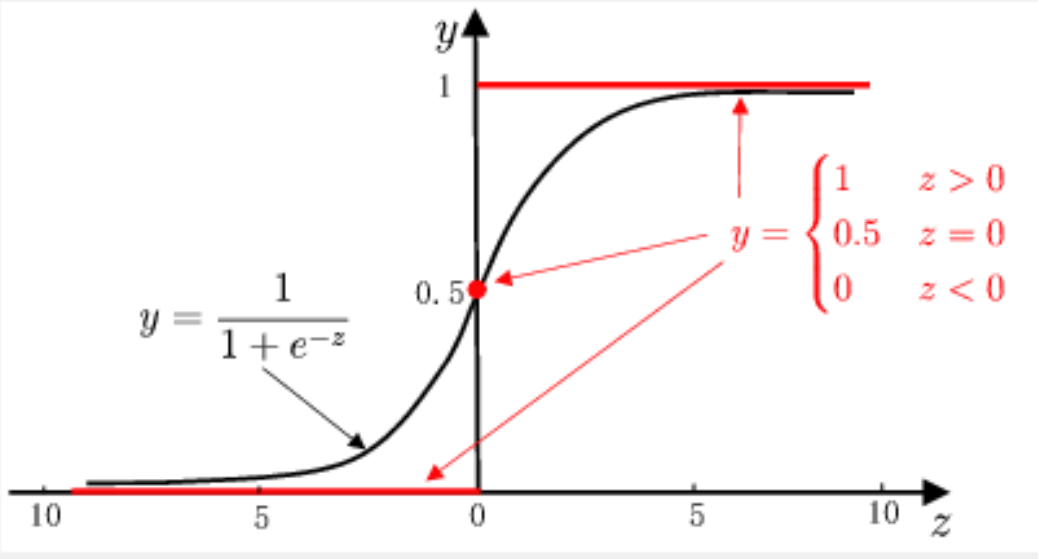

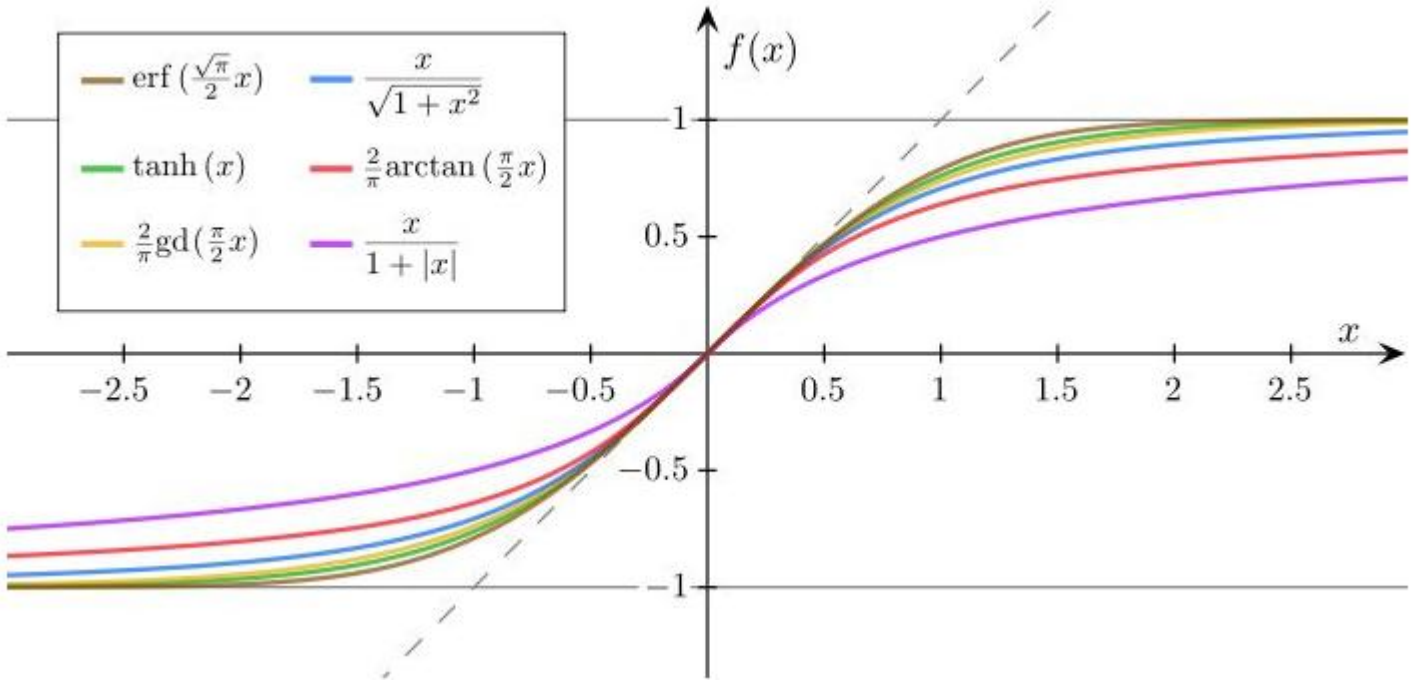

$$y = \frac{1}{1+e^{-z}}$$

$$\frac{\mathrm{d}y}{\mathrm{d}z} = \frac{e^{-z}}{(1+e^{-z})^2} = y\frac{e^{-z}}{1+e^{-z}} = y(1-y)$$

逻辑回归

癌症病人治疗5年之后的状况

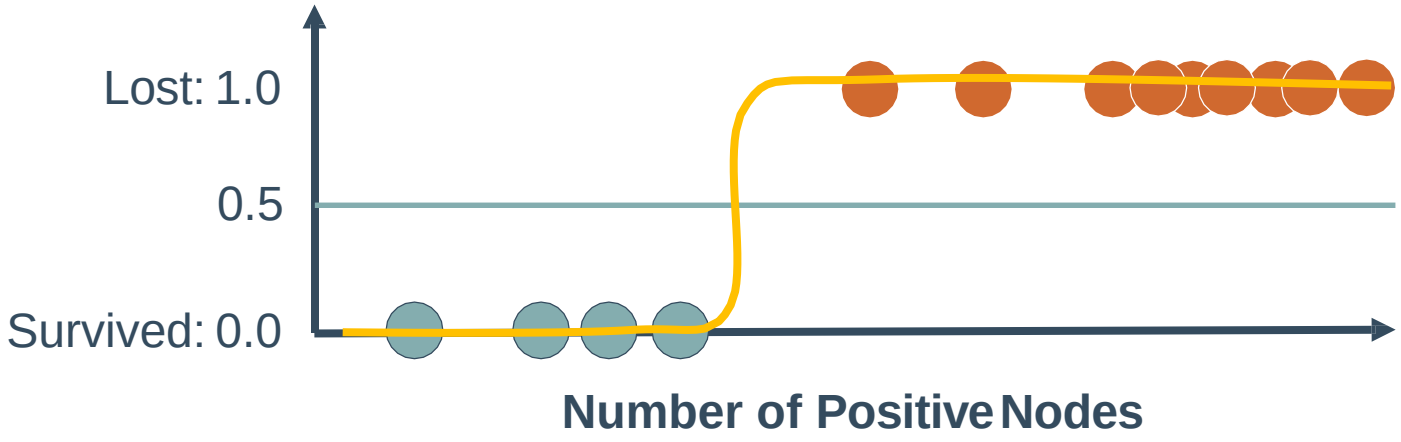

$$y_\beta(x) = \frac{1}{1+e^{-(\beta_0+\beta_1 x)}}$$

判定边界

癌症病人治疗5年之后的状况

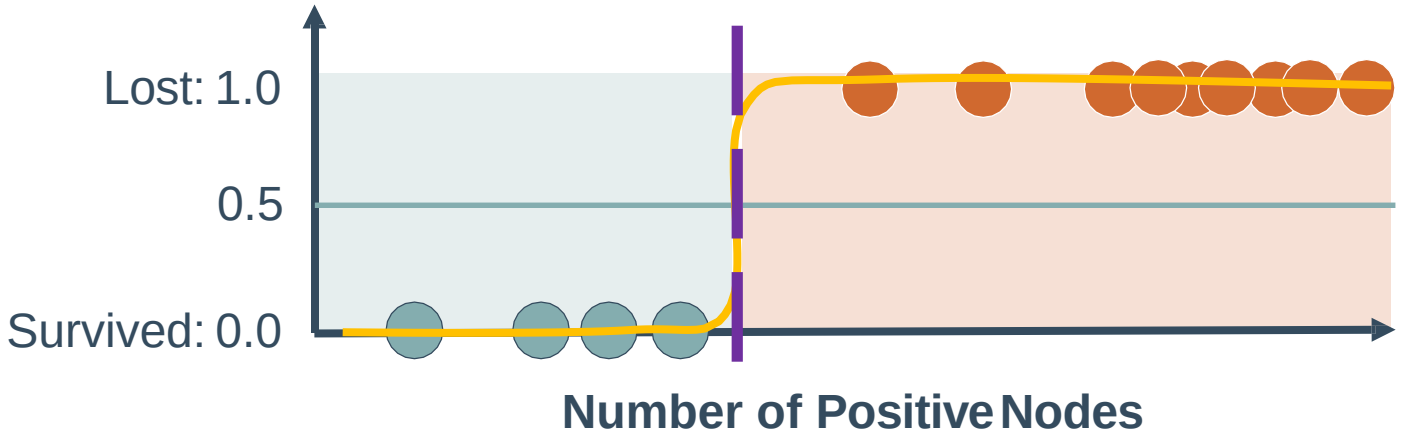

$$y_\beta(x) = \frac{1}{1+e^{-(\beta_0+\beta_1 x)}}$$

逻辑回归和线性回归的关系

Logistic
函数

$$P(x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

逻辑回归和线性回归的关系

Logistic
函数

$$P(x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

$$P(x) = \frac{e^{(\beta_0 + \beta_1 x)}}{1 + e^{(\beta_0 + \beta_1 x)}}$$

逻辑回归和线性回归的关系

Logistic
函数

$$P(x) = \frac{e^{(\beta_0 + \beta_1 x)}}{1 + e^{(\beta_0 + \beta_1 x)}}$$

逻辑回归和线性回归的关系

Logistic 函数

$$P(x) = \frac{e^{(\beta_0 + \beta_1 x)}}{1 + e^{(\beta_0 + \beta_1 x)}}$$

Odds Ratio

$$\frac{P(x)}{1 - P(x)} = e^{(\beta_0 + \beta_1 x)}$$

逻辑回归和线性回归的关系

Logistic 函数

$$P(x) = \frac{e^{(\beta_0 + \beta_1 x)}}{1 + e^{(\beta_0 + \beta_1 x)}}$$

Log Odds

$$log\left[\frac{P(x)}{1-P(x)}\right] = \beta_0 + \beta_1 x$$

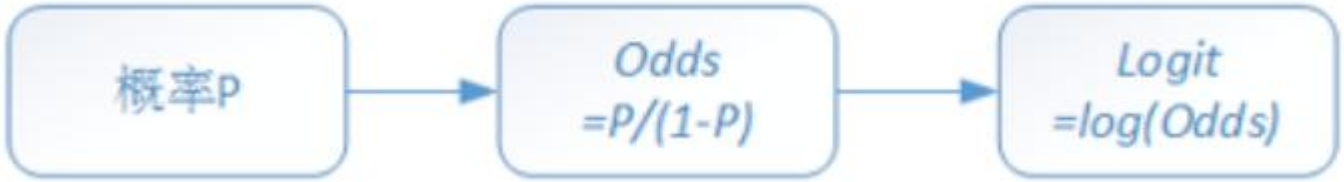

逻辑回归和线性回归的关系

Logistic 函数

$$P(x) = \frac{e^{(\beta_0 + \beta_1 x)}}{1 + e^{(\beta_0 + \beta_1 x)}}$$

Log Odds

$$log\left[\frac{P(x)}{1 - P(x)}\right] = \boxed{\beta_0 + \beta_1 x}$$

代价函数

$$J(\boldsymbol{w}) = \frac{1}{2m}\sum_{i=1}^{m}\left(y^{(i)} - P\left(y^{(i)}|\boldsymbol{x}^{(i)};\boldsymbol{w}\right)\right)^2$$

最大化样本属于其真实标记的概率

$$\prod_{i=1}^{m} p(\hat{y}^{(i)}|x^{(i)})$$

因为各项观测独立，所以它们的联合分布可以表示为各边际分布的乘积

最大化对数似然函数

$$\ell\left(\boldsymbol{w}, b\right) = \sum_{i=1}^{m} \ln\, p\left(y_i \mid \boldsymbol{x}_i; \boldsymbol{w}_i, b\right)$$

逻辑回归的优点

直接对分类可能性建模，无需事先假设数据分布

不是仅预测出“类别”，还可得到对近似概率的预测

对数几率（logistic）函数是任意阶可导的凸函数，有很好的数学性质

逻辑回归做分类

一个特征 (nodes)
两个类标签 (survived, lost)

癌症病人治疗5年之后的状况

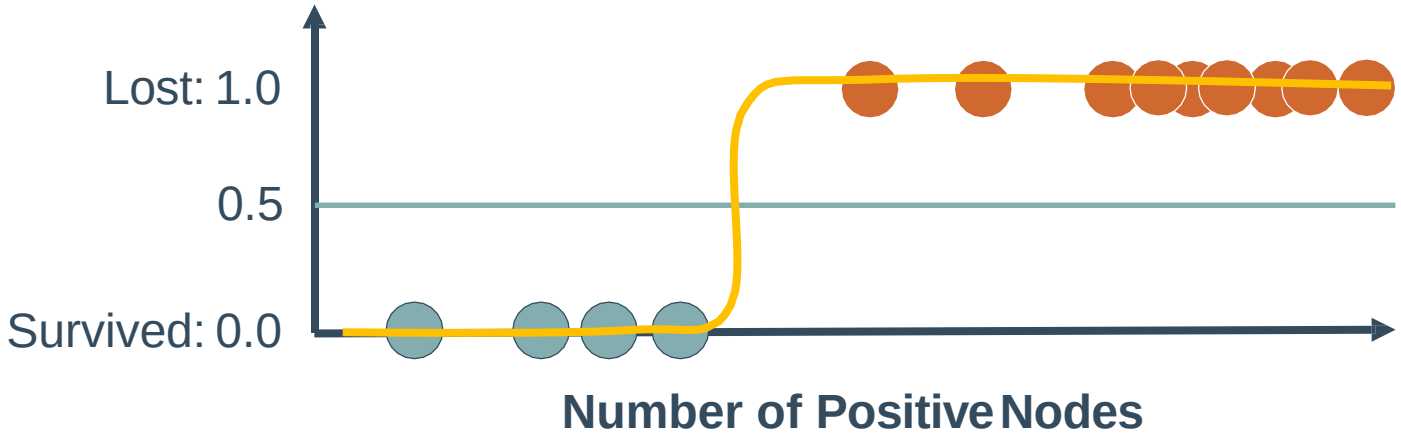

逻辑回归做分类

两个特征 (nodes, age)
两个类标签 (survived, lost)

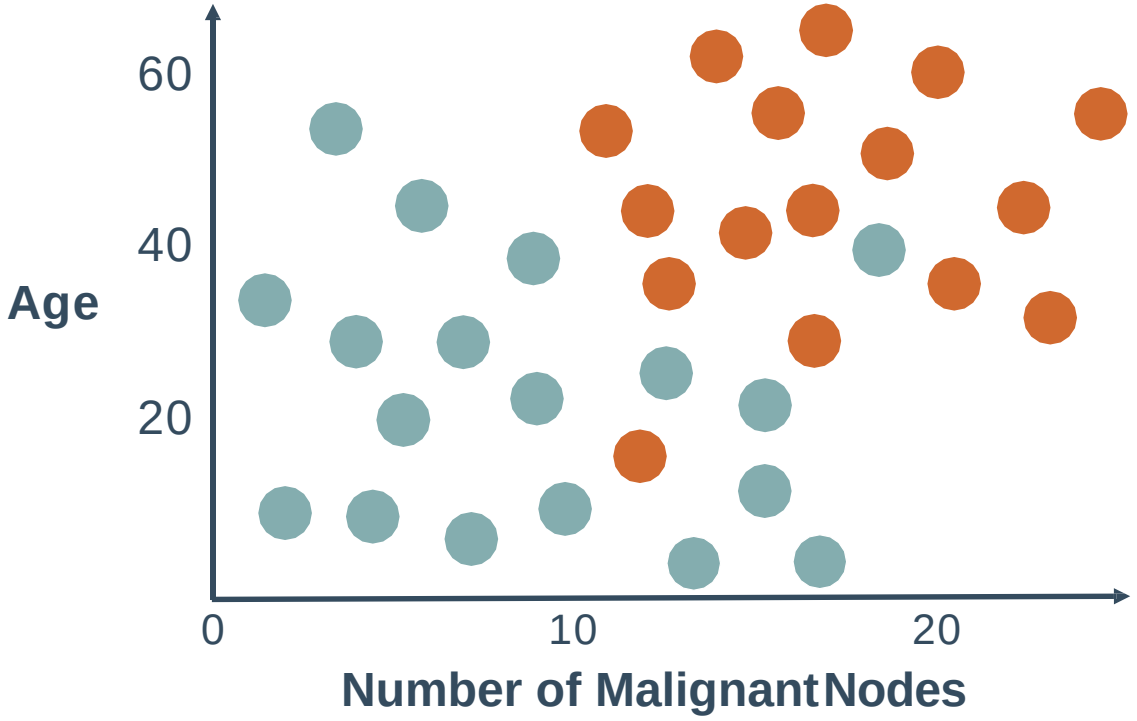

逻辑回归做分类

两个特征 (nodes, age)
两个类标签 (survived, lost)

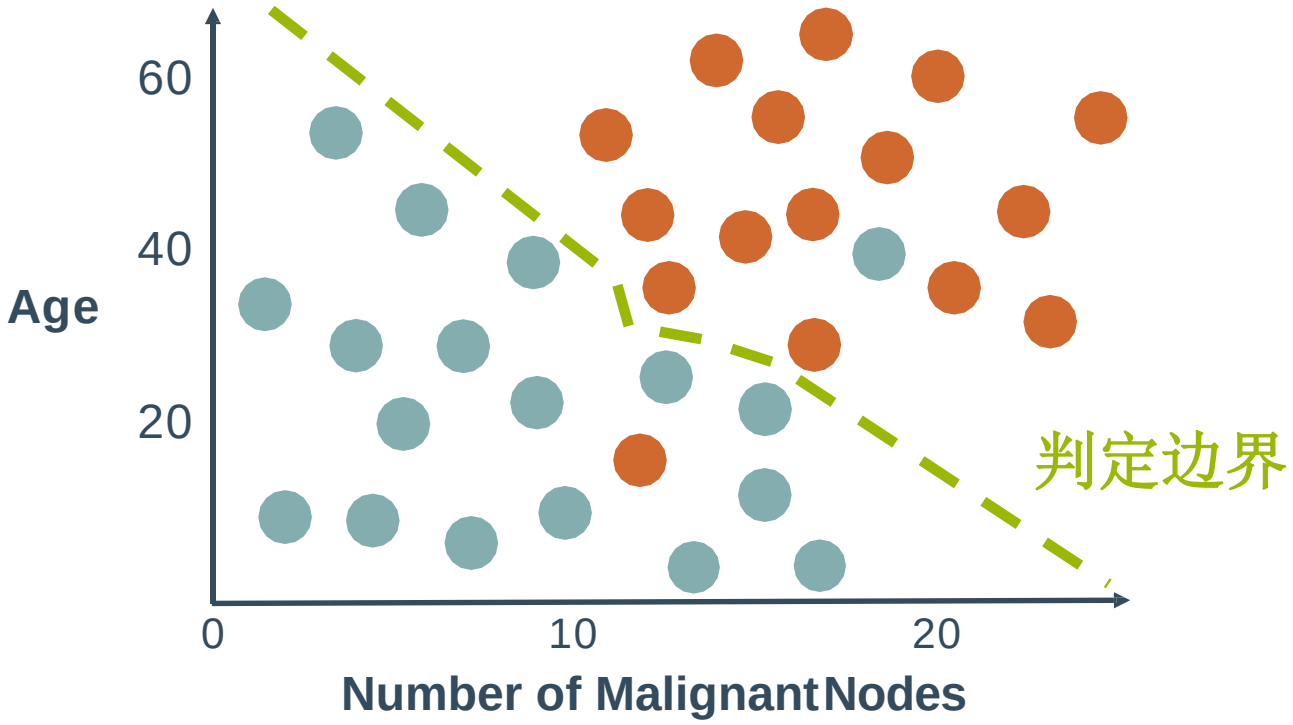

逻辑回归做分类

两个特征 (nodes, age)
两个类标签 (survived, lost)

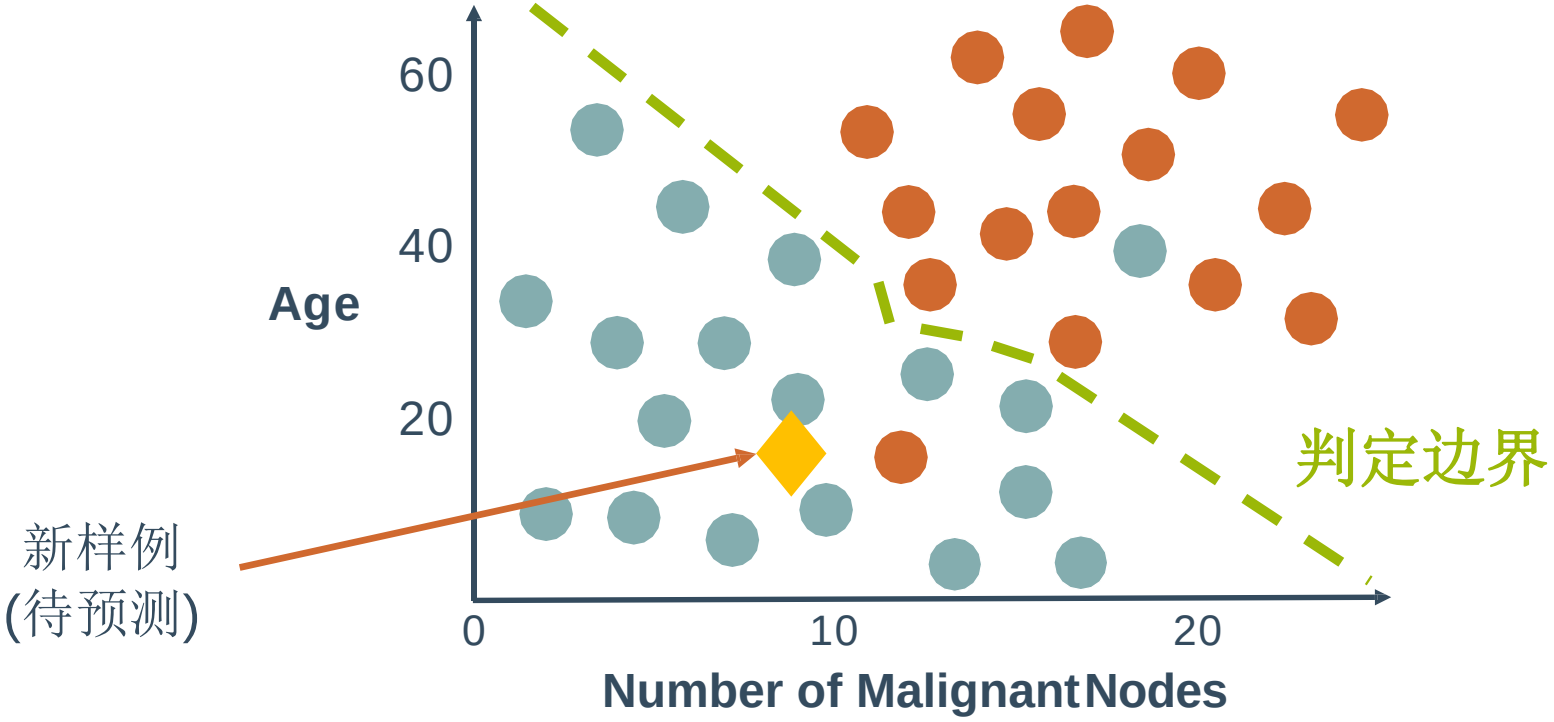

逻辑回归做多分类

两个特征 (nodes, age)
三个类标签 (survived, complications, lost)

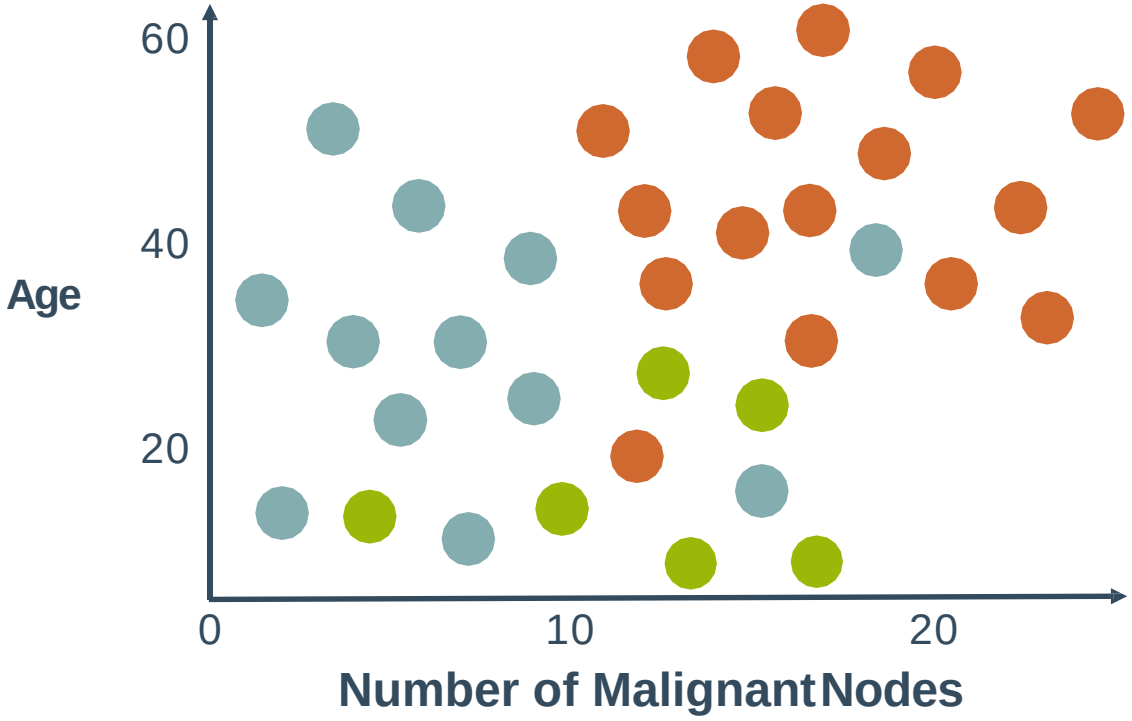

多分类学习

多分类学习方法

1. 二分类学习方法推广到多类
2. 利用二分类学习器解决多分类问题（常用）

- 对问题进行拆分，为拆出的每个二分类任务训练一个分类器
- 对每个分类器的预测结果进行集成以获得最终的多分类结果

拆分策略

- 一对一（One vs. One, OvO）
- 一对其余（One vs. Rest, OvR）
- 多对多（Many vs. Many, MvM）

多分类学习 - 一对一

拆分阶段

1. N个类别两两配对

   N(N-1)/2 个二类任务

2. 各个二类任务学习分类器

   N(N-1)/2 个二类分类器

测试阶段

1. 新样本提交给所有分类器预测

   N(N-1)/2 个分类结果

2. 投票产生最终分类结果

   被预测最多的类别为最终类别

多分类学习 - 一对其余

任务拆分

1. 某一类作为正例，其他反例

   N 个二类任务

2. 各个二类任务学习分类器

   N 个二类分类器

测试阶段

1. 新样本提交给所有分类器预测

   N 个分类结果

2. 比较各分类器预测置信度

   置信度最大类别作为最终类别

多分类学习 - 两种策略比较

训练N(N-1)/2个分类器，存储开销和测试时间大

训练只用两个类的样例，训练时间短

训练N个分类器，存储开销和测试时间小

训练用到全部训练样例，训练时间长

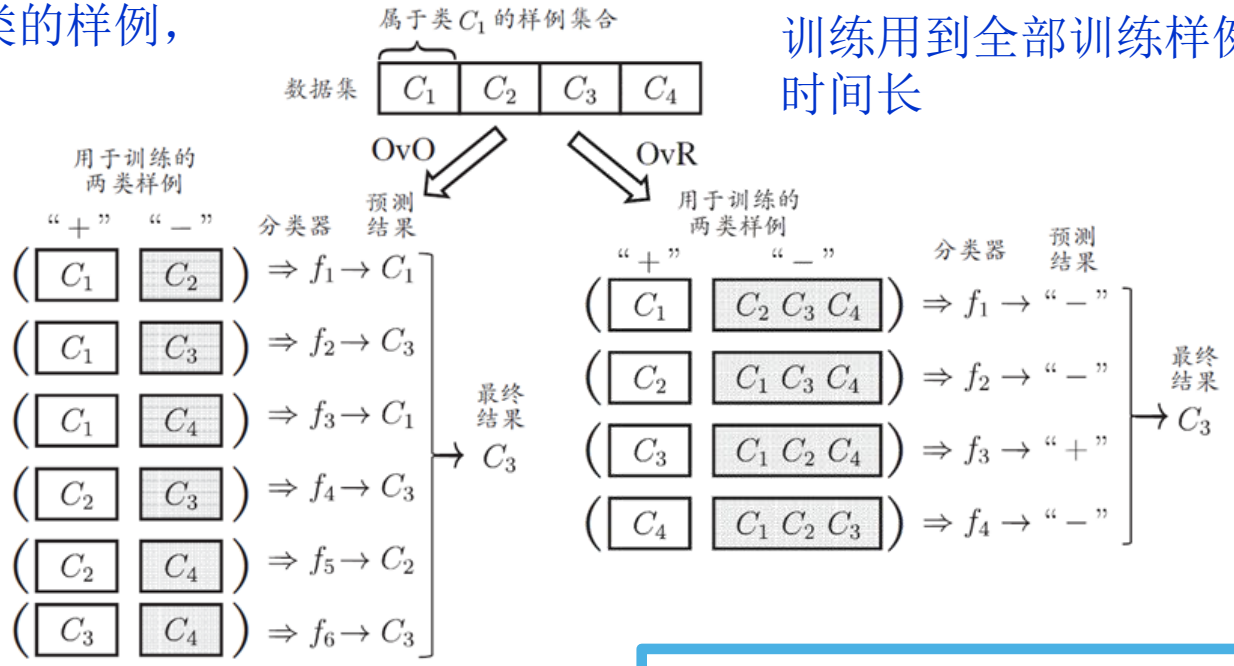

预测性能取决于具体数据分布，多数情况下两者差不多

多分类学习 - 多对多

多对多（Many vs Many，MvM）

若干类作为正类，若干类作为反类

纠错输出码（Error Correcting Output Code, ECOC）

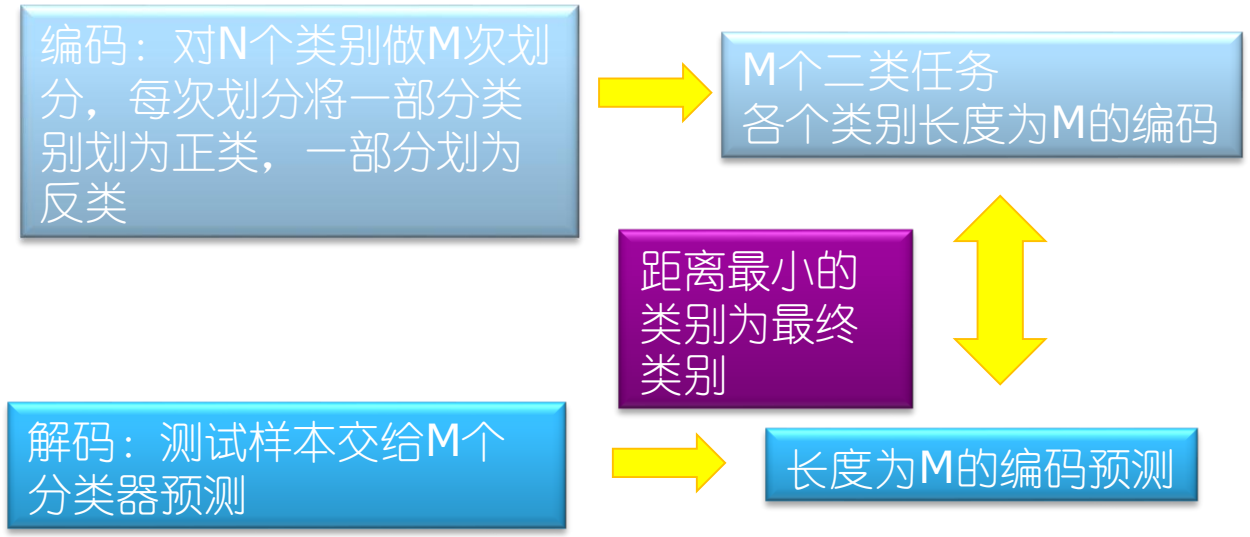

多分类学习 - 多对多

两个码字的对应比特取值不同的比特数称为这两个码字的海明距离

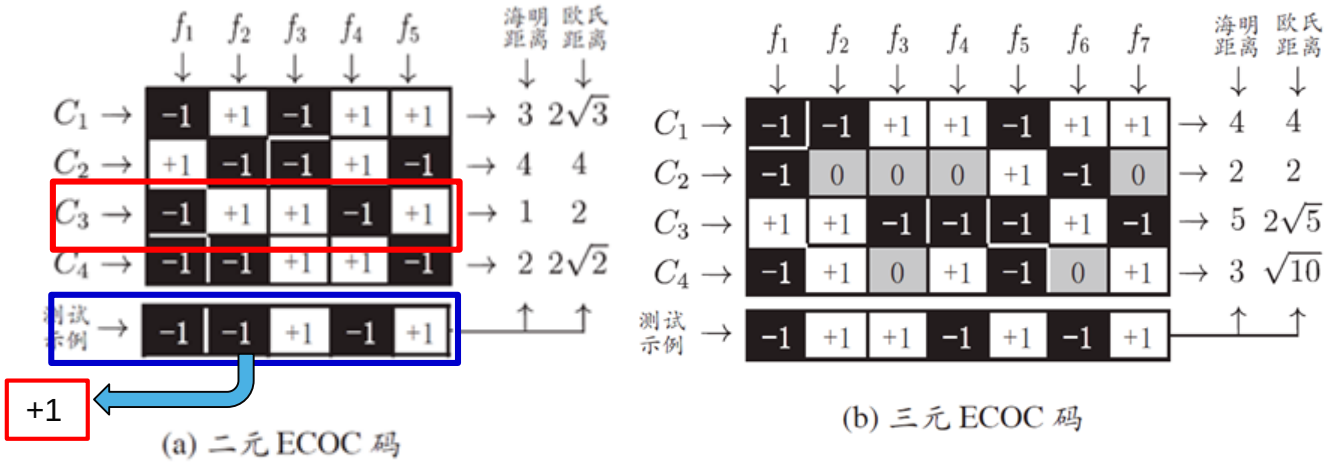

- ECOC编码对分类器错误有一定容忍和修正能力，编码越长、纠错能力越强
- 对同等长度的编码，理论上来说，任意两个类别之间的编码距离越远，则纠错能力越强

One vs All: Survived vs All

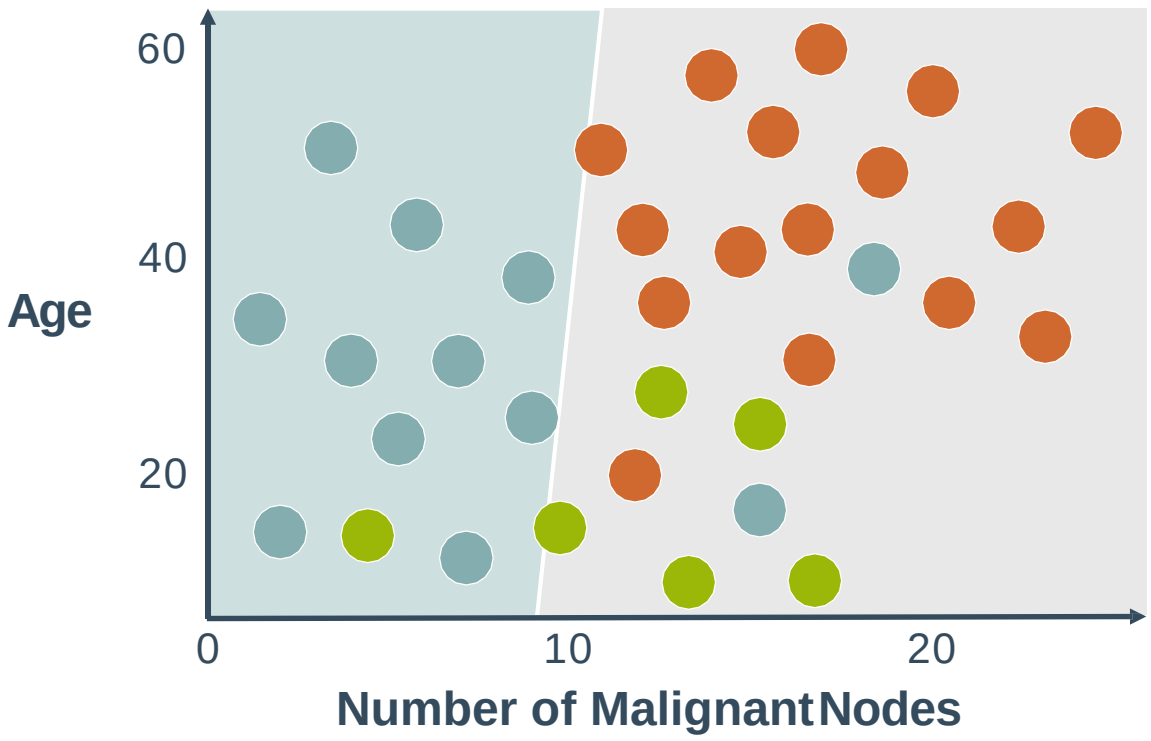

One vs All: Complications vs All

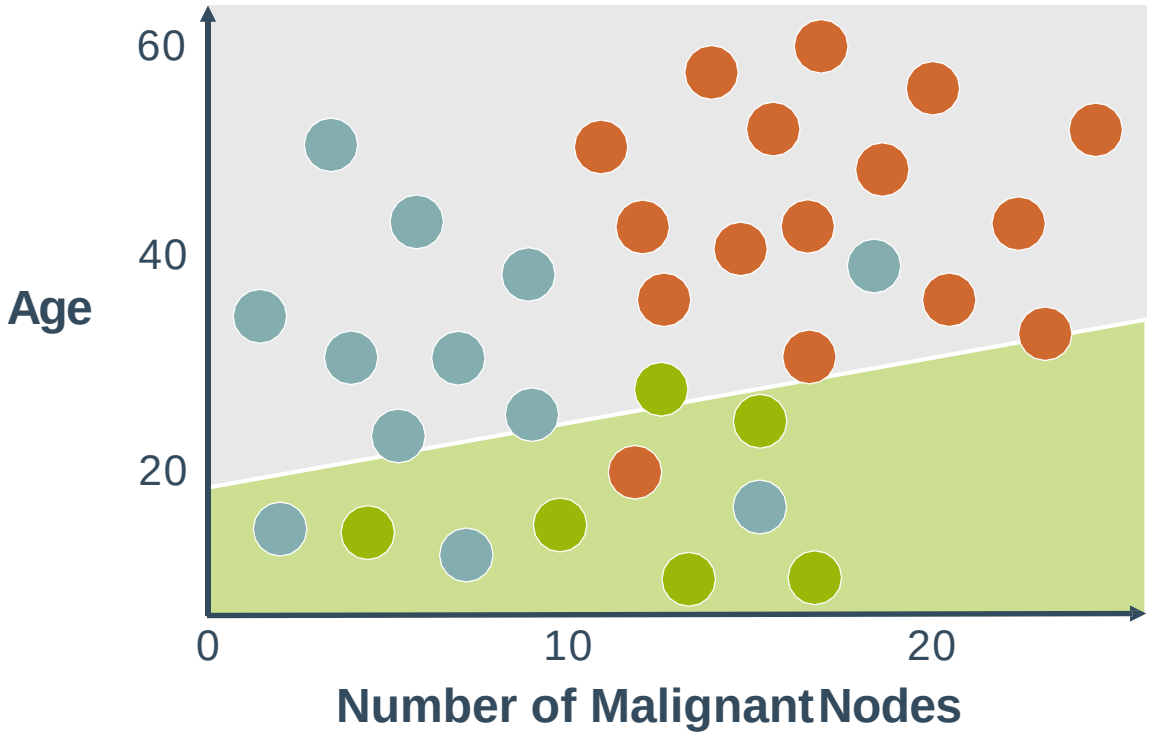

One vs All: Lost vs All

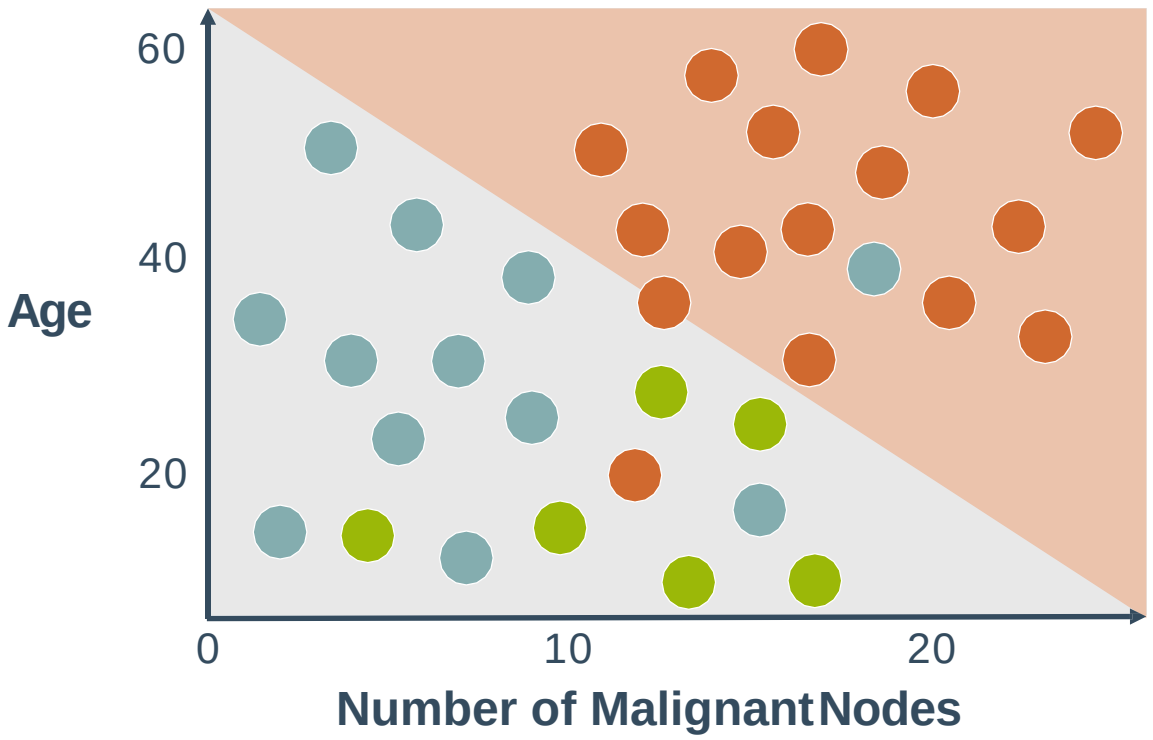

多分类判定边界

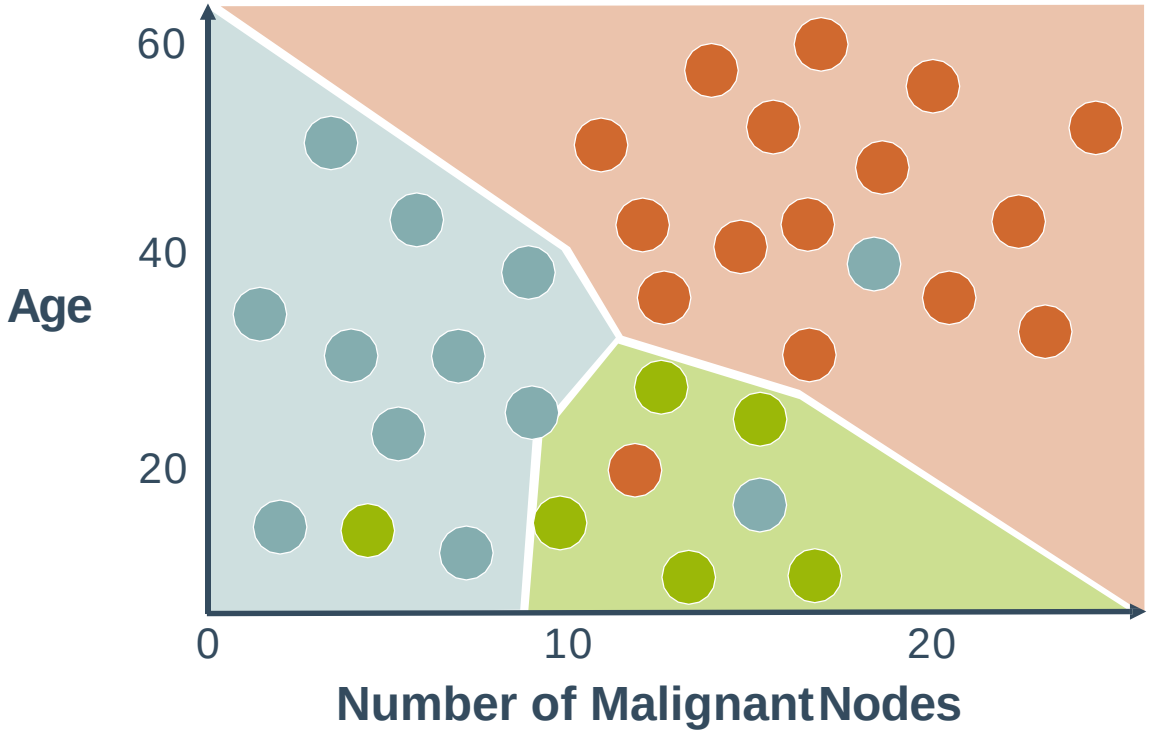

每个区域属于其概率最大的类

逻辑回归的语法

导入包含分类方法的类：

```
from sklearn.linear_model import LogisticRegression
```

创建该类的一个实例：

```
LR = LogisticRegression(penalty = 'l2', C = 10.0)
```

逻辑回归的语法

导入包含分类方法的类：

```
from sklearn.linear_model import LogisticRegression
```

创建该类的一个实例：

```
LR = LogisticRegression(penalty = 'l2', C = 10.0)
```

正则化参数

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

逻辑回归的语法

导入包含分类方法的类：

```
from sklearn.linear_model import LogisticRegression
```

创建该类的一个实例：

```
LR = LogisticRegression(penalty = '12', C = 10.0)
```

拟合训练数据并预测：

```
LR = LR.fit(X_train, y_train)

y_predict = LR.predict(X_test)
```

逻辑回归的语法

导入包含分类方法的类：

```
from sklearn.linear_model import LogisticRegression
```

创建该类的一个实例：

```
LR = LogisticRegression(penalty = 'l2', C = 10.0)
```

拟合训练数据并预测：

```
LR = LR.fit(X_train, y_train)
y_predict = LR.predict(X_test)
```

使用交叉验证自动确定正则化参数：**LogisticRegressionCV**