朴素贝叶斯

贝叶斯决策论

贝叶斯决策论是在概率框架下实施决策的基本方法。

在分类问题情况下，在所有相关概率都已知的理想情形下，贝叶斯决策考虑如何基于这些概率和误判损失来选择最优的类别标记。

假设有 N 种可能的类别标记，即 $y=\{c_1,c_2,\ldots,c_N\}$，λ_{ij} 是将一个真实标记为 c_j的样本误分类为c_i所产生的损失。基于后验概率 $P\{c_i \mid \mathbf{x}\}$ 可获得将样本x分类为 c_i所产生的期望损失，即在样本x上的“条件风险”

$$R(c_i \mid \mathbf{x})=\sum_{j=1}^{N}\lambda_{ij}P(c_j \mid \mathbf{x})$$

贝叶斯判定准则：为最小化总体风险，只需在每个样本上选择那个能使条件风险最小的类别标记，即

$$h^*(x)=\underset{c\in y}{\operatorname{argmin}}\,R(c \mid x)$$

具体来说，若目标是最小化分类错误率，则误判损失λ_{ij} 可写为

$$\lambda_{i,j}\begin{cases} 0, & \text{if } \ i=j; \\ 1, & \text{otherwise}, \end{cases}$$

此时条件风险

$$R(c \mid \mathbf{x}) = 1 - P(c \mid \mathbf{x})$$

可得：

$$R(c_i|\boldsymbol{x}) = 1 * P(c_1|\boldsymbol{x}) + 1 * P(c_2|\boldsymbol{x}) + \ldots$$
$$+ 0 * P(c_i|\boldsymbol{x}) + \ldots + 1 * P(c_N|\boldsymbol{x})$$

又 $\sum_{j=1}^{N} P(c_j|\boldsymbol{x}) = 1$，则：

$$R(c_i|\boldsymbol{x}) = 1 - P(c_i|\boldsymbol{x})$$

使用贝叶斯判定准则来最小化决策风险，首先要获得后验概率 $P(c \mid \mathbf{x})$。

然而，在现实中通常难以直接获得。机器学习所要实现的是基于有限的训练样本尽可能准确地估计出后验概率 $P(c \mid \mathbf{x})$。

主要有两种策略：

- 判别式模型（discriminative）

  给定 $\mathbf{x}$，通过直接建模 $P(c \mid \mathbf{x})$，来预测 c

  决策树，BP神经网络，支持向量机

- 生成式模型（generative）

  先对联合概率分布 $P(\mathbf{x}, c)$ 建模，再由此获得 $P(c \mid \mathbf{x})$

  生成式模型考虑 $P(c \mid \mathbf{x}) = \dfrac{P(\mathbf{x}, c)}{P(\mathbf{x})}$

贝叶斯分类器 ≠ 贝叶斯学习

基于贝叶斯定理，$P(c \mid \mathbf{x})$ 可写成

$$P(c \mid \mathbf{x}) = \frac{P(c)P(\mathbf{x} \mid c)}{P(\mathbf{x})}$$

类标记 c 相对于样本 $\mathbf{x}$ 的“类条件概率”（class-conditional probability），或称“似然”。

先验概率
样本空间中各类样本所占的比例，可通过各类样本出现的频率估计（大数定理）

与类标记无关

概率模型的训练过程就是参数估计过程，统计学界的两个学派提供了不同的方案：

- 频率主义。认为参数虽然未知，但却存在客观值。（统计学习）
- 贝叶斯主义。认为参数是未观察到的随机变量，其本身也可有分布，因此可假定参数服从一个先验分布，然后基于观测到的数据计算参数的后验分布。

极大似然估计

估计类条件概率的常用策略：先假定其具有某种确定的概率分布形式，再基于训练样本对概率分布参数估计。

记关于类别 c 的类条件概率为 $P(\mathbf{x} \mid c)$ ，

假设 $P(\mathbf{x} \mid c)$ 具有确定的形式被参数 $\boldsymbol{\theta}_c$ 唯一确定，我们的任务就是利用训练集 D 估计参数 $\boldsymbol{\theta}_c$

令 D_c 表示训练集中第 c 类样本的组成的集合，假设这些样本是独立的，则参数 $\boldsymbol{\theta}_c$ 对于数据集 D_c 的似然是

$$P(D_c \mid \boldsymbol{\theta}_c) = \prod_{\mathbf{x} \in D_c} P(\mathbf{x} \mid \boldsymbol{\theta}_c)$$

对 $\boldsymbol{\theta}_c$ 进行极大似然估计，寻找能最大化似然 $P(D_c \mid \theta_c)$ 的参数值 $\hat{\theta}_c$ 。直观上看，极大似然估计是试图在 θ_c 所有可能的取值中，找到一个使数据出现的“可能性”最大值。

贝叶斯定理

$$P(Y|X) = \frac{P(X|Y) * P(Y)}{\cancel{P(X)}}$$

$$posterior = \frac{likelihood * prior}{\cancel{evidence}}$$

训练朴素贝叶斯

给定特征向量(X)，计算其属于每个类别 (C) 的概率

$$P(C|X) = P(X|C) * P(C)$$

Class Features

训练朴素贝叶斯：朴素假设

给定特征向量(X)，计算其属于每个类别 (C) 的概率

$$P(C|X) = P(X|C) * P(C)$$

很难计算所有特征的联合概率

$$P(C|X) = P(X_1, X_2, \dots, X_n|C) * P(C)$$

$$P(X_1|X_2, \dots, X_n, C) * P(X_2, \dots, X_n|C) * P(C)$$

$$\dots$$

训练朴素贝叶斯：朴素假设

给定特征向量(X)，计算其属于每个类别 (C) 的概率

解决方案：**假设给定类别，所有特征相互独立**

$$P(C|X) = P(X|C) * P(C)$$

$$P(C|X) = P(X_1|C) * P(X_2|C) * P(X_n|C) * P(C)$$

训练朴素贝叶斯：朴素假设

给定特征向量(X)，计算其属于每个类别 (C) 的概率

解决方案：**假设给定类别，所有特征相互独立**

这就是“朴素”的假设

$$P(C|X) = P(X|C) * P(C)$$

$$P(C|X) = P(X_1|C) * P(X_2|C) * P(X_n|C) * P(C)$$

$$P(C|X) = P(C)\prod_{i=1}^{n} P(X_i|C)$$

训练朴素贝叶斯

给定特征向量(X)，计算其属于每个类别 (C) 的概率

$$P(C|X) = P(X|C) * P(C)$$

按照最大后验概率规则，把X分入概率最大的类别

$$\underset{k \in \{1, \dots K\}}{argmax} P(C_k) \prod_{i=1}^{n} P(X_i|C_k)$$

对数技巧

很多概率值连乘，容易造成浮点计算下界溢出

$$\underset{k \in \{1, \dots K\}}{argmax} P(C_k) \prod_{i=1}^{n} P(X_i | C_k)$$

对数技巧

很多概率值连乘，容易造成浮点计算下界溢出

$$\underset{k \in \{1, \dots K\}}{argmax} P(C_k) \prod_{i=1}^{n} P(X_i | C_k)$$

取对数把乘法转化成加法

$$\log(P(C_k)) \sum_{i=1}^{n} \log(P(X_i | C_k))$$

案例：预测打网球

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

案例：预测打网球

预测下面情境下是否打网球：

x’=(Outlook=Sunny, Temperature=Cool, Humidity=High, Wind=Strong)

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

案例：预测打网球

$$\frac{argmax}{k \in \{1, \dots K\}} P(C_k) \prod_{i=1}^{n} P(X_i | C_k)$$

P(Play=Yes) = 9/14

P(Play=No) = 5/14

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

案例：预测打网球

$$\underset{k \in \{1, \dots K\}}{argmax} P(C_k) \prod_{i=1}^{n} P(X_i | C_k)$$

P(Play=Yes) = 9/14

Outlook	Play=Yes	Play=No
Sunny	2/9	3/5
Overcast	4/9	0/5
Rain	3/9	2/5

P(Play=No) = 5/14

Temperature	Play=Yes	Play=No
Hot	2/9	2/5
Mild	4/9	2/5
Cool	3/9	1/5

Humidity	Play=Yes	Play=No
High	3/9	4/5
Normal	6/9	1/5

Wind	Play=Yes	Play=No
Strong	3/9	3/5
Weak	6/9	2/5

使用训练数据构建概率查找表

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

案例：预测打网球

$$\underset{k \in \{1, \dots K\}}{argmax} P(C_k) \prod_{i=1}^{n} P(X_i | C_k)$$

预测下面情境下是否打网球：

x'=(Outlook=Sunny, Temperature=Cool, Humidity=High, Wind=Strong)

$$P(yes|sunny, cool, high, strong) = P(sunny|yes) * P(cool|yes) * P(high|yes) * P(strong|yes) * P(yes)$$

$$P(no|sunny, cool, high, strong) = P(sunny|no) * P(cool|no) * P(high|no) * P(strong|no) * P(no)$$

案例：预测打网球

预测下面输入的输出：

x'=(Outlook=Sunny, Temperature=Cool, Humidity=High, Wind=Strong)

$$\underset{k \in \{1, \dots K\}}{argmax} P(C_k) \prod_{i=1}^{n} P(X_i | C_k)$$

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

$$P(yes|sunny, cool, high, strong) = P(sunny|yes) * P(cool|yes) * P(high|yes) * P(strong|yes) * P(yes)$$

$$P(no|sunny, cool, high, strong) = P(sunny|no) * P(cool|no) * P(high|no) * P(strong|no) * P(no)$$

Feature	Play=Yes	Play=No
Outlook=Sunny	2/9	3/5
Temperature=Cool	3/9	1/5
Humidity=High	3/9	4/5
Wind=Strong	3/9	3/5
Overall Label	**9/14**	**5/14**

案例：预测打网球

预测下面输入的输出：

x’=(Outlook=Sunny, Temperature=Cool, Humidity=High, Wind=Strong)

$$\underset{k \in \{1, \dots K\}}{argmax} P(C_k) \prod_{i=1}^{n} P(X_i | C_k)$$

Feature	Play=Yes	Play=No
Outlook=Sunny	2/9	3/5
Temperature=Cool	3/9	1/5
Humidity=High	3/9	4/5
Wind=Strong	3/9	3/5
Overall Label	**9/14**	**5/14**
Probability	**0.0053**	**0.0206**

案例：预测打网球

预测下面输入的输出：

x’=(Outlook=Sunny, Temperature=Cool, Humidity=High, Wind=Strong)

$$\underset{k \in \{1, \dots K\}}{argmax} P(C_k) \prod_{i=1}^{n} P(X_i | C_k)$$

Feature	Play=Yes	Play=No
Outlook=Sunny	2/9	3/5
Temperature=Cool	3/9	1/5
Humidity=High	3/9	4/5
Wind=Strong	3/9	3/5
Overall Label	**9/14**	**5/14**
Probability	**0.0053**	**0.0206**

案例：预测打网球

预测下面输入的输出：

x’=(Outlook=Overcast, Temperature=Cool, Humidity=High, Wind=Strong)

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

$$\underset{k \in \{1, \dots K\}}{argmax} P(C_k) \prod_{i=1}^{n} P(X_i | C_k)$$

拉普拉斯平滑

问题：有些类别里没有的特征将会导致这些条件概率值为"0"

$$P(C|X) = \overset{0}{\boxed{P(X_1|C)}} * P(X_2|C) * P(C)$$

拉普拉斯平滑（修正）

若某个属性值在训练集中没有与某个类同时出现过，则直接计算会出现问题。训练集中没有该样例，因此连乘式计算的概率值为0，无论其他属性如何，分类结果不会是该类别，这显然不合理。

为了避免其他属性携带的信息被训练集中未出现的属性值“抹去”，在估计概率值时通常要进行“拉普拉斯修正”

令 N 表示训练集 D 中可能的类别数，N_i表示第 i个属性可能的取值数，则修正为

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N} \qquad \hat{P}(x_i \mid c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}$$

拉普拉斯平滑

问题：有些类别里没有的特征将会导致这些条件概率值为"0"

$$P(C|X) = \overset{0}{\boxed{P(X_1|C)}} * P(X_2|C) * P(C)$$

解决方案：

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N}$$

$$\hat{P}(x_i \mid c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}$$

朴素贝叶斯模型的类型

朴素贝叶斯模型	数据类型
贝努利模型	二值 (T/F)
多项式模型	离散值 (如，计数)
高斯模型	连续值

不同朴素贝叶斯模型的区别，主要在于它们对概率分布 $P(X_i/C)$所做的不同假设。

朴素贝叶斯的语法

导入包含朴素贝叶斯分类方法的类：

```
from sklearn.naive_bayes import BernoulliNB
```

创建该类的一个对象：

```
BNB = BernoulliNB(alpha=1.0)
```

拟合训练数据，并预测：

```
BNB = BNB.fit(X_train, y_train)
y_predict = BNB.predict(X_test)
```

朴素贝叶斯的语法

导入包含朴素贝叶斯分类方法的类：

```
from sklearn.naive_bayes import BernoulliNB
```

创建该类的一个对象：

```
BNB = BernoulliNB(alpha=1.0)
```

拉普拉斯平滑参数

拟合训练数据，并预测：

```
BNB = BNB.fit(X_train, y_train)
y_predict = BNB.predict(X_test)
```

http://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.BernoulliNB.html

朴素贝叶斯的语法

导入包含朴素贝叶斯分类方法的类：

```
from sklearn.naive_bayes import BernoulliNB
```

创建该类的一个对象：

```
BNB = BernoulliNB(alpha=1.0)
```

拉普拉斯平滑参数

拟合训练数据，并预测：

```
BNB = BNB.fit(X_train, y_train)
y_predict = BNB.predict(X_test)
```

其他朴素贝叶斯模型： MultinomialNB, GaussianNB.

文本分类实例

文本	标签
A great game	Sports
The election was over	not Sports
Very clean match	Sports
A clean but forgettable game	Sports
It was a close election	not Sports

A very close game → Sports / not Sports ?

P(Sports | a very close game)

P(not Sports | a very close game)

P(Sports | a very close game) = P(a very close game | Sports) x P(Sports)

P(not Sports | a very close game) = P(a very close game | not Sports) x P(not Sports)

P(Sports | a very close game) = P(a very close game | Sports) x P(Sports)

=P(a|Sports)x P(very |Sports)x close |Sports)x game |Sports)x P(Sports)

=2/11*1/11*0/11*2/11*11/14*3/5

文本分类

用计算机对文本按照一定的分类体系或标准进行自动分类标记

其应用场景众多，包括：

- 情感分析（Sentiment Analyse）　（积极、消极、中性）
- 主题分类（Topic Labeling）　（金融、体育、军事、社会）
- 问答任务(Question Answering)
- 意图识别(Dialog Act Classification)　（天气查询、歌曲搜索、随机闲聊）
- 自然语言推理（Natural Language Inference）

文本特征表示

文本特征表示的目的让将文本转变成一种能够让计算机更容易处理的形式，同时减少信息的损失。常见的文本特征表示方法包括：BOW、N-gram、TF-IDF、word2vec、Glove。

- BOW用词典大小的向量来表征文本，每个值代表该词在文中出现的次数，该方法忽略了文本当中的词序。
- N-gram将相邻的文字和词组信息纳入到表征的词典当中。
- TF-IDF使用词频和逆文档频率来建模文本。
- Word2vec使用局部上下文信息来获取词向量。
- Glove采用了局部上下文信息和全局统计特征。

TF-IDF（term frequency - inverse document frequency）

单个文本的样本称为**文档**(document)，而所有文档的集合称为**语料库**(corpus)。

- 淘宝购物后的评语，每一条评语称为**文档**，所有的评语称为**语料库**；
- 一篇论文可称为**文档**，所有的论文称为**语料库**。

TF 词频计算

r_j 代表文档， w_i 代表单词

r_1	w_1	$\boxed{w_2}$	w_3	$\boxed{w_2}$	w_5	w_6			→ 共6个单词
r_2	w_1	$\boxed{w_3}$	$\boxed{w_3}$	w_4	w_5	w_6	w_4	w_7	→ 共8个单词
r_3	…			…			…		
⋮									
r_n	…			…			…		

TF的通用公式为： $TF(w_i, r_j) = \frac{\text{当前文档里单词}w_i\text{的出现次数}}{\text{当前文档单词总数}}$

- 在文档 r_1 中 w_2 的词频为： $TF(w_2, r_1) = \frac{2}{6} = \frac{1}{3}$
- 在文档 r_2 中 w_3 的词频为： $TF(w_3, r_2) = \frac{2}{8} = \frac{1}{4}$

IDF 逆文本频率指数计算

r_j 代表文档， w_i 代表单词

r_1	w_1	w_2	$\boxed{w_3}$	w_2	w_5	w_6		
r_2	w_1	$\boxed{w_3}$	$\boxed{w_3}$	w_4	w_5	w_6	w_4	w_7
r_3	$\cdots$			$\cdots$	$\boxed{w_3}$		$\cdots$	
$\vdots$								
r_{10}	$\cdots$		$\boxed{w_3}$	$\cdots$			$\cdots$	
$\vdots$								
r_n	$\cdots$			$\cdots$			$\cdots$	

IDF的通用公式为： $IDF(w_i, D_c) = log\left(\frac{\text{总文档数}}{\text{包含}w_i\text{的文档数}}\right)$,语料库 $D_c = \{r_1, r_2, \cdots, r_n\}$

在所有文档中，包含单词w_3 的有 $\{r_1, r_2, r_3, r_{10}\}$ 四个文档，所以关于 单词w_3 逆文本频率 $IDF(w_3, D_c) = log\left(\frac{n}{4}\right)$ ，一般 n 是固定的比较大，如果分母非常小，所以需要 log 来进行量纲问题处理。

TF-IDF

$$TF-IDF = TF(w_i, r_j) * IDF(w_i, D_c)$$

如果某个单词w_i 在某个文档 r_j 中的频数很大,那么**TF**就会很大 ； 同时w_i只在语料库 D_c 少量文档中出现,那么**IDF**就会很大，那么 **TF-IDF**就会更大。

TF-IDF 就是更加 重视语料库中较罕见的词 和 更加 重视单个文档中较常见的词。

垃圾邮件识别

发件人和邮件主题

附带恶意软件的邮件

邮件内容和文本排版