第12章 集成学习

集成

集成学习(ensemble learning)通过**构建**并**结合多个学习器**来提升性能

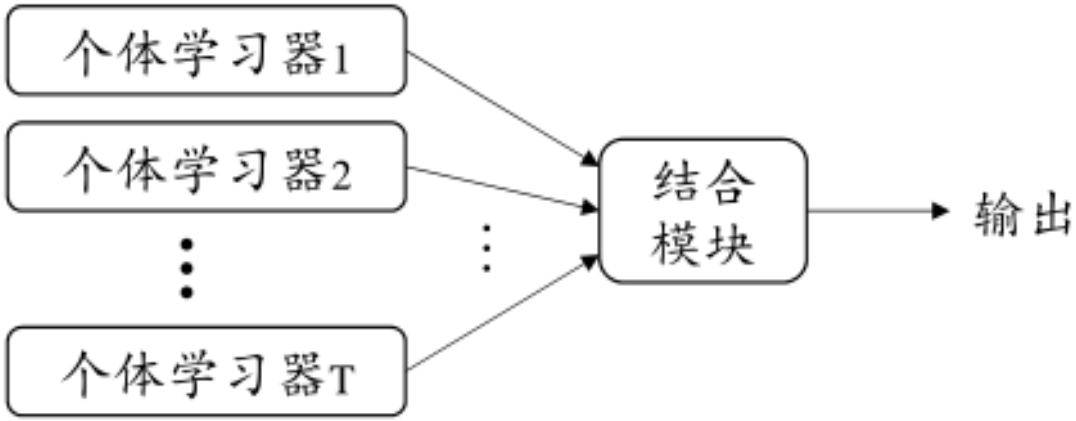

三个臭皮匠 顶个诸葛亮

- 同质
- 基学习器
- 基学习算法
- 异质
- 组件学习器
- 个体学习器
- 弱学习器

考虑一个简单的例子，在二分类问题中，假定3个分类器在三个样本中的表现如下图所示，其中√表示分类正确，X号表示分类错误，集成的结果通过投票产生。

	测试例1	测试例2	测试例3
h_1	√	√	×
h_2	×	√	√
h_3	√	×	√
集群	√	√	√

(a) 集群提升性能

	测试例1	测试例2	测试例3
h_1	√	√	×
h_2	√	√	×
h_3	√	√	×
集群	√	√	×

(b) 集群不起作用

	测试例1	测试例2	测试例3
h_1	√	×	×
h_2	×	√	×
h_3	×	×	√
集群	×	×	×

(c) 集群起负作用

集成个体：好而不同

假设基分类器的错误率相互独立，

在一定条件下，随着集成分类器数目的增加，集成的错误率将指数级下降，最终趋向于0

上面的分析有一个关键假设：基学习器的**误差相互独立**

现实任务中，个体学习器是为解决同一个问题训练出来的，显然不可能互相独立

个体学习器的“准确性”和“多样性”本身就存在冲突

如何产生“好而不同”的个体学习器是集成学习研究的核心

集成学习大致可分为两大类：

- 串行生成的序列化
- 同时生成的并行化

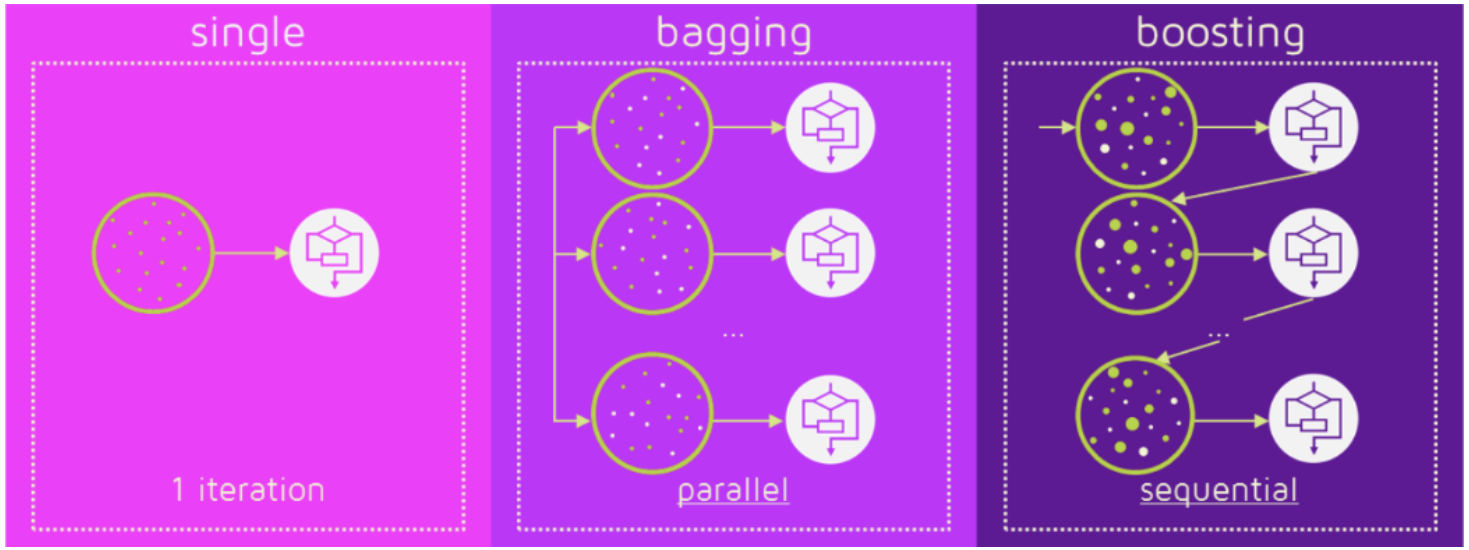

12.1 装袋 BAGGING

个体学习器不存在强依赖关系

并行化生成

自助采样法

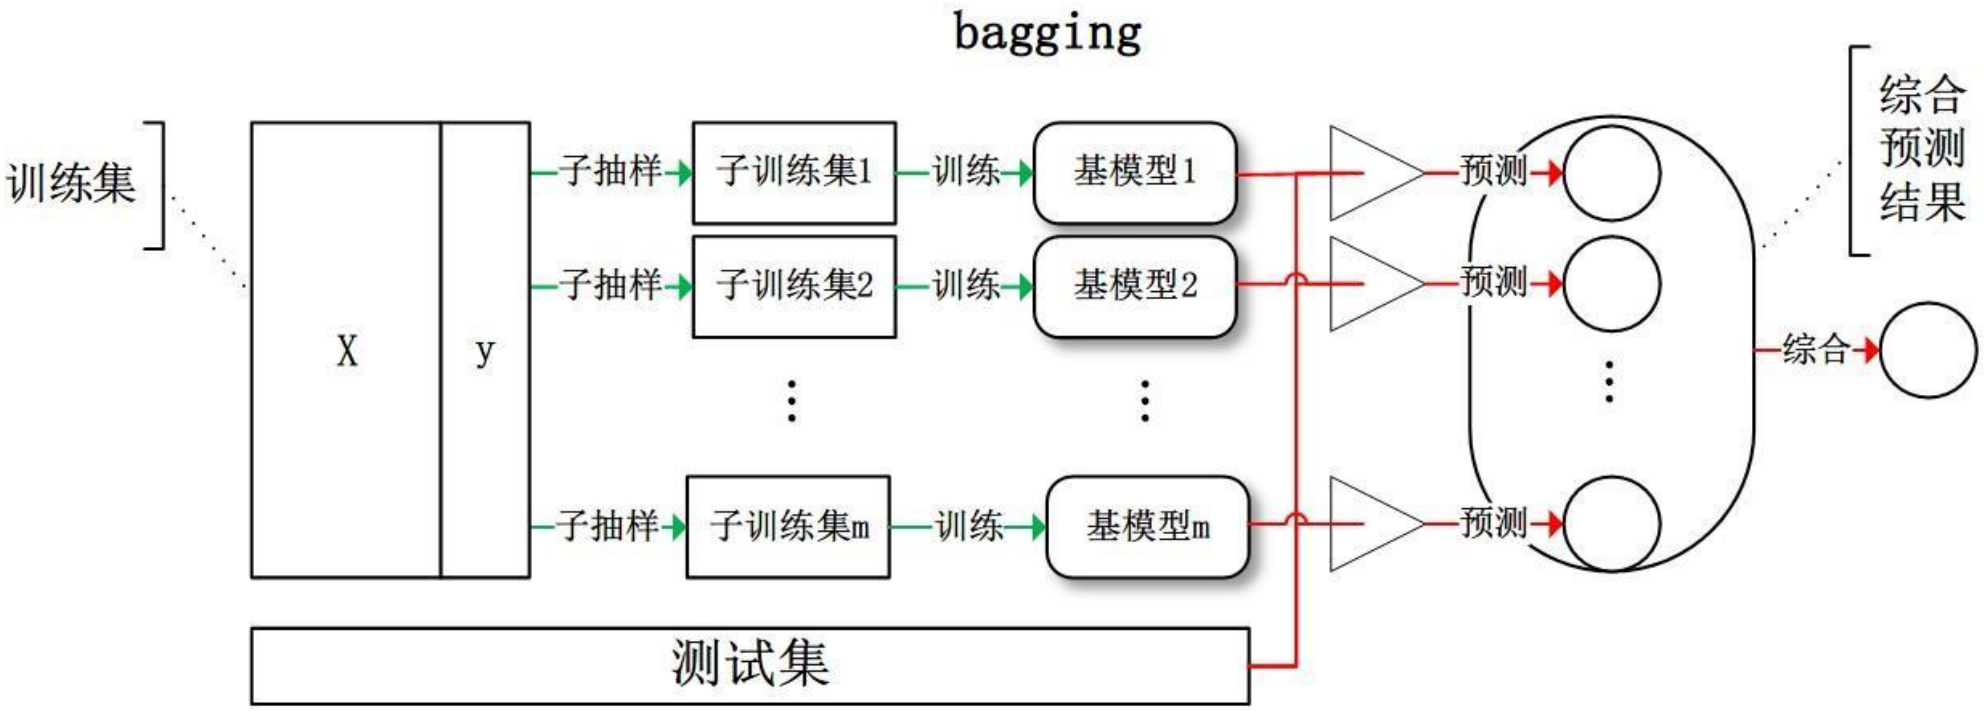

Bagging基本流程：

（1）采样出T个含m个训练样本的采样集，采用**自助采样法**：经过m次有放回随机采样操作得到含有m个样本的采样集。初始训练集中约有**63.2%**的样本出现在采样集中。重复操作，得到T个含m个训练样本的采样集；

（2）基于每个采样集训练出一个基学习器；

（3）将这些基学习器进行结合（分类任务使用简单投票，回归任务使用简单平均法）。

$$\lim_{m\mapsto\infty}\left(1-\frac{1}{m}\right)^m \mapsto \frac{1}{e} \approx 0.368$$

Bagging算法

输入: 训练集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$;
基学习算法 $\mathfrak{L}$;
训练轮数 T.

过程:

1: **for** $t = 1, 2, \ldots, T$ **do**
2: $\quad h_t = \mathfrak{L}(D, \mathcal{D}_{bs})$
3: **end for**

输出: $H(\boldsymbol{x}) = \arg\max_{y \in \mathcal{Y}} \sum_{t=1}^{T} \mathbb{I}(h_t(\boldsymbol{x}) = y)$

Bagging算法特点

时间复杂度低

- 假定基学习器的计算复杂度为O(m)，采样与投票/平均过程的复杂度为O(s)，则bagging的复杂度大致为T(O(m)+O(s))
- 由于O(s)很小且T是一个不大的常数
- 因此训练一个bagging集成与直接使用基学习器的复杂度同阶

可使用包外估计：每个基学习器只使用了初始训练集中约63.2%的样本，剩下约36.8%可用作验证集对泛化性能进行“包外估计”。

如何创建多棵树

使用bootstrapping，即有放回的随机抽样

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

如何创建多棵树

创建多个bootstrapped样本

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

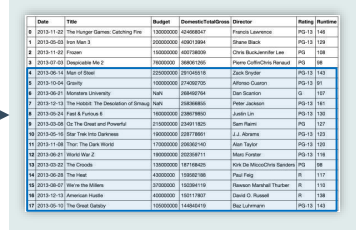

如何创建多棵树

使用每个bootstrapped样本构建一棵决策树

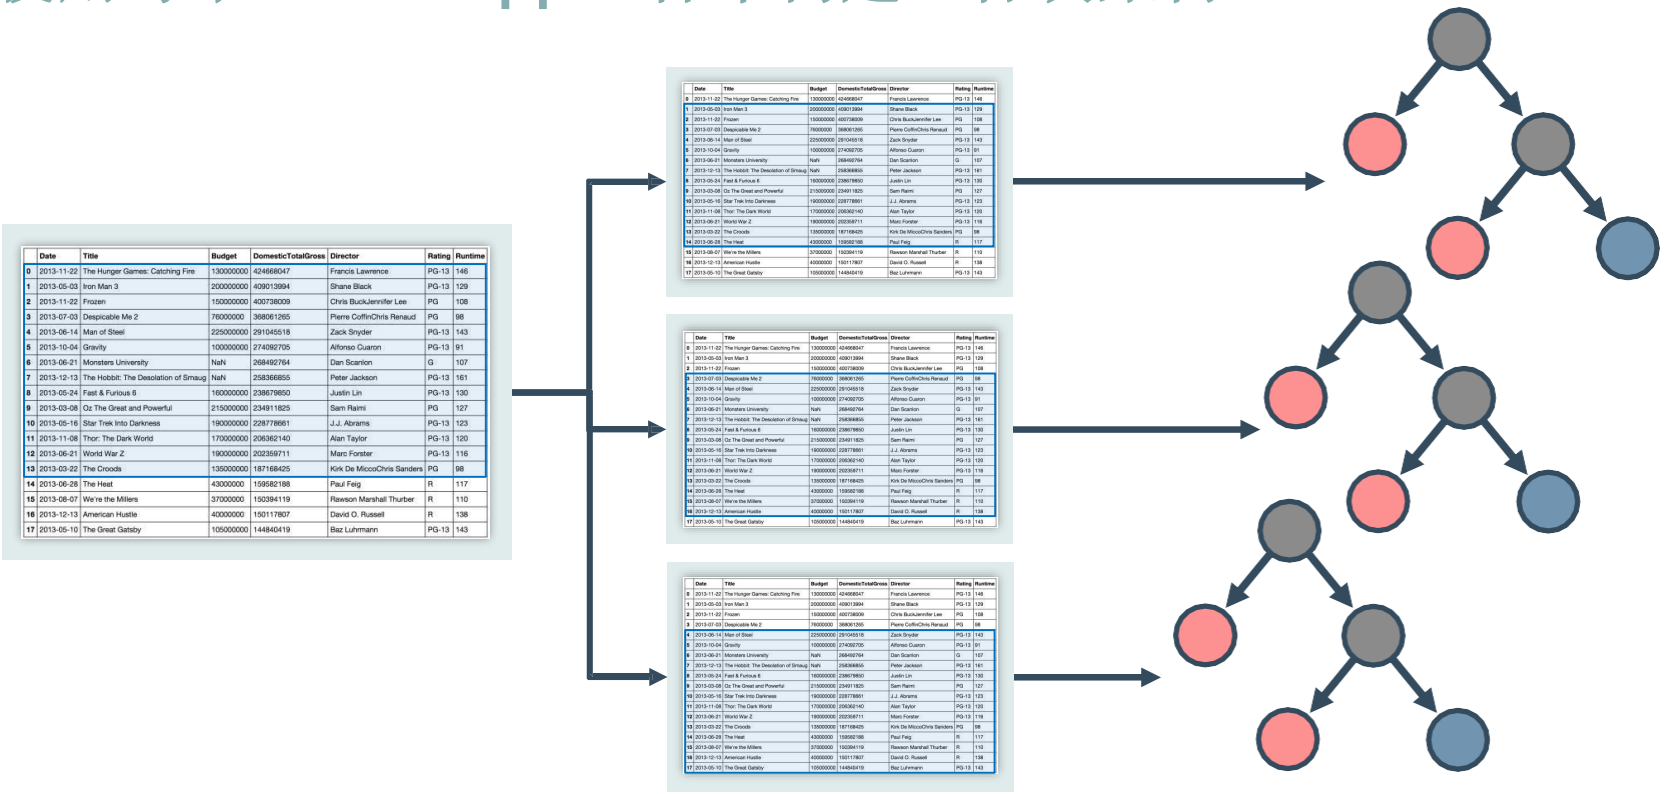

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

样本中的数据分布

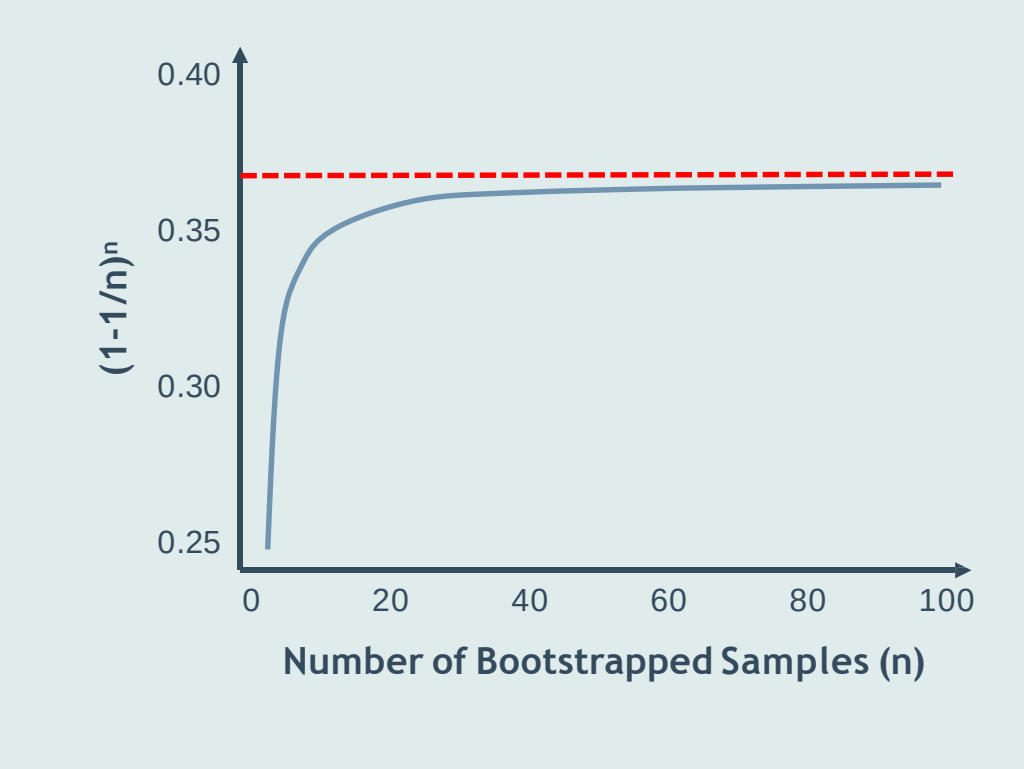

- 给定一个包含n条记录的数据集，创建n个bootstrapped样本
- 对于给定的一条记录 x,

$$P(rec\ x\ not\ selected) = (1 - {}^{1}/_{n})^{n}$$

- 每个bootstrapped样本包含大约2/3条记录

聚集结果

多棵树的结果通过**投票**或者取**平均**得到每个样例点的最终结果

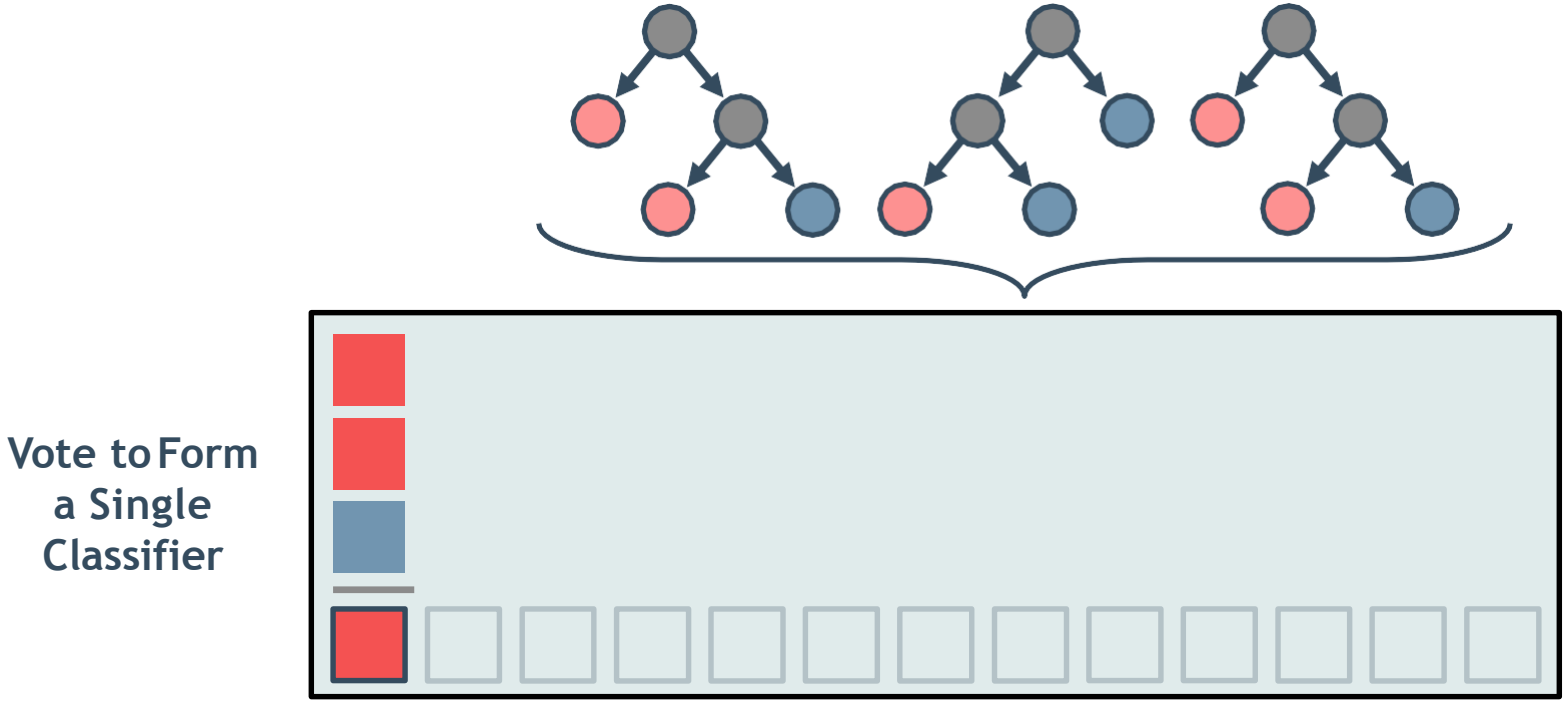

聚集结果

多棵树的结果通过**投票**或者取**平均**得到每个样例点的最终结果

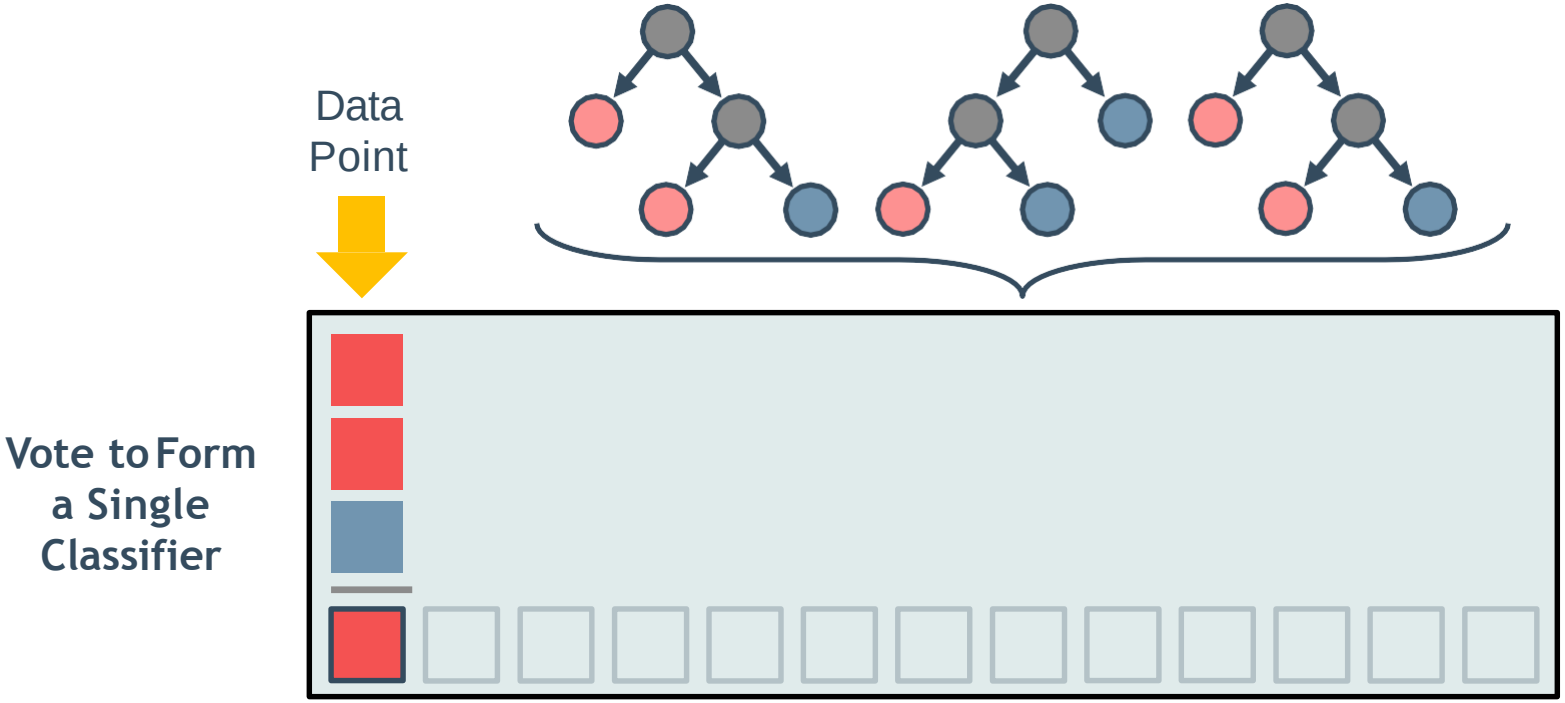

聚集结果

多棵树的结果通过**投票**或者取**平均**得到每个样例点的最终结果

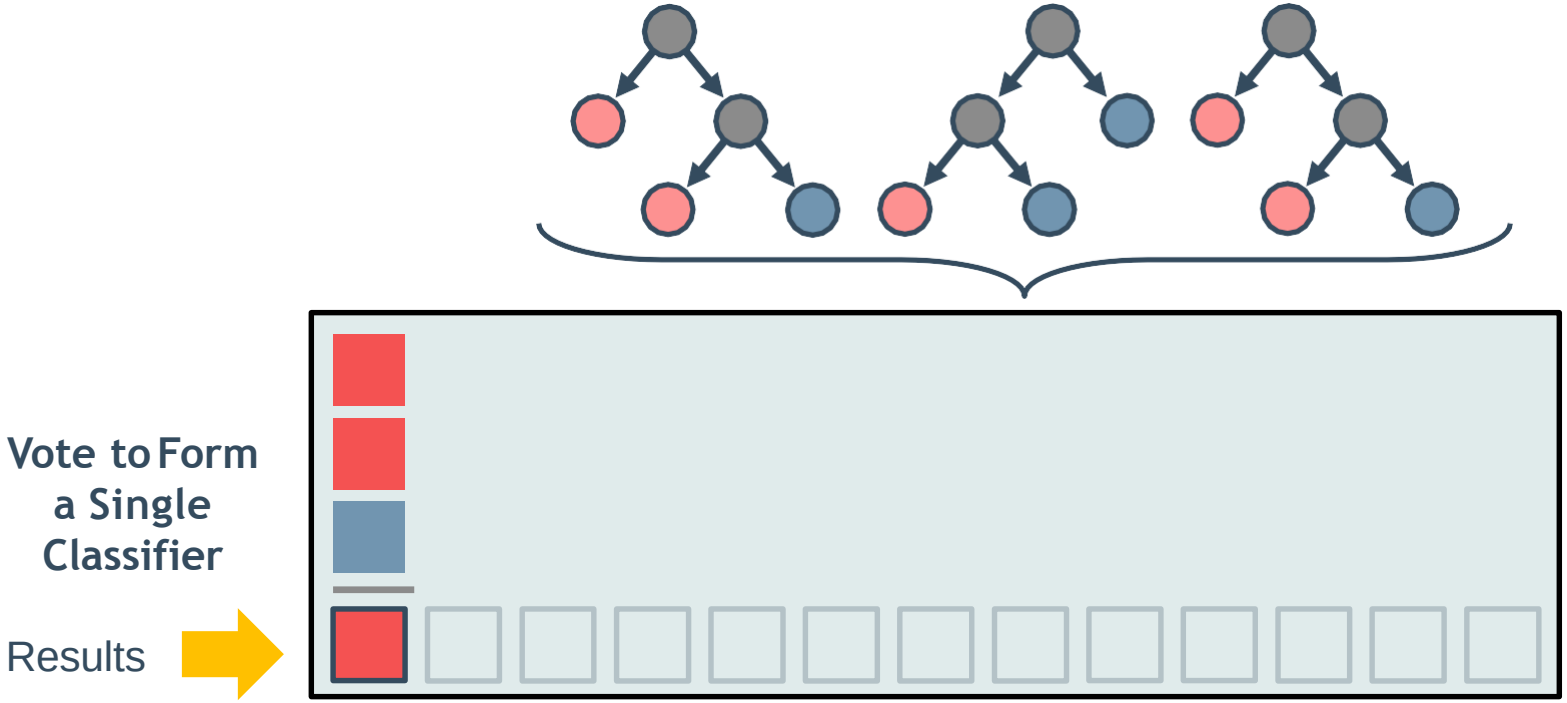

聚集结果

多棵树的结果通过**投票**或者取**平均**得到每个样例点的最终结果

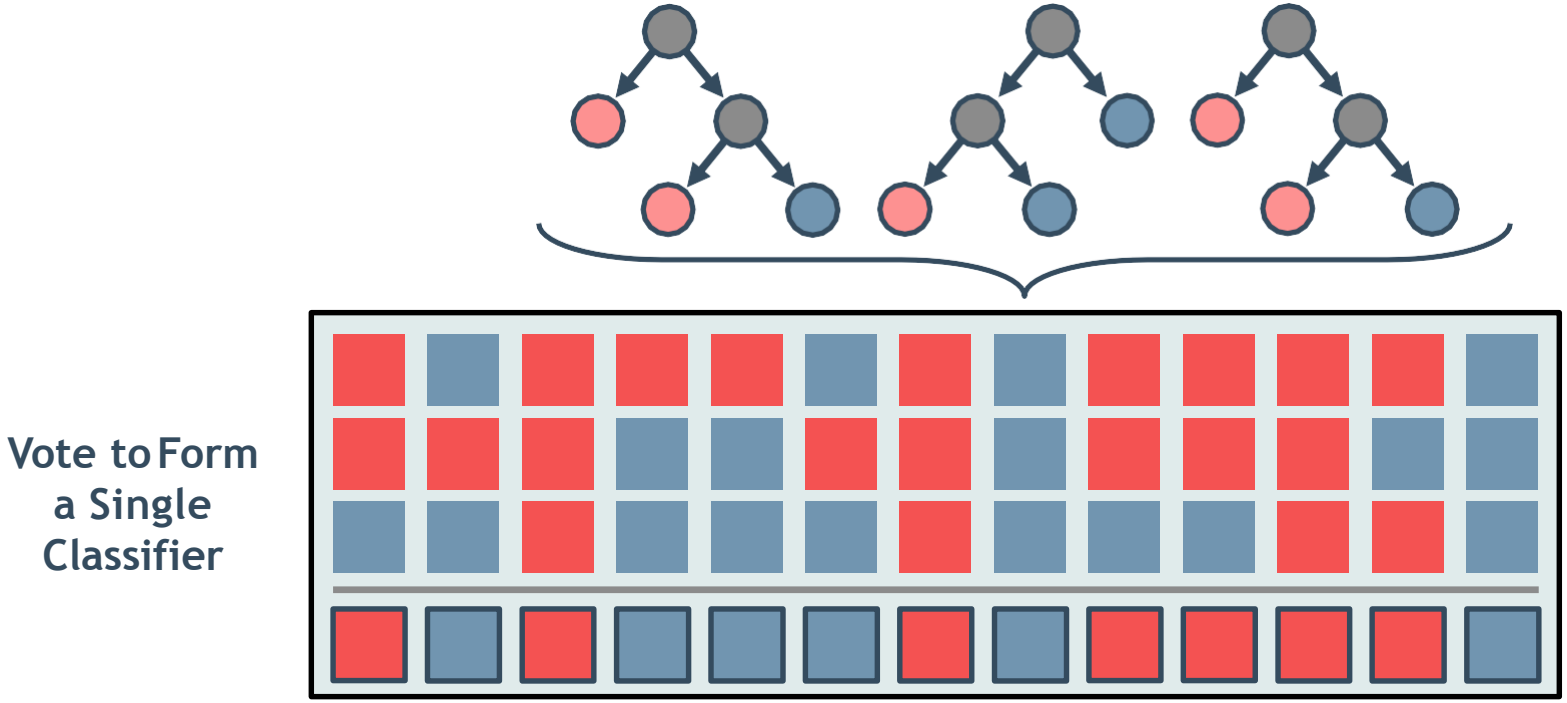

聚集结果

多棵树的结果通过**投票**或者取**平均**得到每个样例点的最终结果

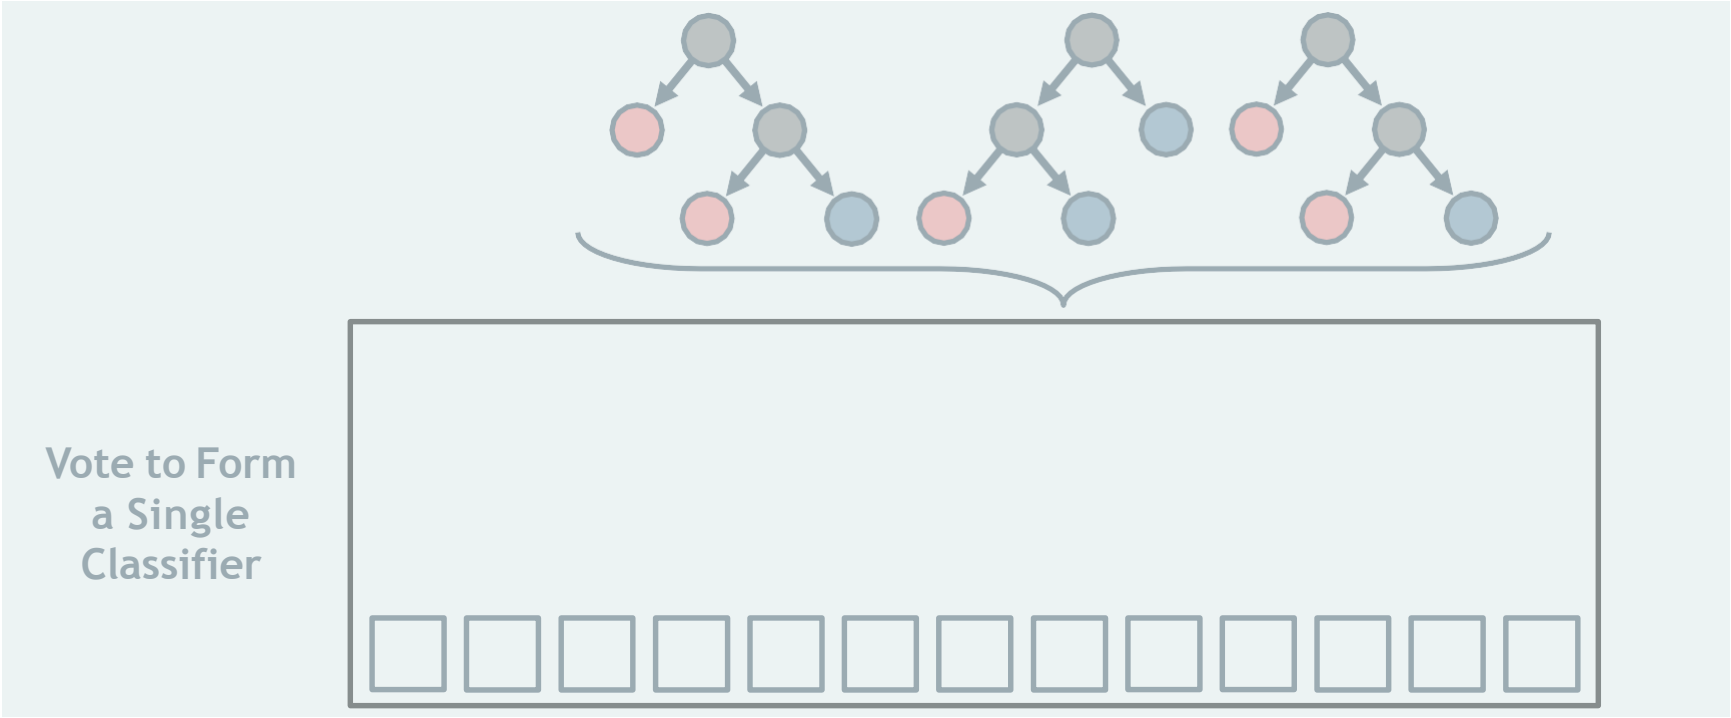

Bagging = BootstrapAggregating

Bagging集成学习

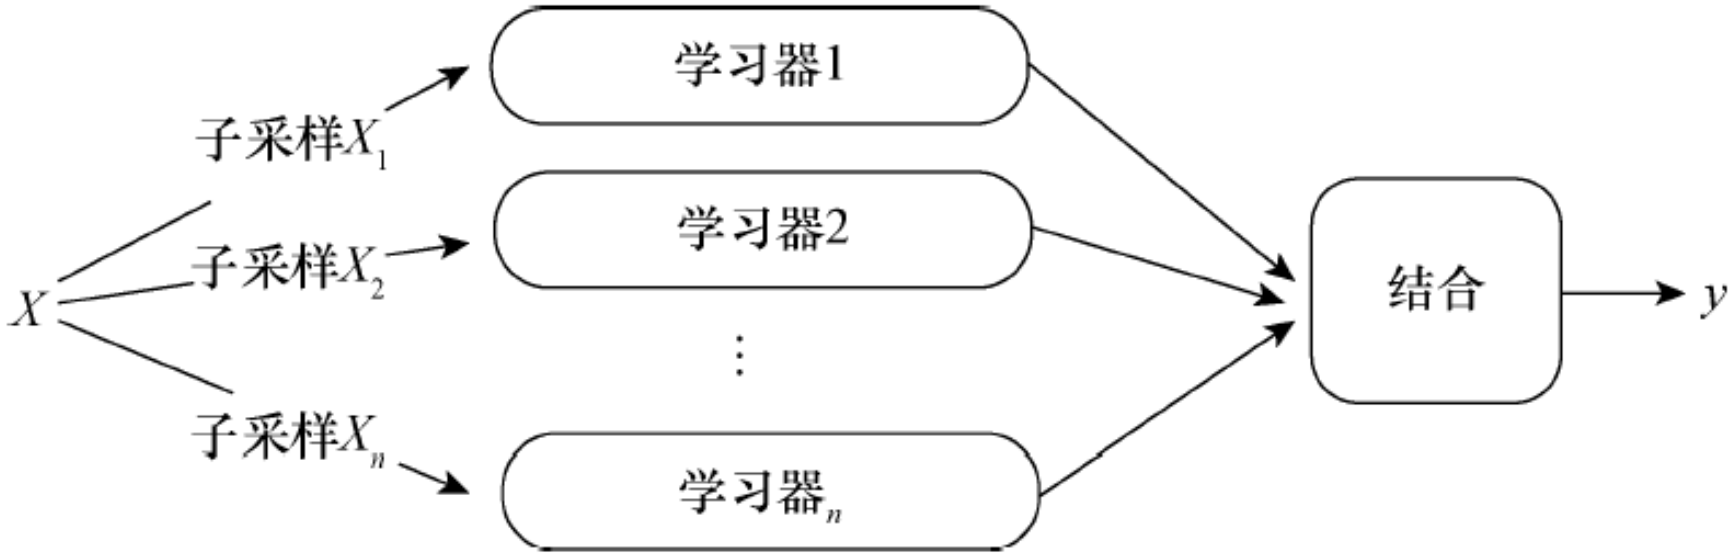

Bagging错误率的计算

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

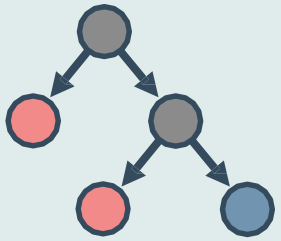

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

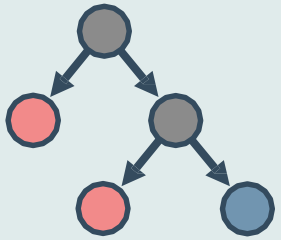

- bootstrapped样本为每棵决策树提供了内置的错误率估算
- 在数据子集上创建决策树
- 用未使用的样例来计算那棵树的错误率

Bagging错误率的计算

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

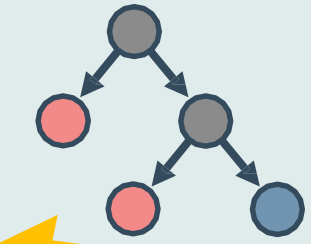

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

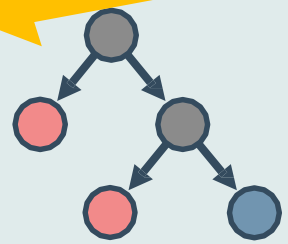

- bootstrapped样本为每棵决策树提供了内置的错误率估算
- 在数据子集上创建决策树
- 用未使用的样例来计算那棵树的错误率

Bagging错误率的计算

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

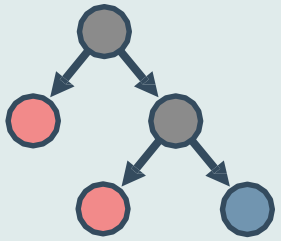

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

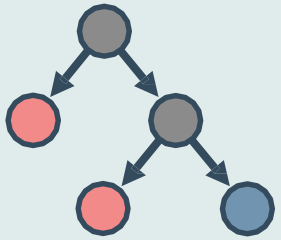

- bootstrapped样本为每棵决策树提供了内置的错误率估算
- 在数据子集上创建决策树
- 用未使用的样例来计算那棵树的错误率
- 称作“袋外（out-of-bag）”错误率

拟合多少棵树？

- Bagging模型的性能随着树的数目增大而改进
- 一般在大约50棵树时获得最大的改进

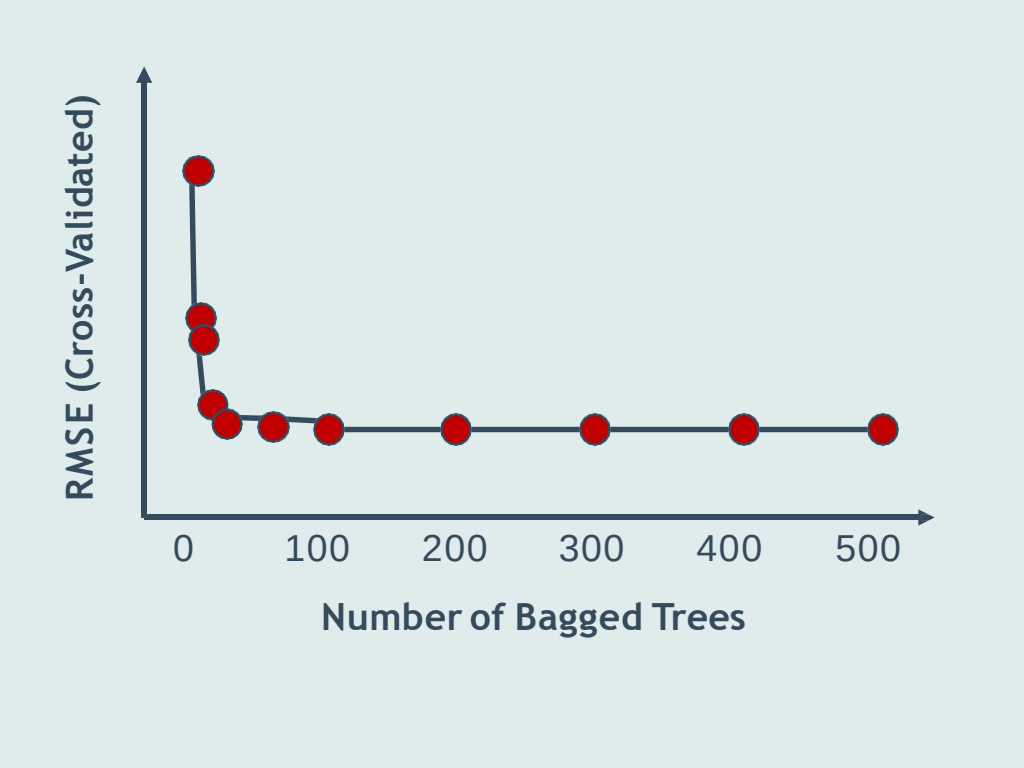

Bagging的优势

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

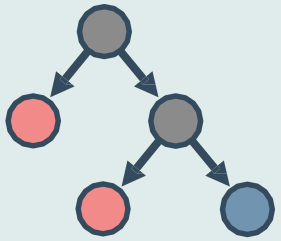

	Date	Title	Budget	DomesticTotalGross	Director	Rating	Runtime
0	2013-11-22	The Hunger Games: Catching Fire	130000000	424668047	Francis Lawrence	PG-13	146
1	2013-05-03	Iron Man 3	200000000	409013994	Shane Black	PG-13	129
2	2013-11-22	Frozen	150000000	400738009	Chris BuckJennifer Lee	PG	108
3	2013-07-03	Despicable Me 2	76000000	368061265	Pierre CoffinChris Renaud	PG	98
4	2013-06-14	Man of Steel	225000000	291045518	Zack Snyder	PG-13	143
5	2013-10-04	Gravity	100000000	274092705	Alfonso Cuaron	PG-13	91
6	2013-06-21	Monsters University	NaN	268492764	Dan Scanlon	G	107
7	2013-12-13	The Hobbit: The Desolation of Smaug	NaN	258366855	Peter Jackson	PG-13	161
8	2013-05-24	Fast & Furious 6	160000000	238679850	Justin Lin	PG-13	130
9	2013-03-08	Oz The Great and Powerful	215000000	234911825	Sam Raimi	PG	127
10	2013-05-16	Star Trek Into Darkness	190000000	228778661	J.J. Abrams	PG-13	123
11	2013-11-08	Thor: The Dark World	170000000	206362140	Alan Taylor	PG-13	120
12	2013-06-21	World War Z	190000000	202359711	Marc Forster	PG-13	116
13	2013-03-22	The Croods	135000000	187168425	Kirk De MiccoChris Sanders	PG	98
14	2013-06-28	The Heat	43000000	159582188	Paul Feig	R	117
15	2013-08-07	We're the Millers	37000000	150394119	Rawson Marshall Thurber	R	110
16	2013-12-13	American Hustle	40000000	150117807	David O. Russell	R	138
17	2013-05-10	The Great Gatsby	105000000	144840419	Baz Luhrmann	PG-13	143

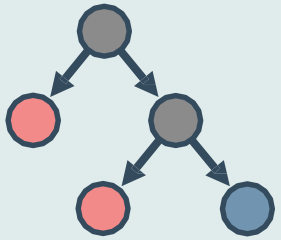

同决策树：

- 易于解释和实现
- 输入数据可以是异构的，不要求预处理

特有的：

- 比决策树的方差低
- 可以并行地构建多棵树

Bagging分类器的语法

导入包含分类方法的类：

```
from sklearn.ensemble import BaggingClassifier
```

创建该类的一个对象：

```
BC = BaggingClassifier(n_estimators=50)
```

拟合训练数据，并预测：

```
BC = BC.fit(X_train, y_train)
y_predict = BC.predict(X_test)
```

使用交叉验证调参。回归用**BaggingRegressor**。

http://scikit-learn.org/stable/modules/generated/sklearn.ensemble.BaggingClassifier.html

BaggingClassifier参数设置

base_estimator	基学习器 在采样得到的数据子集上训练的基学习器。 缺省值是None。等于None时，则使用决策树做基学习器。
n_estimators	基学习器个数 用于集成的基学习器的个数。 缺省值是10。
max_samples	最大样例个数 从训练集中随机抽取的，用于训练每个基学习器的样例数目。 缺省值是1.0。整数值表示抽取样例的个数；小数值表示抽取样例数占训练集的总样例数的比。
max_features	最大特征数 从训练集中随机抽取的，用于训练每个基学习器的特征数目。 缺省值是1.0。整数值表示抽取特征的个数；小数值表示抽取特征数占训练集的总特征数的比。

引入更多的随机性

- 解决方案：进一步消除树之间的相关性
- 每棵树使用一组随机抽取的特征：
  - 分类：$\sqrt{m}$
  - 回归：$m/3$

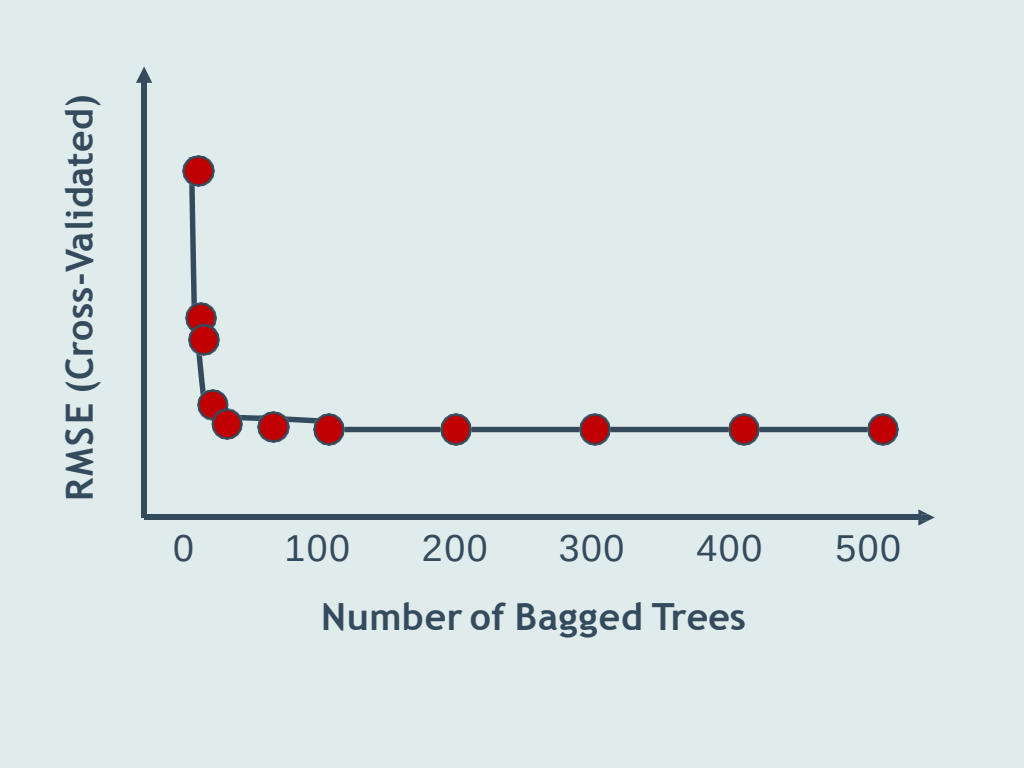

引入更多的随机性

- 解决方案：进一步消除树之间的相关性
- 每棵树使用一组随机抽取的特征：
  - 分类：$\sqrt{m}$
  - 回归：$m/3$
- 称作“随机森林”

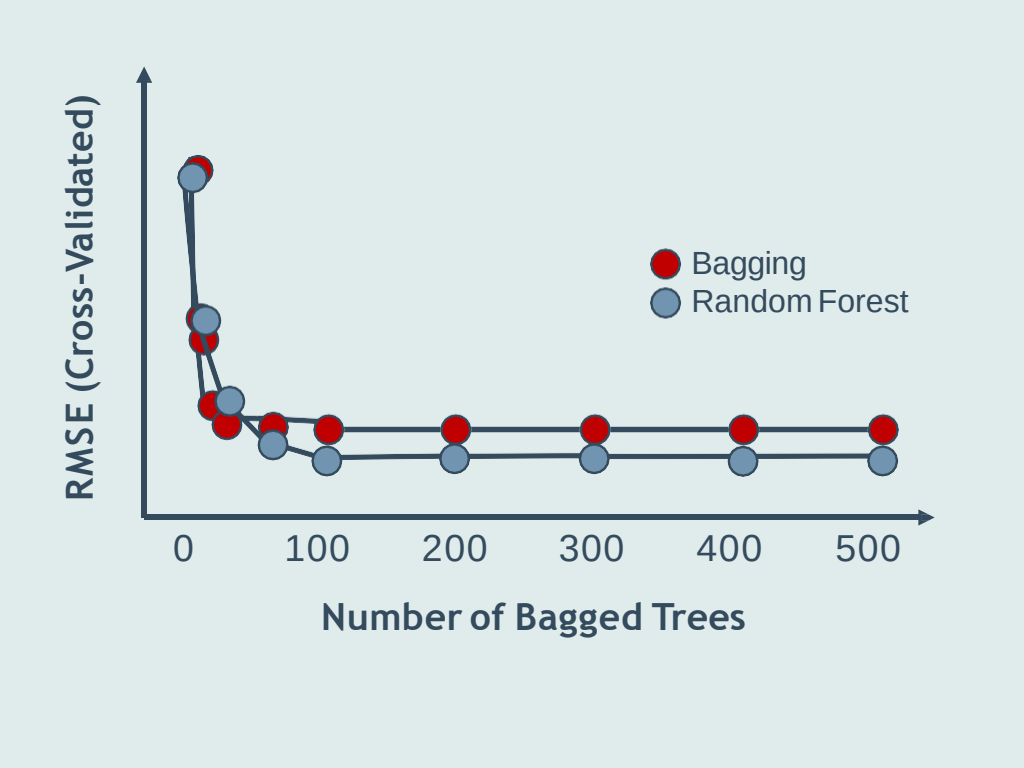

随机森林

随机森林(Random Forest，简称RF)是bagging的一个扩展变种

- 采样的随机性
- 属性选择的随机性

随机森林多少棵树？

- 相对于Bagging，随机森林的错误率会进一步降低。
- 增加足够的树直到错误率不再变化为止
- 新增加树不会改善结果了。

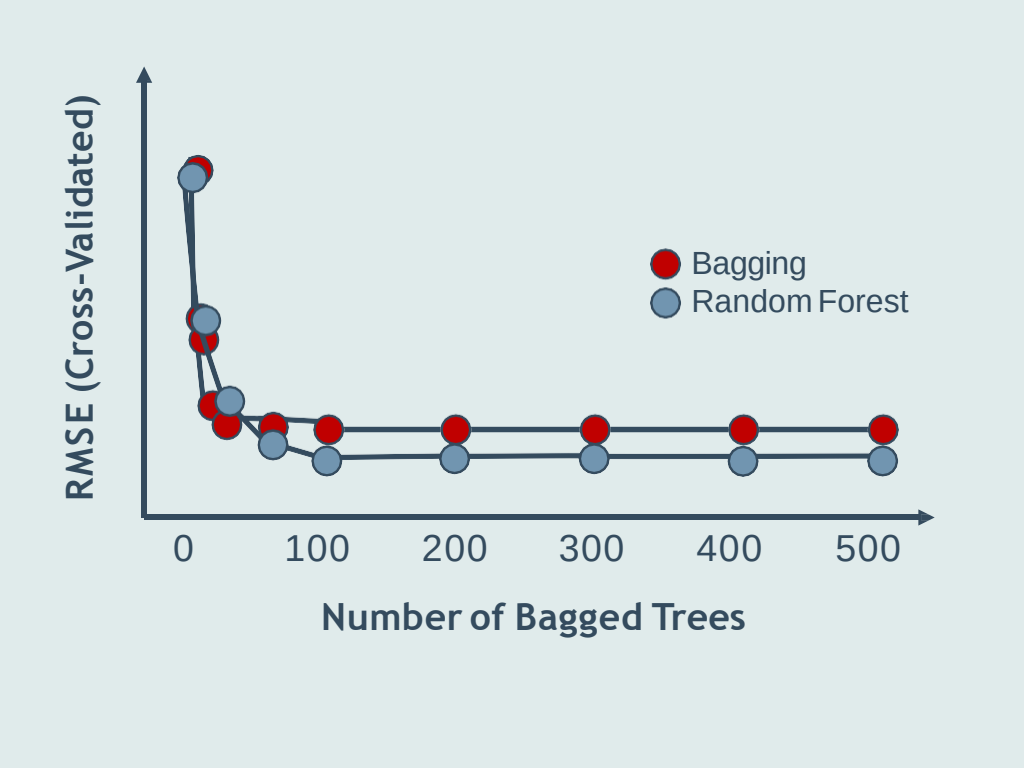

随机森林的语法

导入包含分类方法的类：

```
from sklearn.ensemble import RandomForestClassifier
```

创建该类的一个对象：

```
RC = RandomForestClassifier(n_estimators=100, max_features=10)
```

拟合训练数据，并预测：

```
RC = RC.fit(X_train, y_train)
y_predict = RC.predict(X_test)
```

使用交叉验证调参数。回归用**RandomForestRegressor**。

http://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html

随机森林参数设置

n_estimators	基学习器个数，森林中树的个数。 缺省值是10。
criterion	分裂条件选择标准 RandomForestClassifier的缺省值是“gini”，即用基尼指数作为衡量指标，也可以是“entropy”，即使用熵作为衡量指标； RandomForestRegressor的缺省值是“mse”，即使用均方差作为衡量指标，也可以是“mae”，即使用平均绝对值误差作为衡量指标。
max_features	选择分裂条件时考虑的最大特征数 有以下多种可能的取值： ● 整数，即可考虑的特征的最多个数； ● 小数，即可考虑的特征的最多个数占总的特征数的比例； ● “auto”，即最多考虑（√总的特征数）个特征； ● “log2”，即最多考虑（$\log_2$ 总的特征数）个特征； ● “sqrt”，即最多考虑（√总的特征数）个特征； 缺省值是“auto”。 直到找到一个有效的分裂为止，即使需要考虑多于max_features个特征。
max_depth	决策树的最大深度 缺省值是None。如果为None，则节点会一直分裂下去直到每个叶子节点都纯了或者叶子节点包含的样例个数少于min_samples_split。

引入更多的随机性

- 有时需要比随机森林更多的随机性
- 解决方案：随机选择特征，并创建**随机划分**---即不使用贪婪划分
- 称作“超随机森林”

超随机森林分类器的语法

导入包含分类方法的类：

```
from sklearn.ensemble import ExtraTreesClassifier
```

创建该类的一个对象：

```
EC = ExtraTreesClassifier(n_estimators=100, max_features=10)
```

拟合训练数据，并预测：

```
EC = EC.fit(X_train, y_train)
y_predict = EC.predict(X_test)
```

使用交叉验证调参。回归用**ExtraTreesRegressor**。

http://scikit-learn.org/stable/modules/generated/sklearn.ensemble.ExtraTreesClassifier.html

12.2 提升 BOOSTING

起源

PAC（Probably Approximately Correct）学习框架

- Valiant & Kearns (1984)
  - 弱可学习
  - 强可学习
- Valiant & Kearns (1989)
  - 证明了弱可学习和强可学习的等价性
- Schapire (1990)
  - 第一次提出一个多项式时间的Boosting算法
- Freund (1991)
  - 提出一种效率更高的Boosting算法
- Freund & Schapire (1995)
  - 提出**AdaBoost**（Adaptive Boosting）算法
- Friedman (1999)
  - 提出**梯度提升**（Gradient Boosting）算法

Boosting

1. 先从初始训练集训练出一个基学习器。
2. 再根据基学习器的表现对训练样本分布进行调整，使得先前基学习器做错的训练样本在后续受到更多关注。
3. 然后基于调整后的样本分布来训练下一个基学习器。
4. 重复2，3步，直到基学习器的数目达到事先指定的值T。
5. 最后将T个基学习器进行加权结合。

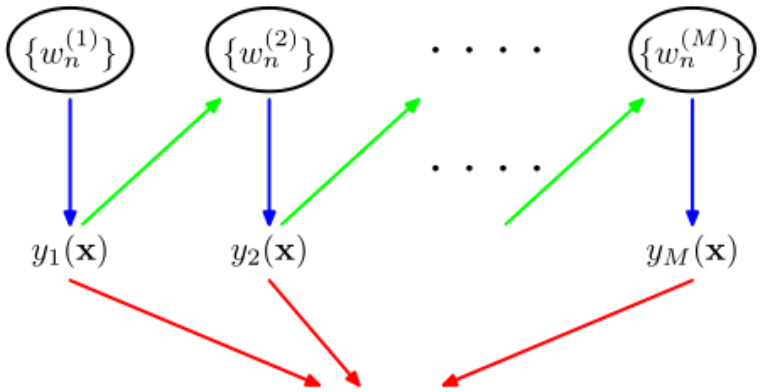

$$Y_M(\mathbf{x}) = \text{sign}\left(\sum_m^M \alpha_m y_m(\mathbf{x})\right)$$

个体学习器存在强依赖关系

串行生成

每次调整训练数据的样本分布

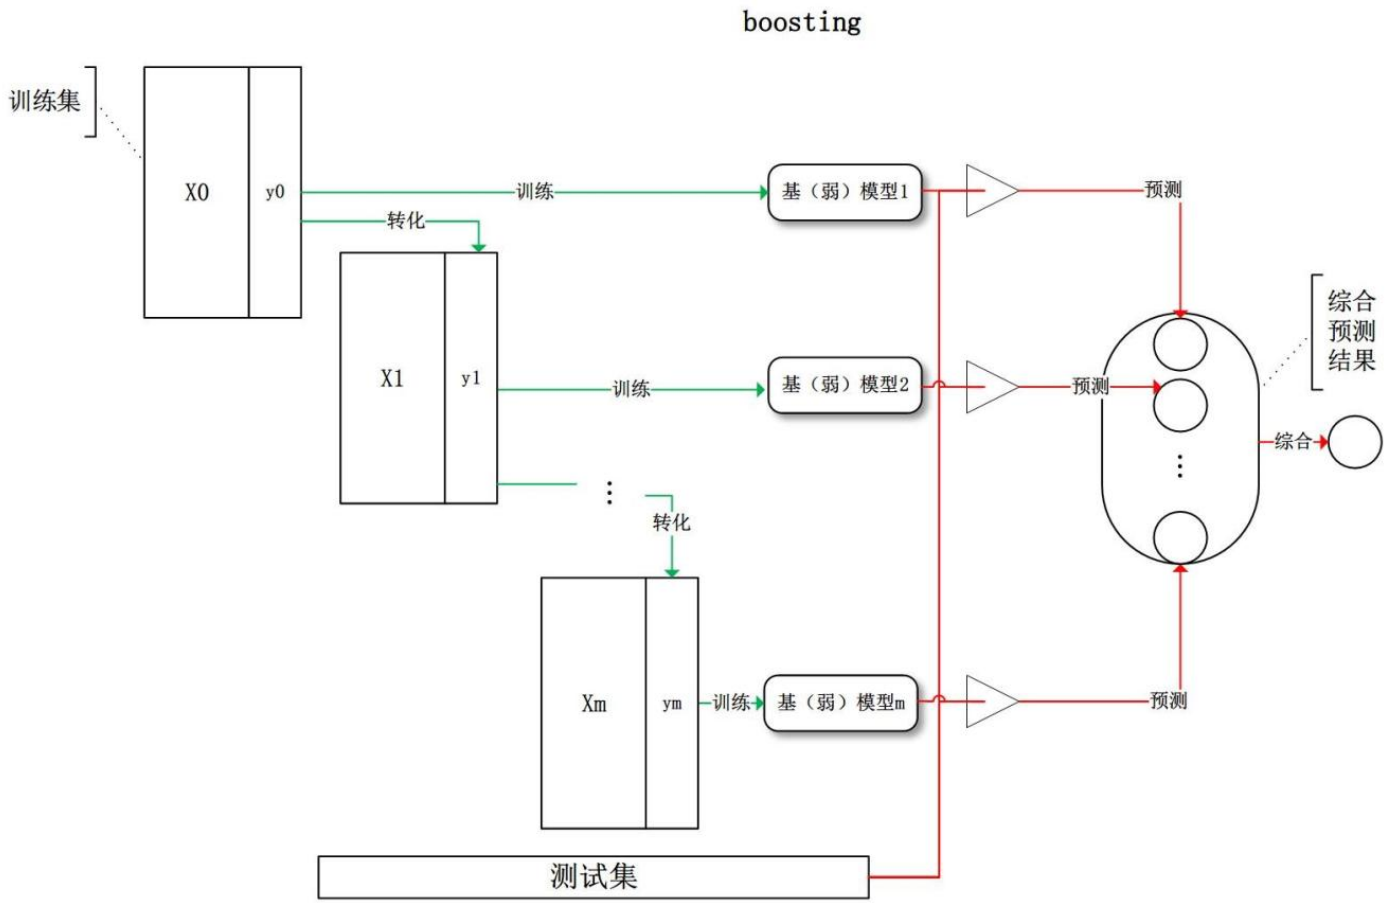

决策树桩：Boosting算法的基学习器

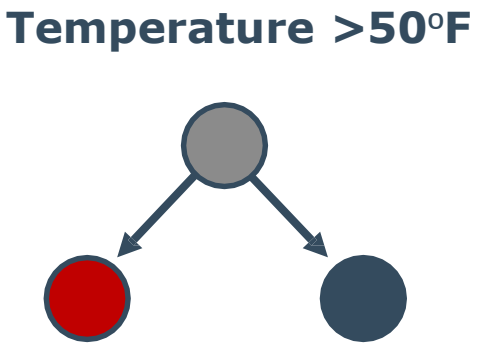

决策树桩：Boosting算法的基学习器

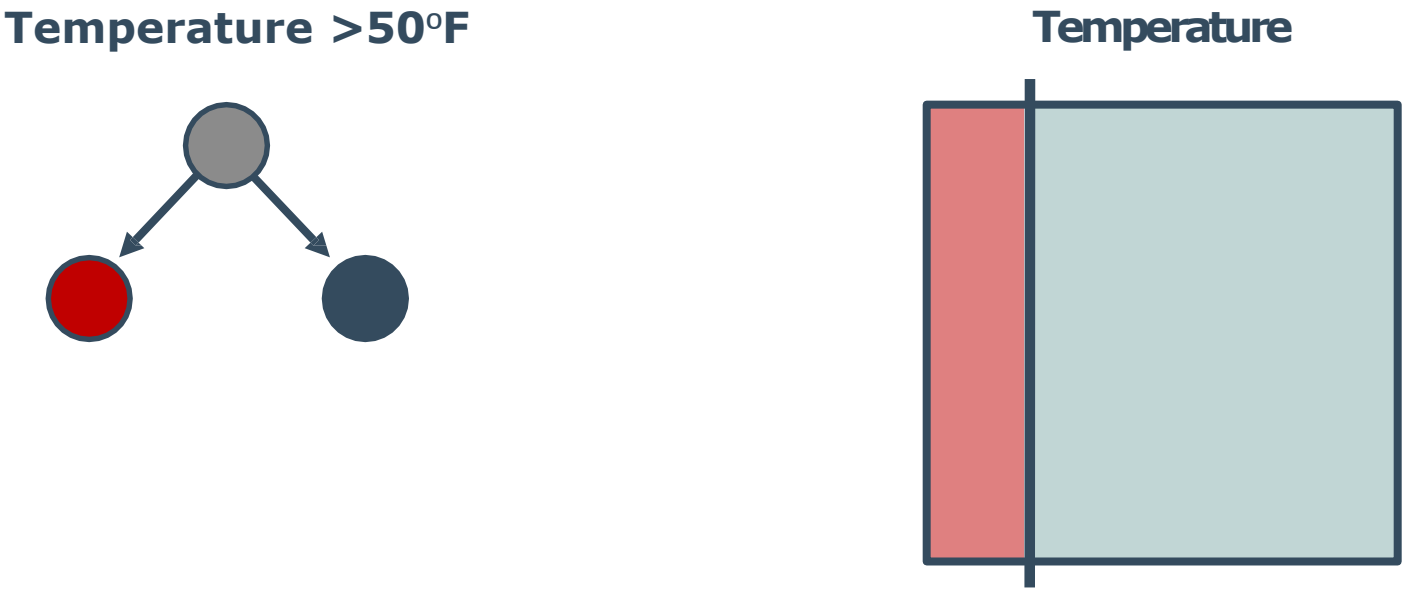

决策树桩：Boosting算法的基学习器

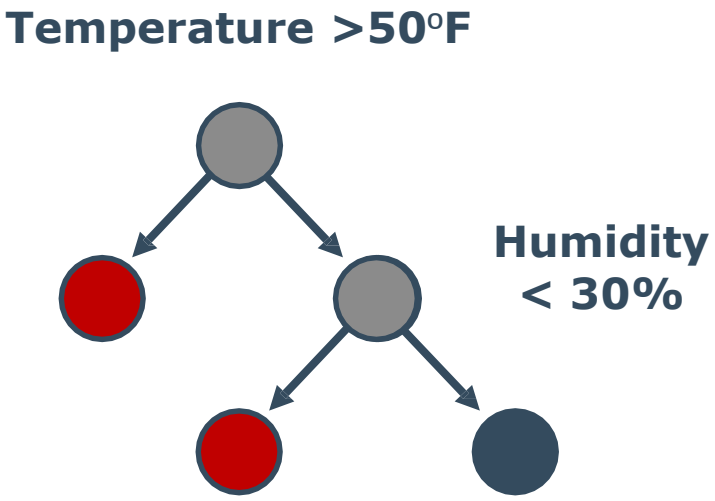

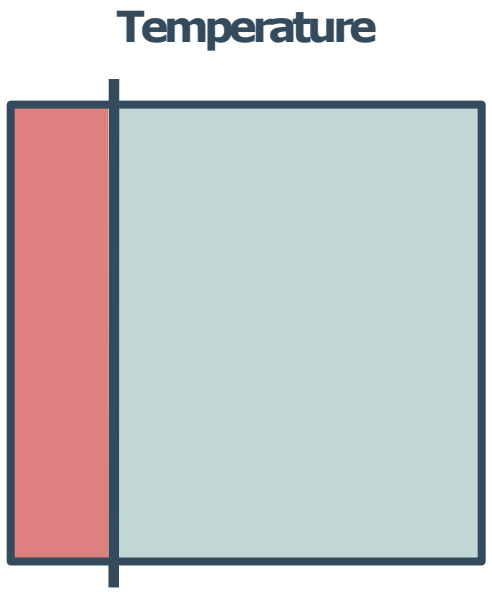

决策树桩：Boosting算法的基学习器

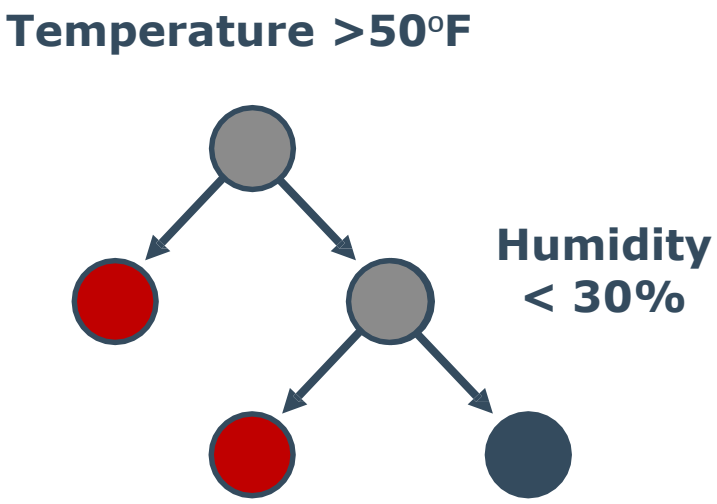

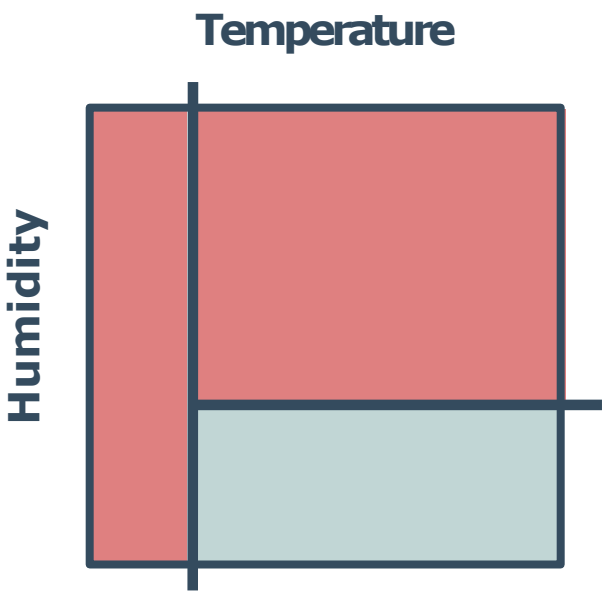

Boosting概述

创建初始的决策树桩

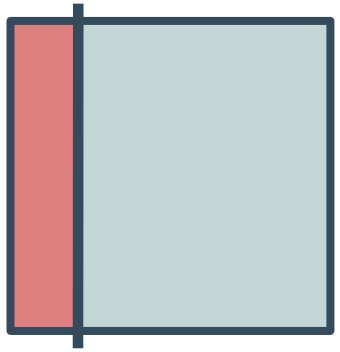

Boosting概述

拟合数据并计算残差

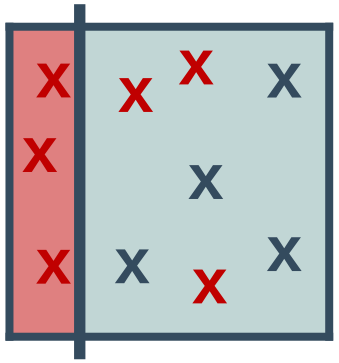

Boosting概述

调整样例
点的权重

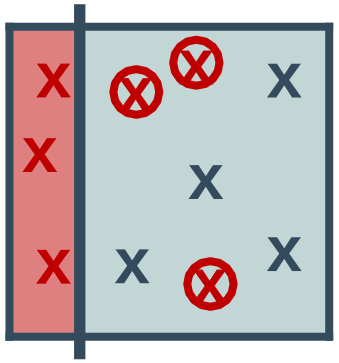

Boosting概述

发现新的
决策树桩
来拟合加
权残差

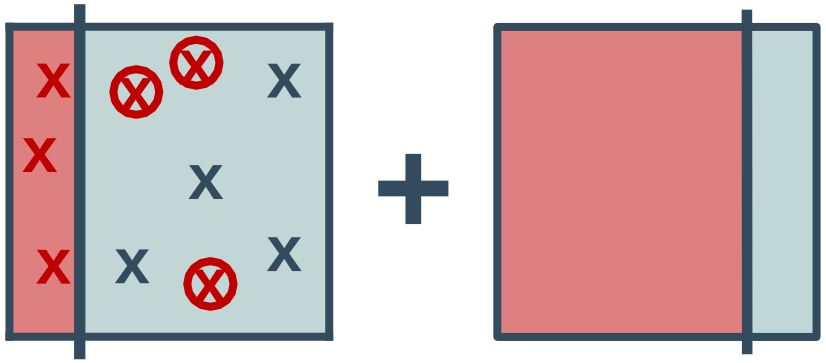

Boosting概述

用新的决策树桩来拟合当前残差

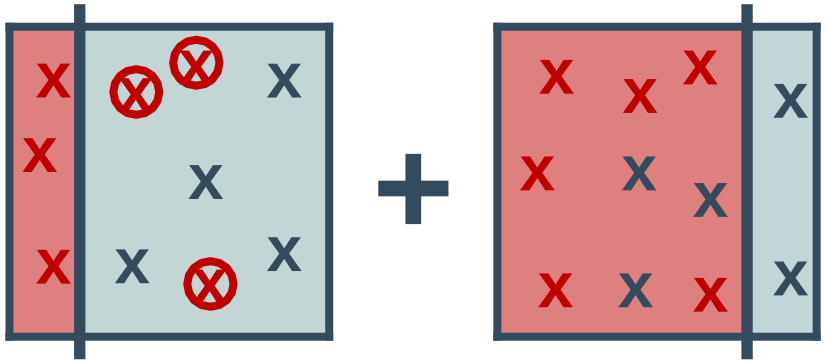

Boosting概述

计算误差，并修改数据点的权重

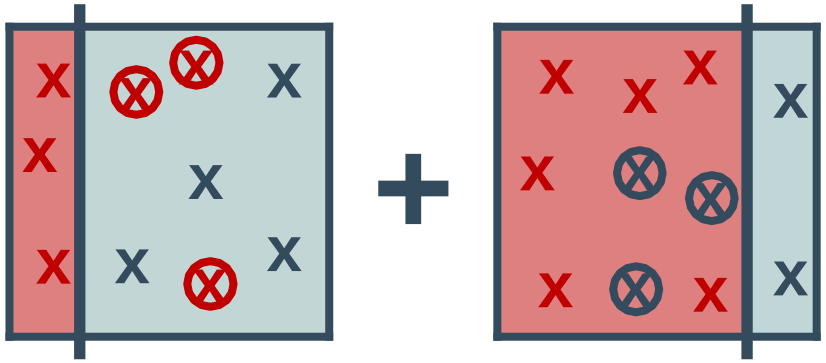

Boosting概述

发现新的
决策树桩
来拟合加
权残差

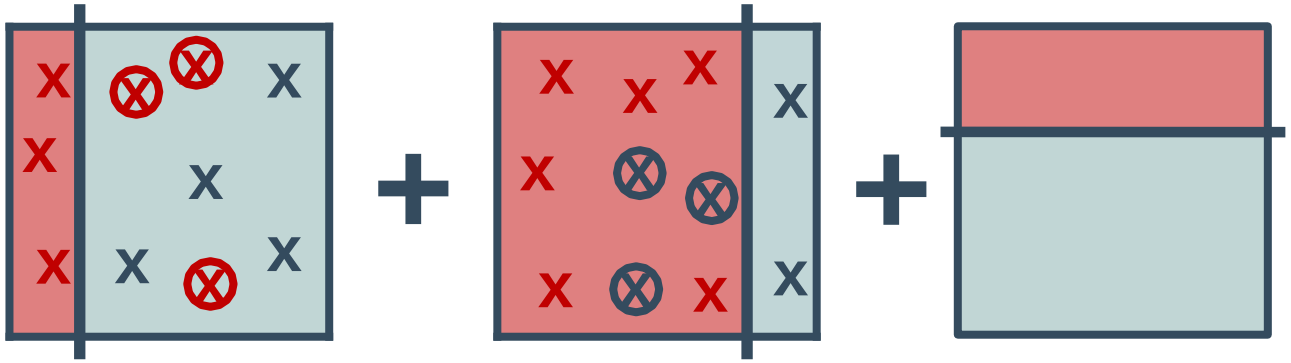

Boosting概述

用新的决策树桩来拟合当前残差

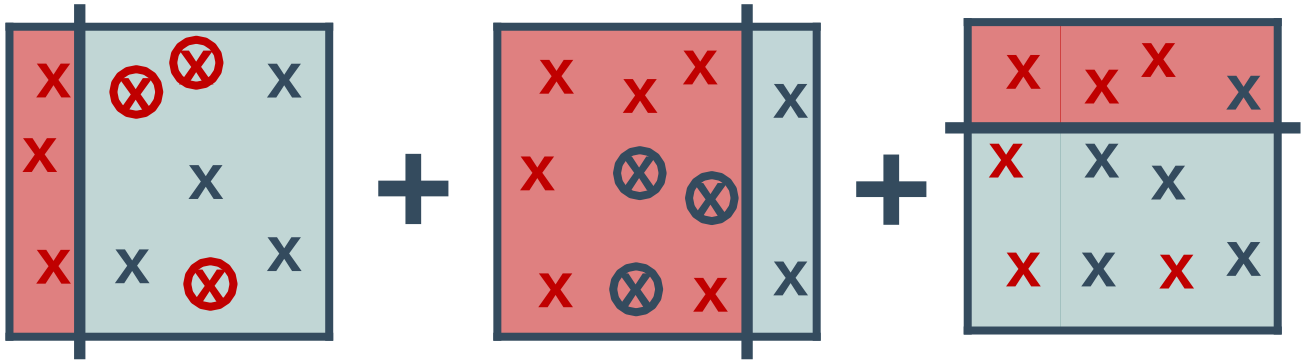

Boosting概述

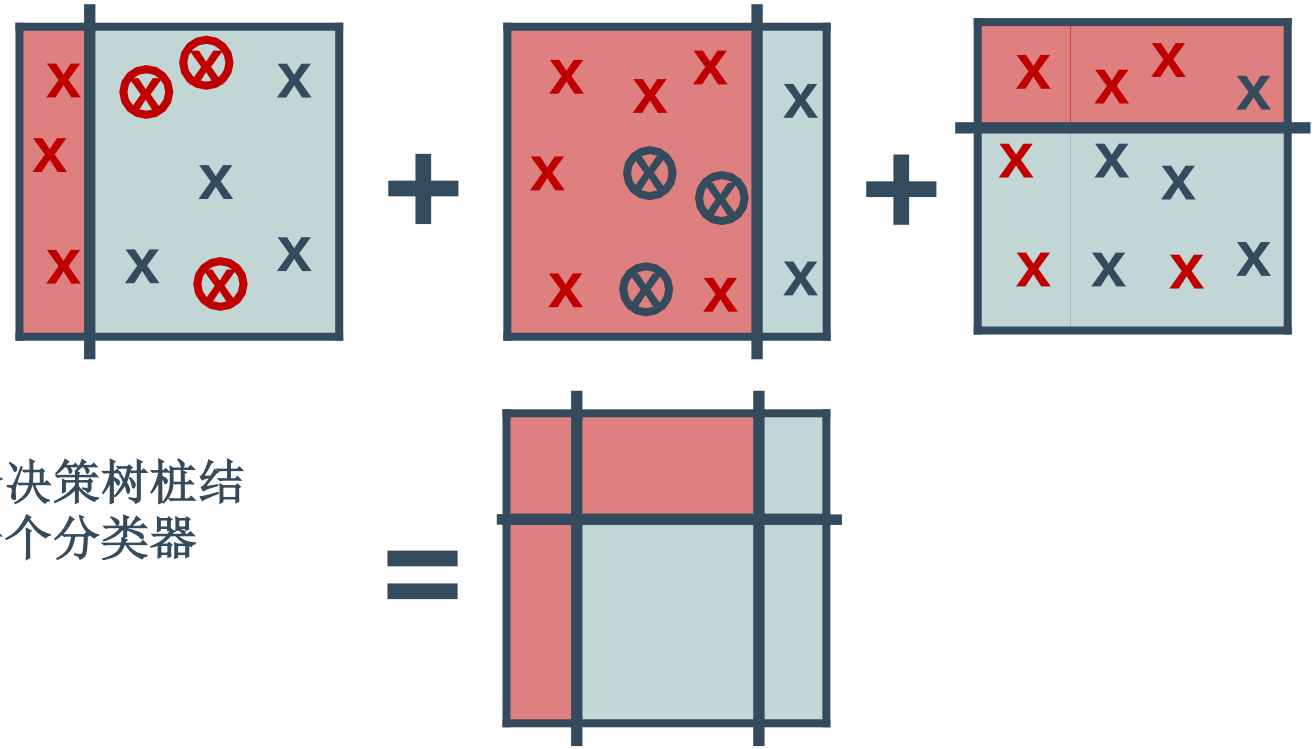

将多个决策树桩结
合成一个分类器

Boosting概述

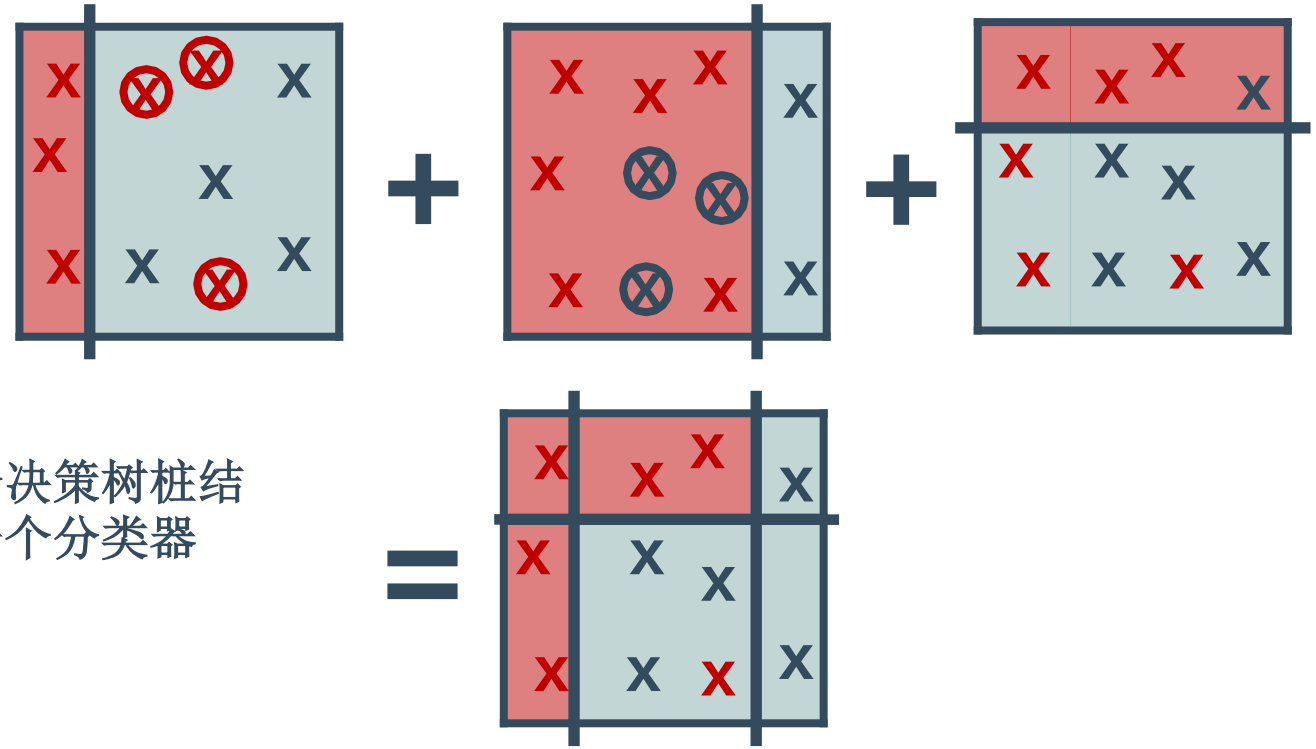

将多个决策树桩结
合成一个分类器

Boosting概述

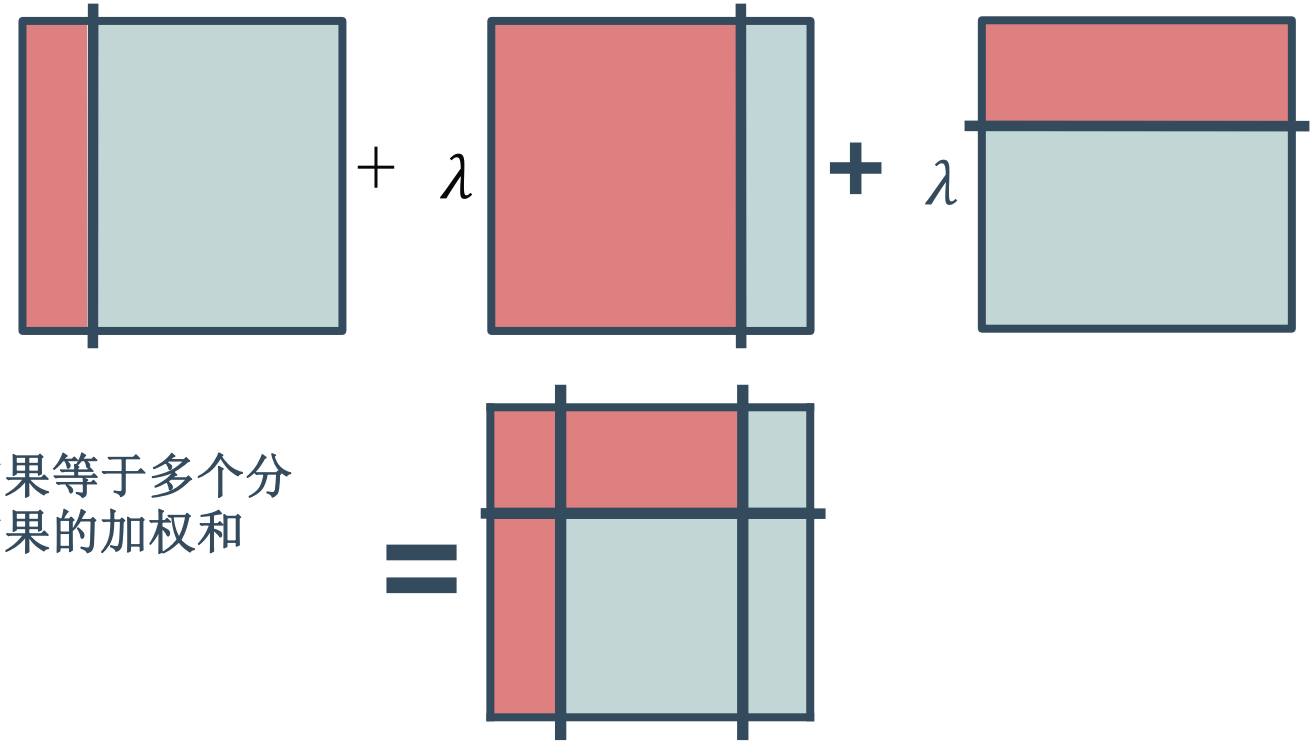

预测结果等于多个分类器结果的加权和

Boosting概述

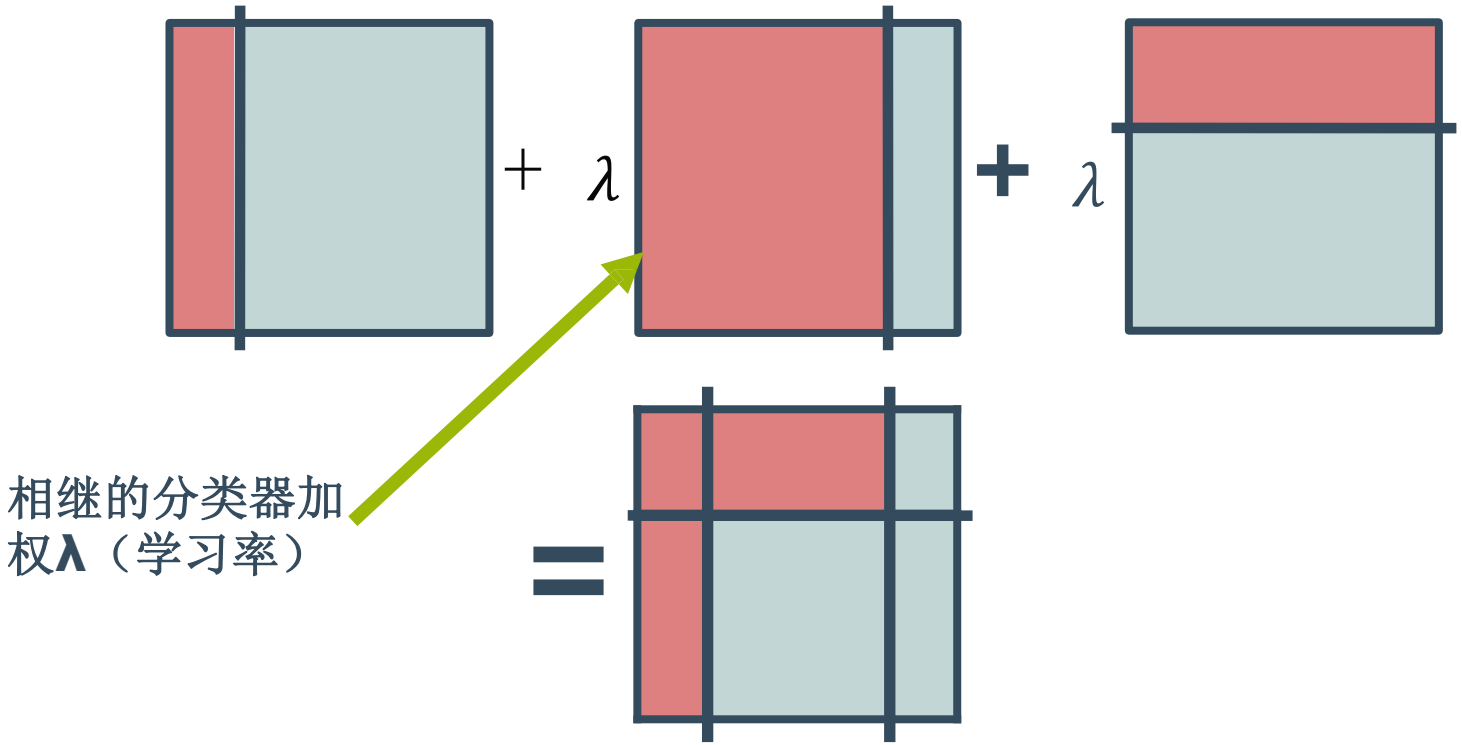

AdaBoost伪码

1. 给定包含n个样本的训练集 $\{x_1, x_2, \cdots, x_n\}$，初始化每个样本的权重$w_i = 1/n$。
2. 分别设$m = 1, 2, \cdots, M$，重复下面的步骤：
    1. 在当前训练集上训练一个弱学习器：$C^{(m)}$
    2. 用训练出的弱学习器预测训练集中每个样例的类别：$C^{(m)}(x_i)$；
    3. 计算该弱学习器的加权错误率：

$$err^{(m)} = \frac{\sum_{i=1}^{n} w_i \, \mathbf{I}(C^{(m)}(x_i) \neq y_i)}{\sum_{i=1}^{n} w_i}$$

    其中$\mathbf{I}(C^{(m)}(x_i) \neq y_i)$是指示函数，当$C^{(m)}(x_i) \neq y_i$成立时，值为1，否则为0。

    4. 计算该弱学习器的权重值：

$$\alpha^{(m)} = \eta \log \frac{(1 - err^{(m)})}{err^{(m)}}$$

    其中η是学习率。

    5. 修改训练集中每个样例的权重：$w_i = w_i \exp\left(\alpha^{(m)} \mathbf{I}(C^{(m)}(x_i) \neq y_i)\right)$，$i=1, 2, \cdots, n$
    6. 归一化w_i：$w_i = w_i / \sum_{i=1}^{n} w_i$
3. 将M个训练好的弱学习器用加权投票法结合起来，得到最终的集成学习器C：

$$C(x) = \underset{k}{\operatorname{argmax}} \sum_{m=1}^{M} \alpha^{(m)} \, \mathbf{I}(C^{(m)}(x) = k)$$

AdaBoost分类器的语法

导入包含分类方法的类：

```
from sklearn.ensemble import AdaBoostClassifier
from sklearn.tree import DecisionTreeClassifier
```

基学习器可以被手工设置

创建该类的一个对象：

```
ABC = AdaBoostClassifier(base_estimator=DecisionTreeClassifier(),
        learning_rate=0.1, n_estimators=200)
```

AdaBoost分类器的语法

导入包含分类方法的类：

```
from sklearn.ensemble import AdaBoostClassifier
from sklearn.tree import DecisionTreeClassifier
```

这里也可以设置最大深度

创建该类的一个对象：

```
ABC = AdaBoostClassifier(base_estimator=DecisionTreeClassifier(),
        learning_rate=0.1, n_estimators=200)
```

AdaBoost分类器的语法

导入包含该分类方法的类：

```
from sklearn.ensemble import AdaBoostClassifier
from sklearn.tree import DecisionTreeClassifier
```

创建该类的一个对象：

```
ABC = AdaBoostClassifier(base_estimator=DecisionTreeClassifier(),
        learning_rate=0.1, n_estimators=200)
```

拟合训练数据，并预测：

```
ABC = ABC.fit (X_train, y_train)

y_predict = ABC.predict(X_test)
```

使用交叉验证调节参数。回归用**AdaBoostRegressor**

http://scikit-learn.org/stable/modules/generated/sklearn.ensemble.AdaBoostClassifier.html

AdaBoost参数设置

base_estimator	基学习器 缺省是使用决策树做基学习器。要求基学习器支持样本加权。
n_estimators	基学习器个数 缺省值是50。集成的基学习器的最大个数。或者说算法的最大迭代次数，如果已经完美拟合数据了，则会提前停止。
learning_rate	学习率 缺省值是1.0。一般设为0到1之间的值，收缩每个基学习器对最终结果的贡献量，也即每个基学习器的权重缩减系数。它和n_estimators之间存在一个折衷，一起来决定算法的拟合效果。如果要达到一定的拟合效果，更小的学习率意味着要训练更多的弱学习器。
algorithm	AdaBoost分类算法（仅用于AdaBoostClassifier） 可能取值：“SAMME”或“SAMME.R”，缺省值是“SAMME.R”。 Scikit-Learn中实现的AdaBoost分类算法实际是一个被称作SAMME的多分类算法版本，当只有两个类别时，SAMME就等同于AdaBoost。如果基学习器可以估算类别概率值（即它们有一个predict_prob()方法），则可以使用SAMME的一个变体SAMME.R（R表示“real”，即实数），它基于类别概率值而不是类别标签来计算弱学习器的权重。通常它比SAMME算法收敛更快，且测试错误率更低，但要求基学习器必须支持类别概率值的计算。
loss	损失函数（仅用于AdaBoostRegressor） 可能取值：“linear”，“square”或“exponential”，缺省值是“linear”。 每一轮调整样本权重时需要用到的损失函数，用于计算每一轮训练出的弱学习器在训练集中每个样本上的预测值与真实值之间的误差，可以是线性误差，平方误差或指数误差。

AdaBoost算法

输入: 训练集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$;
基学习算法 $\mathfrak{L}$;
训练轮数 T.

过程:

$\mathcal{D}_1(\boldsymbol{x}) = 1/m$.
for $t = 1, 2, \ldots, T$ **do**
  $h_t = \mathfrak{L}(D, \mathcal{D}_t)$;
  $\epsilon_t = P_{\boldsymbol{x} \sim \mathcal{D}_t}(h_t(\boldsymbol{x}) \neq f(\boldsymbol{x}))$;
  if $\epsilon_t > 0.5$ **then break**
  $\alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right)$;
  $$\mathcal{D}_{t+1}(\boldsymbol{x}) = \frac{\mathcal{D}_t(\boldsymbol{x})}{Z_t} \times \begin{cases} \exp(-\alpha_t), & \text{if } h_t(\boldsymbol{x}) = f(\boldsymbol{x}) \\ \exp(\alpha_t), & \text{if } h_t(\boldsymbol{x}) \neq f(\boldsymbol{x}) \end{cases} = \frac{\mathcal{D}_t(\boldsymbol{x}) \exp(-\alpha_t f(\boldsymbol{x}) h_t(\boldsymbol{x}))}{Z_t}$$
end for

输出: $H(\boldsymbol{x}) = \operatorname{sign}\left(\sum_{t=1}^{T} \alpha_t h_t(\boldsymbol{x}) \right)$

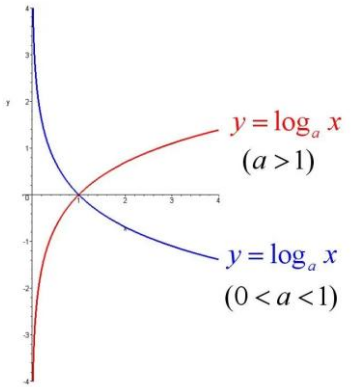

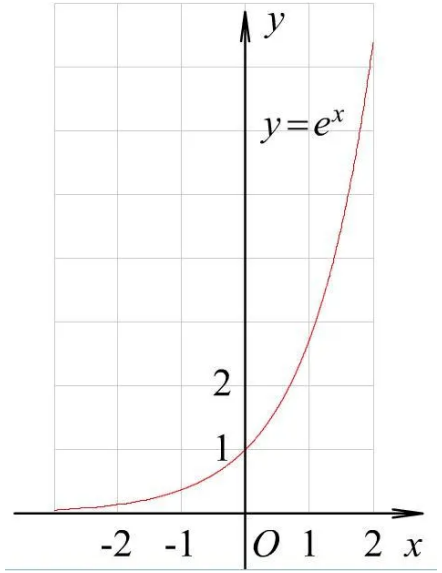

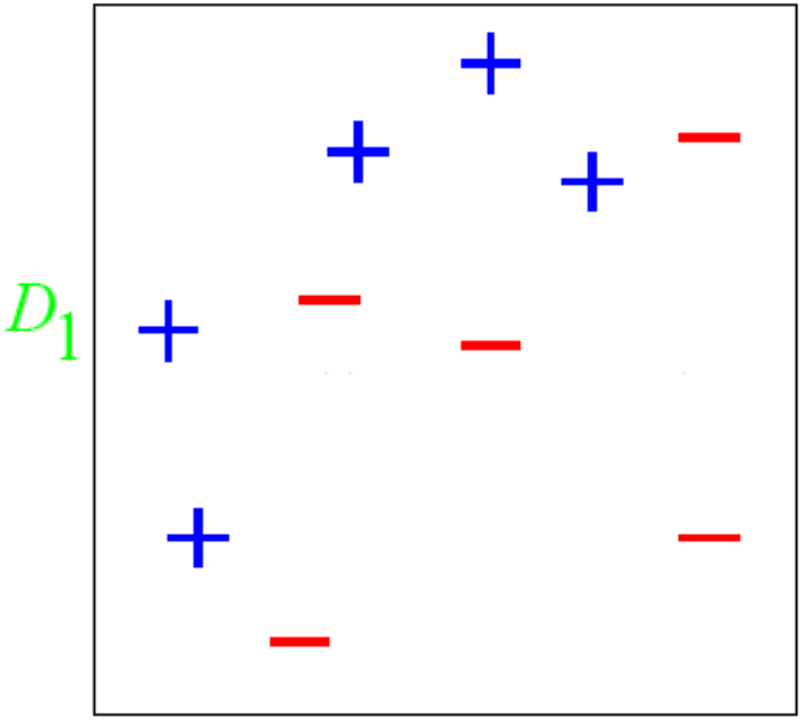
D_1

利用一个决策树桩B1，得到一个子分类器 h1，一个新的样本分布 D2，其中画圈的样本表示被分错的，在右边的图中，比较大的“+”表示对该样本做了加权。

图中的 ε1=0.3，表示的是错误率；α1=0.42，表示该分类器的权重，

α1=1/2*ln(1- ε1/ ε1)

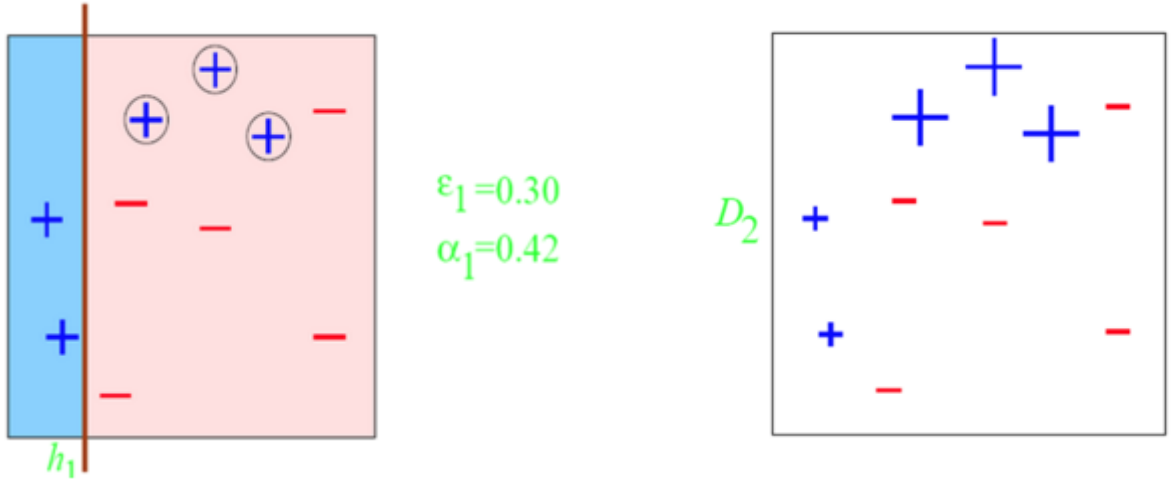

根据新的决策树桩B2，得到一个子分类器 h2，一个新的样本分布 D3，

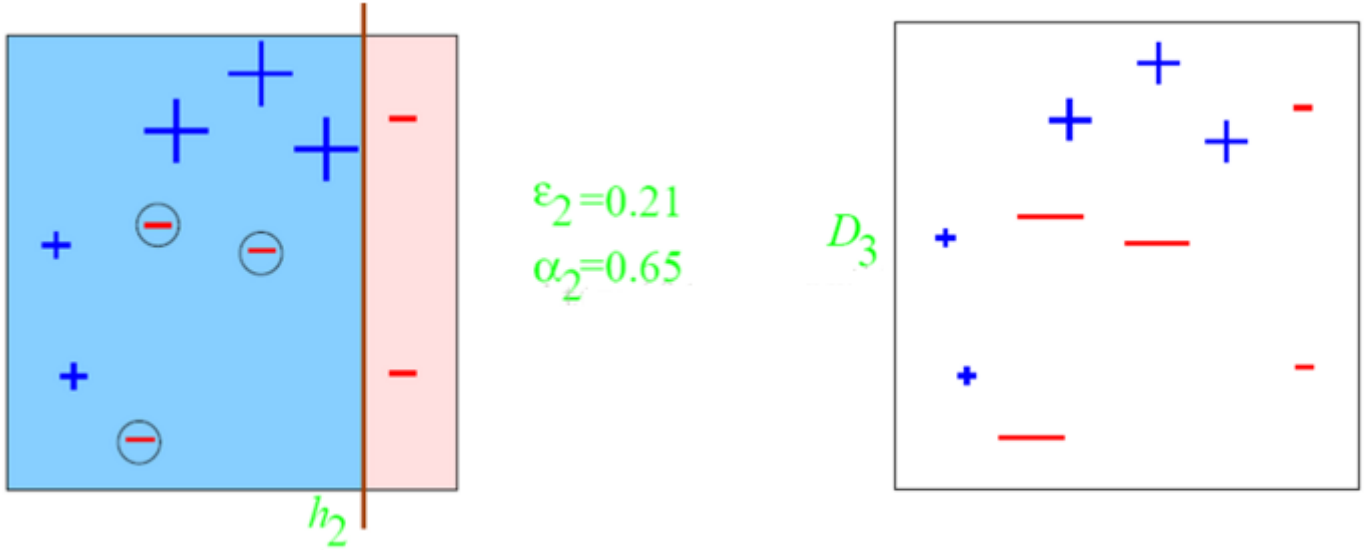

得到一个子分类器h3

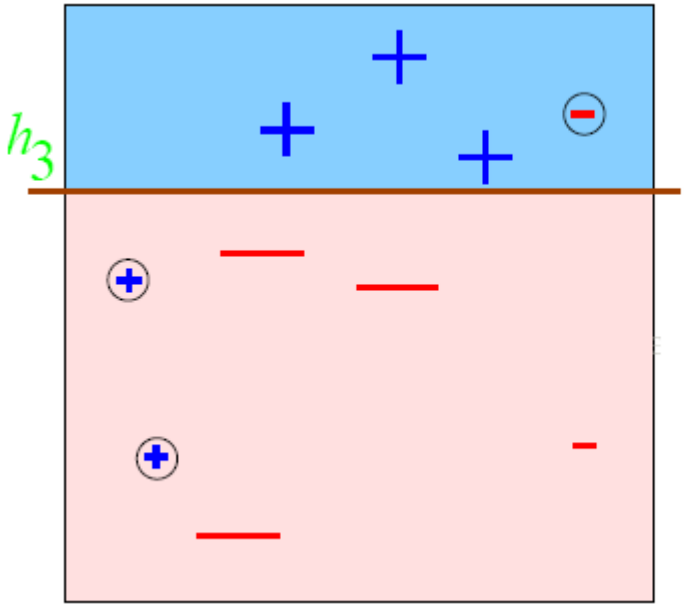

$\varepsilon_3=0.14$

$\alpha_3=0.92$

H_{final}

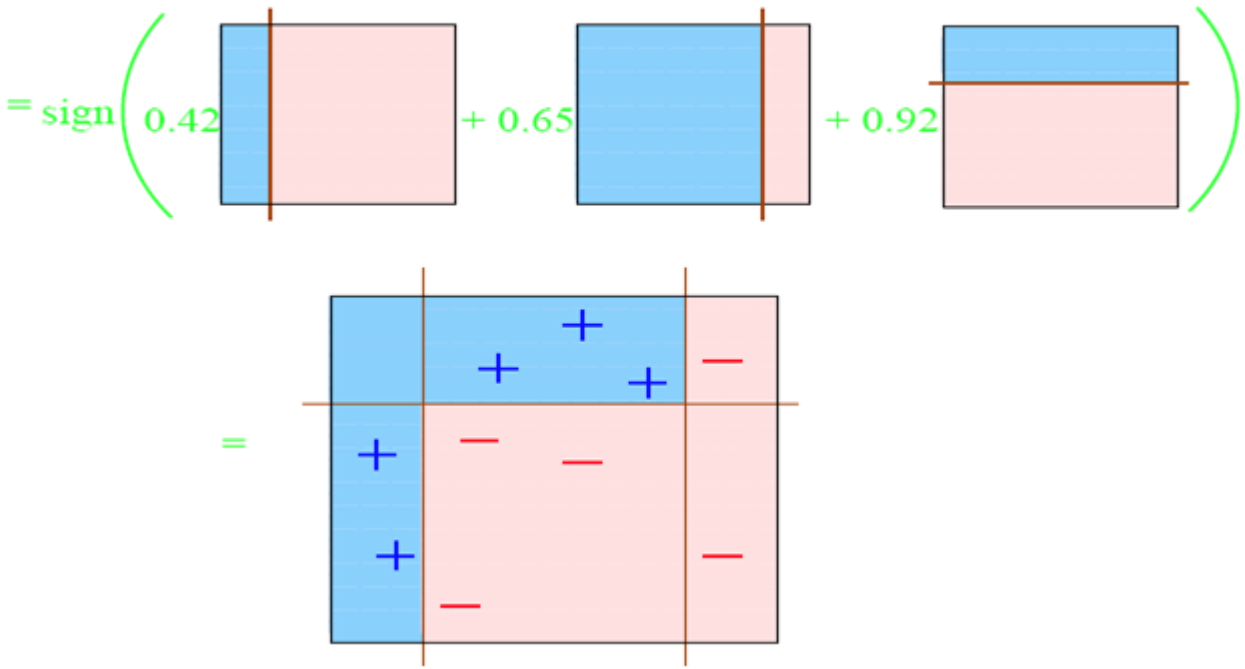

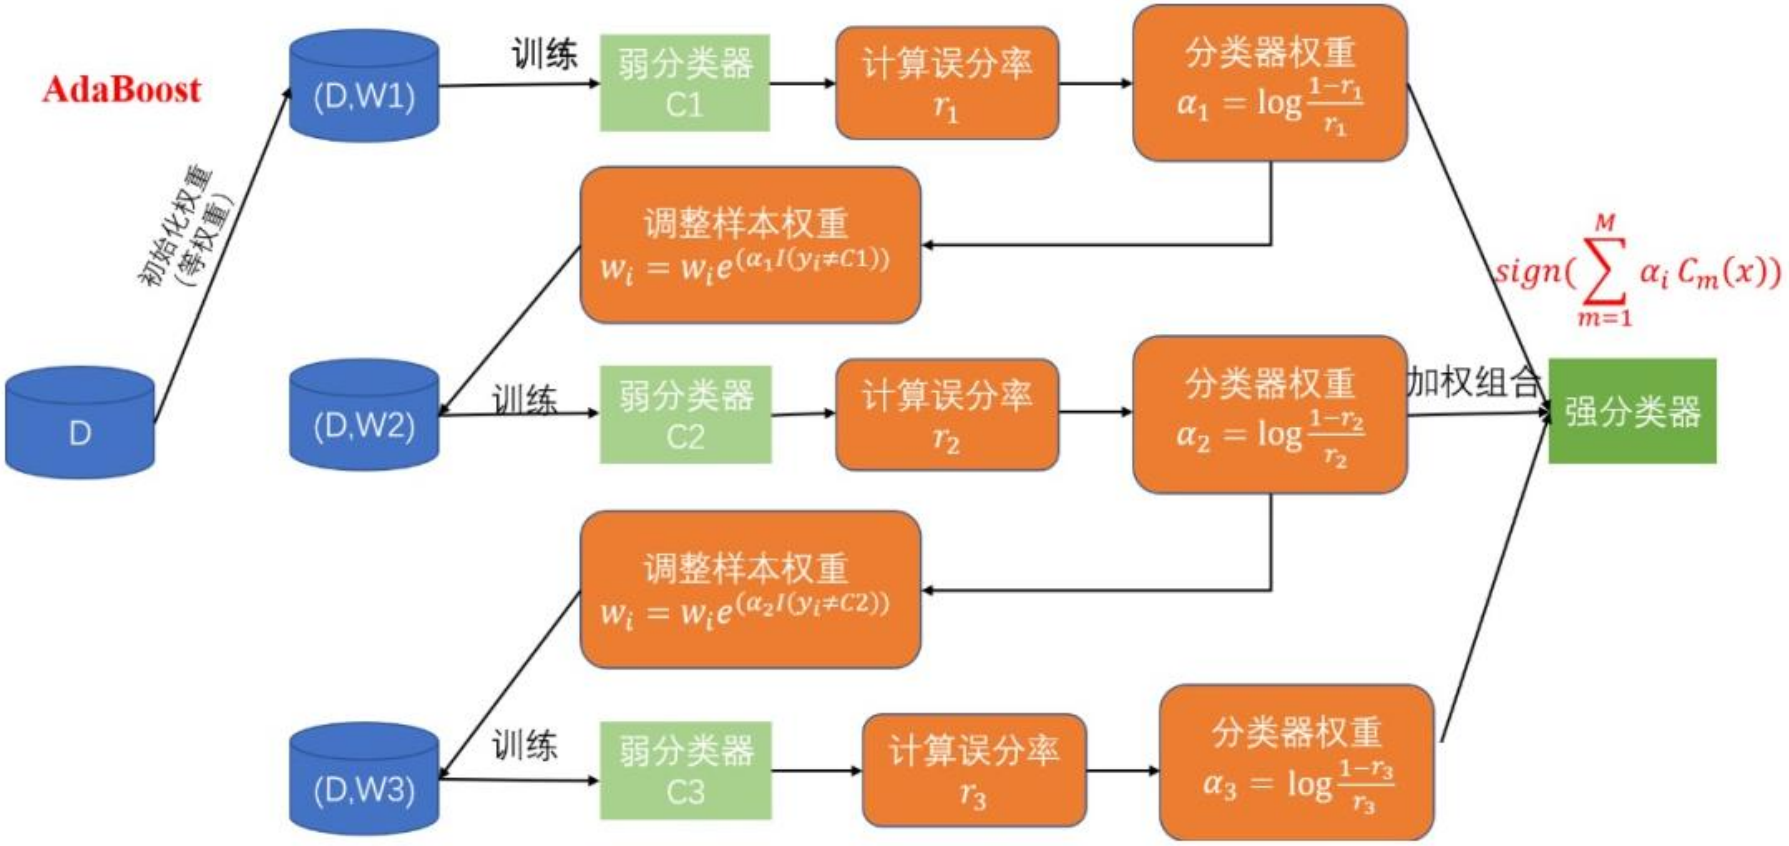
AdaBoost
D
初始化权重
(等权重)
(D,W1)
训练
弱分类器
C1
计算误分率
r_1
分类器权重
$\alpha_1 = \log\frac{1-r_1}{r_1}$
调整样本权重
$w_i = w_i e^{(\alpha_1 I(y_i \neq C1))}$
(D,W2)
训练
弱分类器
C2
计算误分率
r_2
分类器权重
$\alpha_2 = \log\frac{1-r_2}{r_2}$
调整样本权重
$w_i = w_i e^{(\alpha_2 I(y_i \neq C2))}$
(D,W3)
训练
弱分类器
C3
计算误分率
r_3
分类器权重
$\alpha_3 = \log\frac{1-r_3}{r_3}$
加权组合
强分类器
$sign(\sum_{m=1}^{M} \alpha_i C_m(x))$

AdaBoost算法最成功的应用之一是计算机视觉里的目标检测问题，如人脸检测和行人检测，车辆检测。在深度卷积神经网络用于此问题之前，AdaBoost算法在视觉目标检测领域的实际应用上一直处于主导地位。

在2001年Viola和Jones设计了一种人脸检测算法。它使用简单的Haar特征和级联AdaBoost分类器构造检测器，检测速度较之前的方法有2个数量级的提高，并且有很高的精度，这种方法称为VJ框架。VJ框架是人脸检测历史上有里程碑意义的一个成果，奠定了AdaBoost目标检测框架的基础。

Gradient Boosting

- 加性模型（additive model）：

$$\mathrm{F}(\mathrm{x}) = \sum_{m=1}^{M} \gamma_m h_m(x)$$

- 前向分步式构建加性模型：

$$\mathrm{F}_m(\mathrm{x}) = \mathrm{F}_{m-1}(\mathrm{x}) + \gamma_m h_m(x)$$

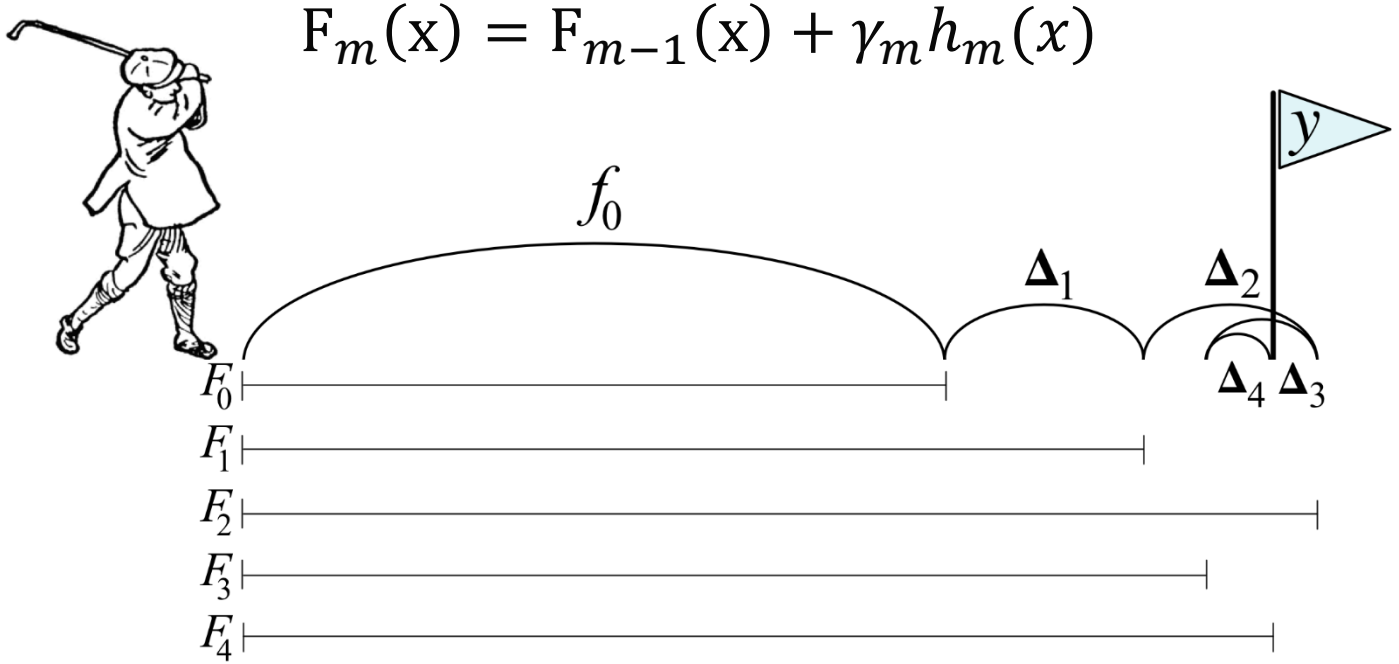

Gradient Boosting

每一步弱学习器$h_m(x)$的训练目标是减少当前模型的预测值$F_{(m-1)}(x)$和目标值y之间的差距，更一般地，即最小化损失函数$L(y, F_{(m-1)}(x)+h_m(x))$：

$$h_m(\mathrm{x}) = \underset{h_m}{\operatorname{argmin}} \sum_{i=1}^{n} \mathrm{L}(\mathrm{y}_i, \mathrm{F}_{m-1}(x_i) + h_m(x_i))$$

如果L是平方误差，则$h_m(x_i) \approx \mathrm{y}_i - \mathrm{F}_{m-1}(x_i)$

残差

对于任意可微的损失函数L，数值化地近似求解最小化问题

$$\mathrm{F}_m(\mathrm{x}) = \mathrm{F}_{m-1}(\mathrm{x}) - \gamma_m \sum_{i=1}^{n} \nabla_{F_{m-1}} \mathrm{L}(\mathrm{y}_i, \mathrm{F}_{m-1}(x_i))$$

伪残差

$$h_m(x_i) \approx -\left[\frac{\partial L(y_i, F(\boldsymbol{x}_i))}{\partial F(\boldsymbol{x}_i)}\right]_{F(\boldsymbol{x})=F_{m-1}(\boldsymbol{x})}$$

$$\gamma_m = \underset{\gamma}{\operatorname{argmin}} \sum_{i=1}^{n} \mathrm{L}(\mathrm{y}_i, \mathrm{F}_{m-1}(x_i) - \gamma \sum_{i=1}^{n} \nabla_{F_{m-1}} \mathrm{L}(\mathrm{y}_i, \mathrm{F}_{m-1}(x_i)))$$

Gradient Boosting伪码

1. 初始化弱学习器为一个常数值：

$$F_0(x) = \underset{\gamma}{\operatorname{argmin}} \sum_{i=1}^{n} L(y_i, \gamma))$$

2. 分别设$m = 1, 2, \cdots, M$，重复下面的步骤：
   a) 计算伪残差（pseudo residuals）：

$$r_{im} = -\left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)}\right]_{F(x)=F_{m-1}(x)} \qquad i = 1, 2, \ldots, n$$

   b) 训练一个弱学习器$h_m(x)$拟合伪残差，即用训练集$\{(x_i, r_{im})\}_{i=1}^{n}$训练
   c) 求解下面的一维优化问题得到γ_m：

$$\gamma_m = \underset{\gamma}{\operatorname{argmin}} \sum_{i=1}^{n} L(y_i, F_{m-1}(x_i) - \gamma \sum_{i=1}^{n} \nabla_{F_{m-1}} L(y_i, F_{m-1}(x_i)))$$

   d) 更新模型：

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x)$$

3. 输出最终模型：$F_M(x)$

Gradient Boosting分类器的语法

导入包含分类方法的类：

```
from sklearn.ensemble import GradientBoostingClassifier
```

创建该类的一个对象：

```
GBC = GradientBoostingClassifier(learning_rate=0.1,
        max_features=1, subsample=0.5, n_estimators=200)
```

拟合训练数据，并预测：

```
GBC = GBC.fit (X_train, y_train)
y_predict = GBC.predict(X_test)
```

使用交叉验证调节参数，回归用GradientBoostingRegressor

http://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingClassifier.html

GradientBoostingClassifier参数设置

loss	损失函数 分类和回归的损失函数不同。 对于分类，可以是对数似然损失“deviance”或者指数损失“exponential”，缺省值是“deviance”。使用“exponential”则等同于AdaBoost算法。 对于回归，可以是平方损失“ls”、绝对损失“lad”、Huber损失“huber”或分位数损失“quantile”，缺省值是“ls”。一般来说，如果数据的噪音点不多，用默认的“ls”比较好。如果噪音点较多，则推荐使用抗噪音的“huber”损失函数。如果我们需要对训练集进行分段预测时，则采用“quantile”损失函数。
n_estimators	基学习器个数 集成的基学习器的个数。或者说算法的迭代次数。 缺省值是100。
learning_rate	学习率 缺省值是0.1。一般设为0到1之间的值，缩减每个基学习器对最终结果的贡献量，即每个基学习器的权重缩减系数，也称步长。它和n_estimators之间存在一个折衷，一起来决定算法的拟合效果。如果要达到一定的拟合效果，更小的学习率意味着要训练更多的弱学习器。
subsample	子采样 用于训练每个基学习器的样本数量占整个训练集的比例。 缺省值是1.0，即用全部数据训练基学习器。小于1.0则是随机梯度提升。小于1.0的值会降低系统的方差，防止过拟合，但会增大系统的偏差。

GBDT(Gradient Boosting Decision Tree) 梯度提升决策树

Bagging vs. Boosting

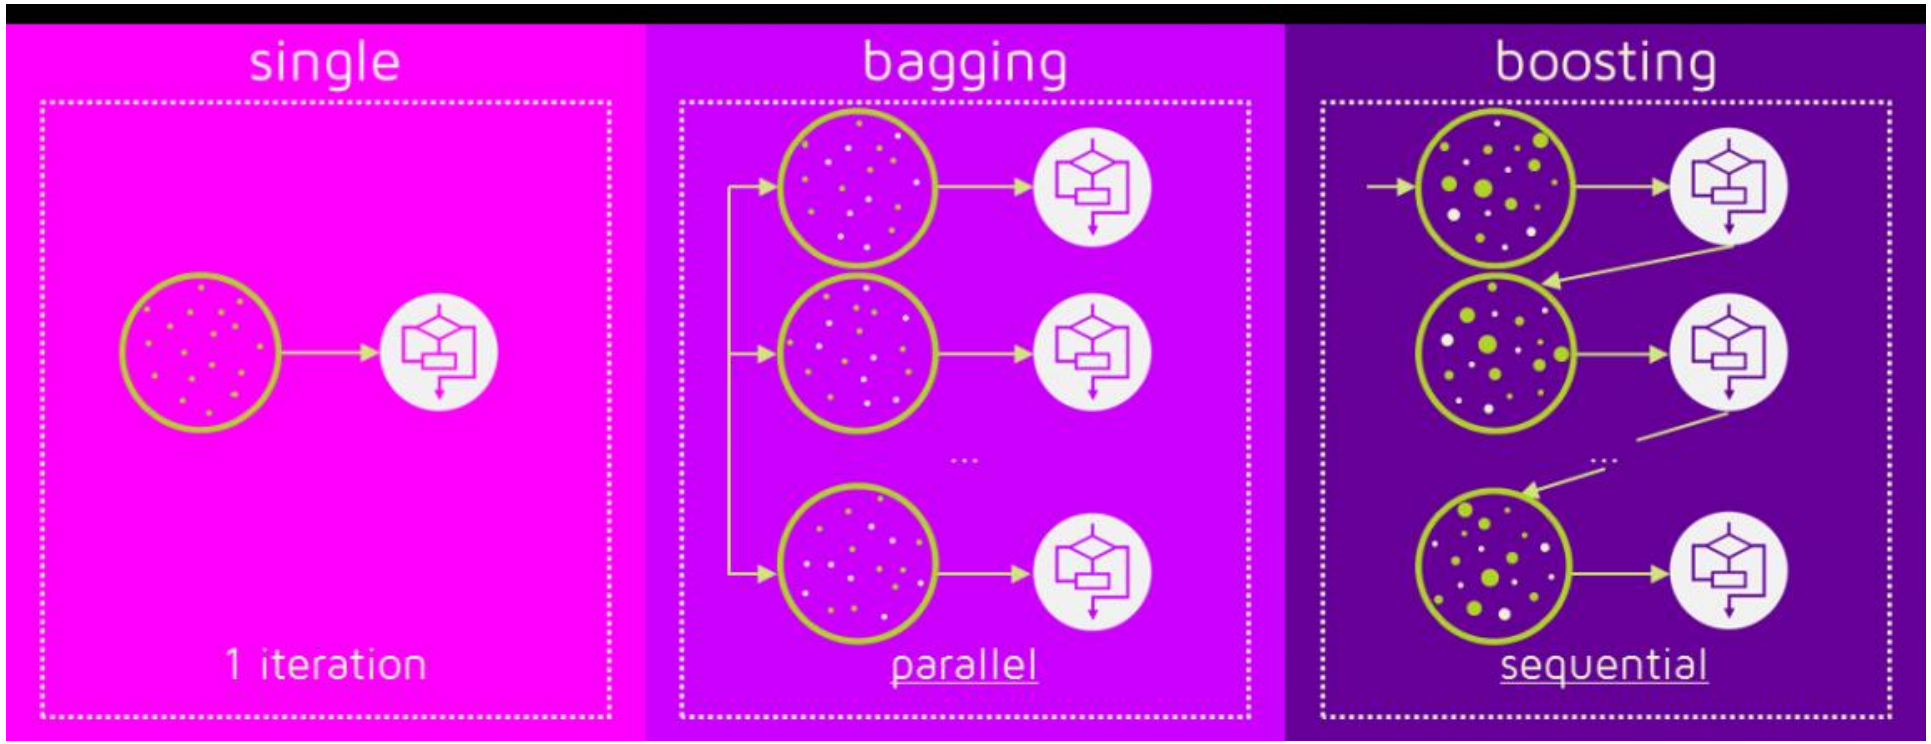

Bagging vs. Boosting

bagging	boosting
Bootstrap产生的样本	拟合全部数据集
独立创建的基本树	相继创建的基本树
只考虑数据点	利用前面创建的模型的残差
不使用权重	增加错误分类点的权重
多余的树不会造成过拟合	当心过拟合
主要关注降低方差	主要关注降低偏差

12.3 STACKING

Stacking：结合多个异构的分类器

- 不同类型的模型可以结合起来构建stacked模型
- 类似bagging，但不局限于决策树

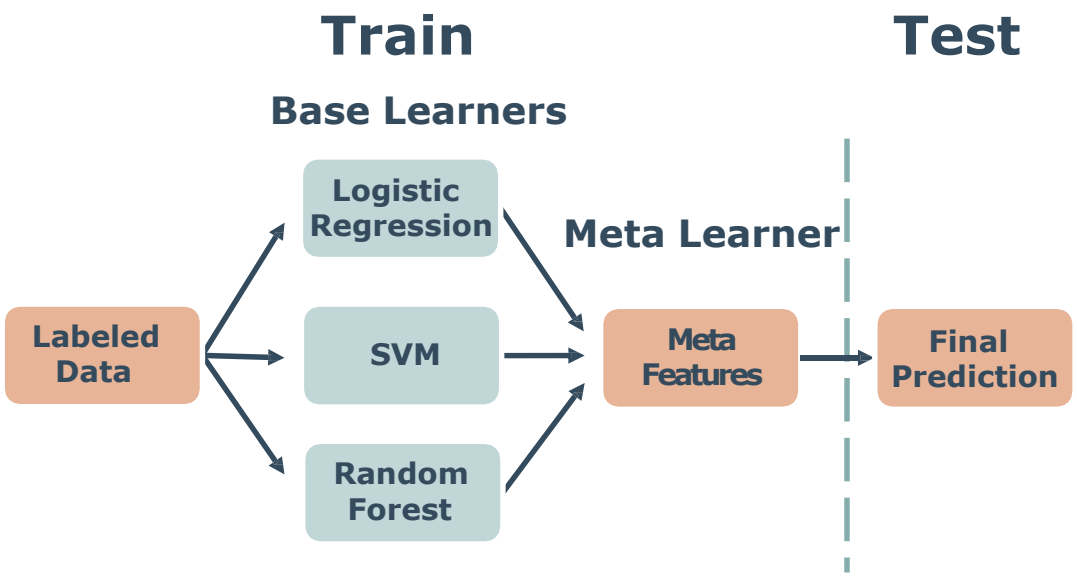

Stacking：结合多个异构的分类器

- 不同类型的模型可以结合起来构建stacked模型
- 类似bagging，但不局限于决策树
- 基学习器的输出产生的特征，可以和数据特征结合在一起

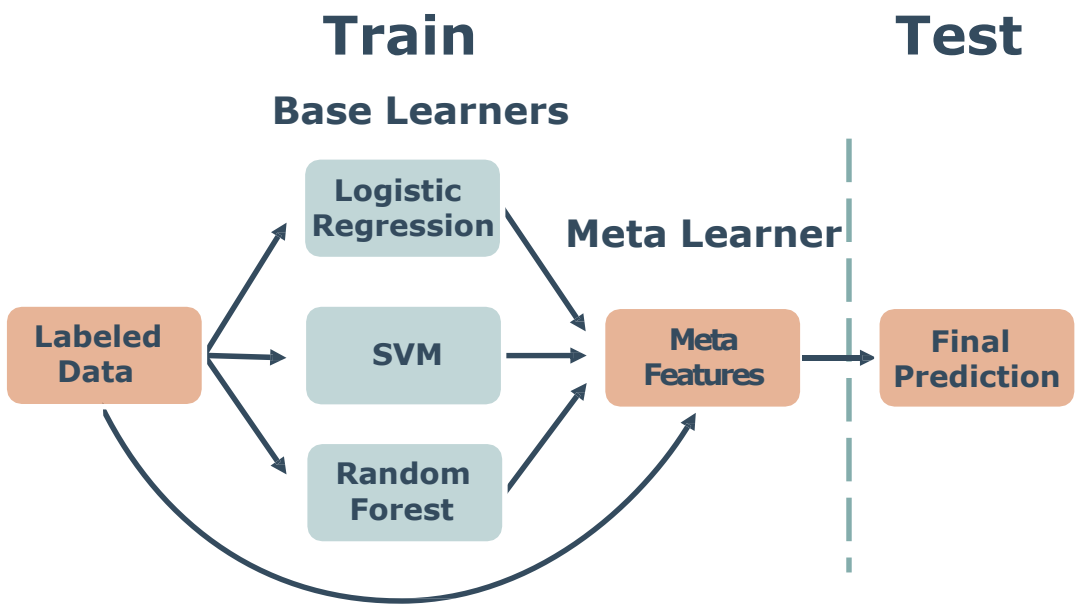

Stacking：结合多个异构的分类器

- 基学习器的输出可以用多数投票或加权和等方式结合起来
- 如果元学习器有参数，则需要另外取出的数据做预测
- 当心增加的模型复杂度

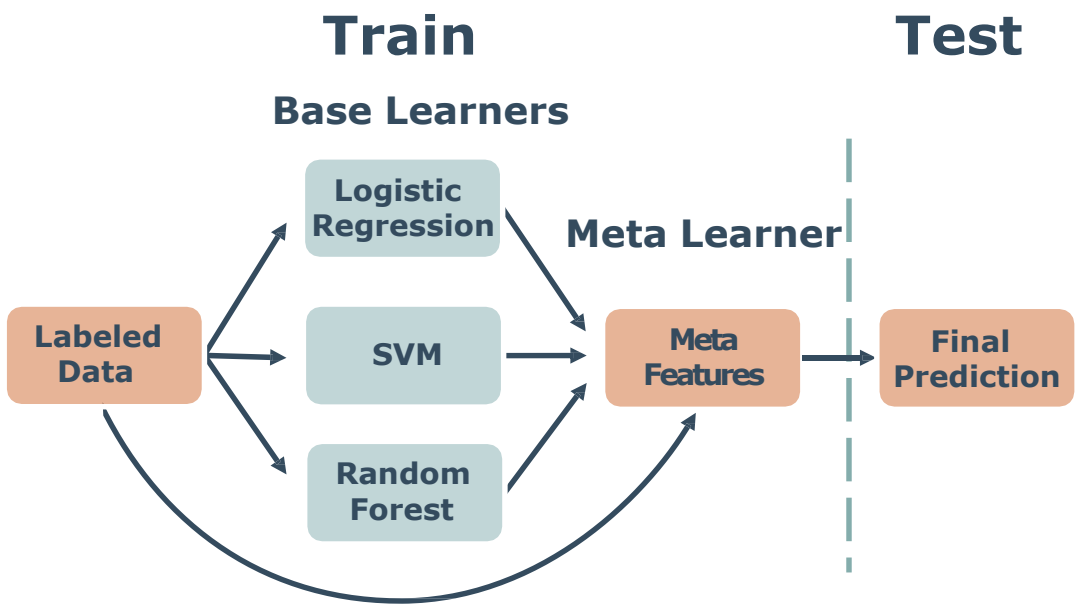

多层堆叠

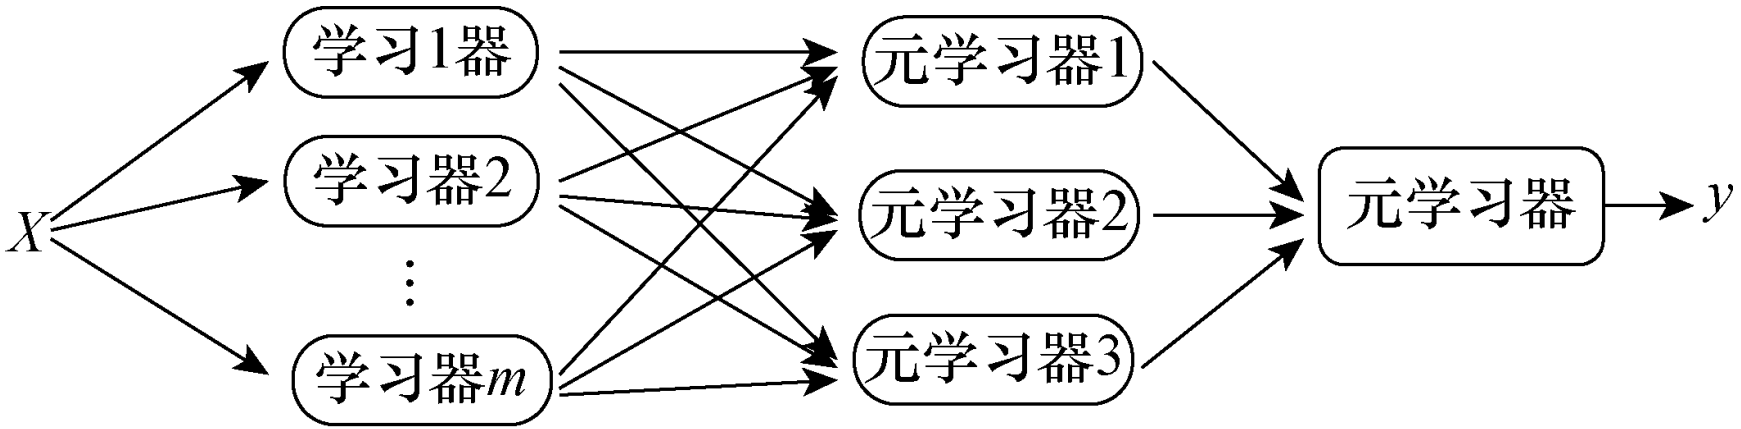

stacking的语法

导入包含该分类方法的类:

```
from sklearn.ensemble import StackingClassifier
From sklearn.linear_model import LogisticRegression
```

创建该类的一个对象:

```
st_clf = StackingClassifier(estimators=estimator_list,
        final_estimator=LogisticRegression())
```

拟合训练数据，并预测:

```
st_clf.fit(X_train, y_train)
y_predict = st_clf.predict(X_test)
```

http://scikit-learn.org/stable/modules/generated/sklearn.ensemble.VotingClassifier.html