线性回归练习题

在这个练习中，我们使用一个Kaggle竞赛中提供的共享单车的数据集：Bike Sharing Demand。 该数据集包含2011到2012年Capital Bikeshare系统中记录的每日每小时单车的租赁数，以及相应的季节和气候等信息。

数据列：

- **datetime** - 每小时日期 + 时间戳
- **季节** - 1 = 春季，2 = 夏季，3 = 秋季，4 = 冬季
- **holiday** - 该日期是否被视为假日
- **workingday** - 无论该日期既不是周末还是节假日
- **天气** - 1：晴朗，云量少，部分多云，部分多云;2：薄雾 + 多云，薄雾 + 碎云，薄雾 + 少量云层;3：小雪，小雨 + 雷暴 + 分散云，小雨 + 分散云;4：大雨 + 冰板 + 雷暴 + 薄雾，雪 + 雾
- **temp** - 以摄氏度为单位的温度
- **atemp** - “感觉像”以摄氏度为单位的温度
- **humidity** - 相对湿度
- **windspeed** - 风速
- **casual** - 发起的非注册用户租赁数量
- **registered** - 发起的注册用户租赁数量
- **count** - 总租赁数量

第一步：读入数据

在 [2] …

```
# read the data and set the datetime as the index
import pandas as pd

bikes = pd.read_csv('bikeshare.csv', index_col='datetime', parse_dates=True)
```

在 [2] …

```
bikes.head()
```

输出[2]：

日期时间	季节	假期	工作日	天气	临时	atemp	湿度	风速	休闲	注册	计数
2011-01-01 00:00:00	1	0	0	1	9.84	14.395	81	0.0	3	13	16
2011-01-01 01:00:00	1	0	0	1	9.02	13.635	80	0.0	8	32	40
2011-01-01 02:00:00	1	0	0	1	9.02	13.635	80	0.0	5	27	32
2011-01-01 03:00:00	1	0	0	1	9.84	14.395	75	0.0	3	10	13
2011-01-01 04:00:00	1	0	0	1	9.84	14.395	75	0.0	0	1	1

第二步：可视化数据

- 用matplotlib画出温度“temp”和自行车租赁数“count”之间的散点图;
- 用seborn画出温度“temp”和自行车租赁数“count”之间带线性关系的散点图（提示：使用seaborn中的lmplot绘制）

在 [5] …

```
# matplotlib
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(1)

N=50
x=np.random.rand(N)
y=np.random.rand(N)
colors=np.random.rand(N)
area=(30*np.random.rand(N))**2

plt.scatter(x,y,s=area,c=colors,alpha=0.5)
plt.show()
```

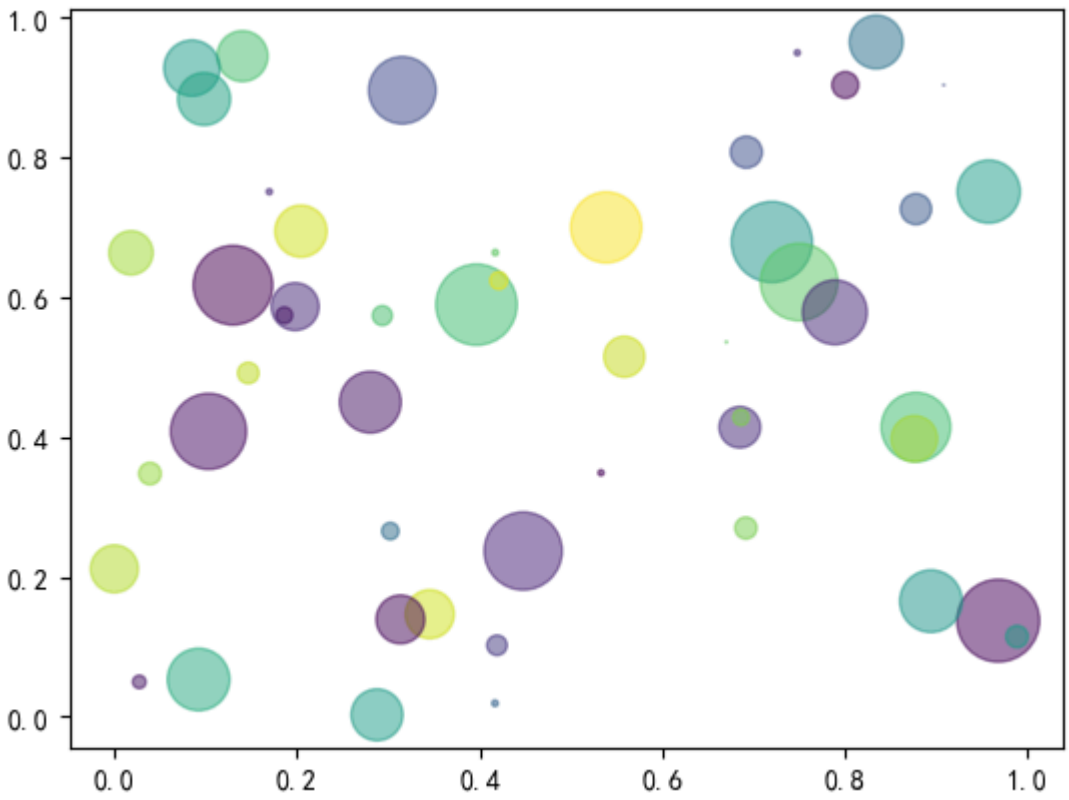

在 [6] …

```
# seaborn
import seaborn as sns
sns.lmplot(x='temp', y='count', data=bikes)
plt.show()
```

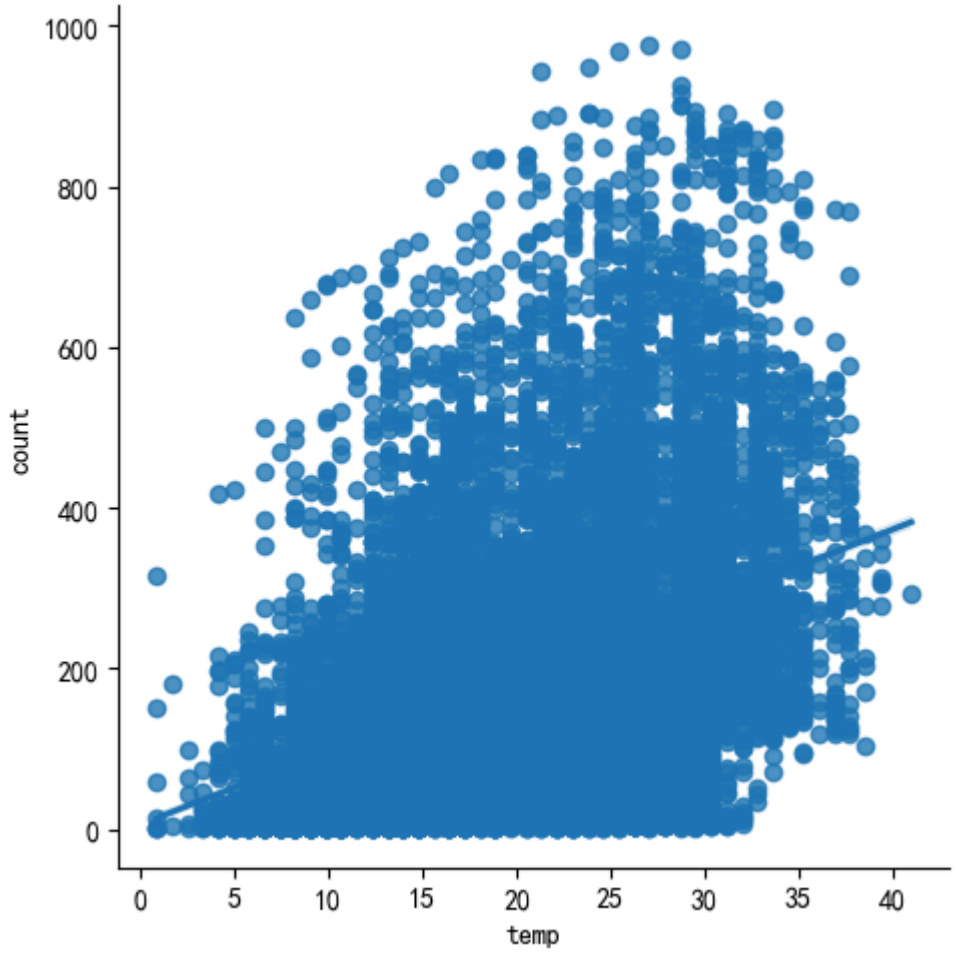

第三步：一元线性回归

用温度预测自行车租赁数

在 [7] …

```
# create X and y
X = bikes[['temp']]  # 特征（温度），注意用双括号确保是二维数组
y = bikes['count']
```

在 [9] …

```
# import, instantiate, fit
from sklearn.linear_model import LinearRegression
model = LinearRegression()
model.fit(X, y)
```

出局[9]:

▾ 线性回归

LinearRegression()

在 [10]…

```
# print the coefficients
print(f"回归系数（斜率）: {model.coef_[0]}")
print(f"截距: {model.intercept_}")
```

```
回归系数（斜率）: 9.170540481426201
截距: 6.046212959617549
```

第四步：探索多个特征

在 [12]…

```
# explore more features
feature_cols = ['temp', 'season', 'weather', 'humidity']
```

在 [15]…

```
# using seaborn, draw multiple scatter plots between each feature in feature_col
for feature in feature_cols:
    plt.figure(figsize=(8, 6))  # 设置图形大小
    sns.scatterplot(x=feature, y='count', data=bikes)
    plt.title(f"{feature} & count 散点图")
    plt.xlabel(feature)
    plt.ylabel('count')
    plt.show()
```

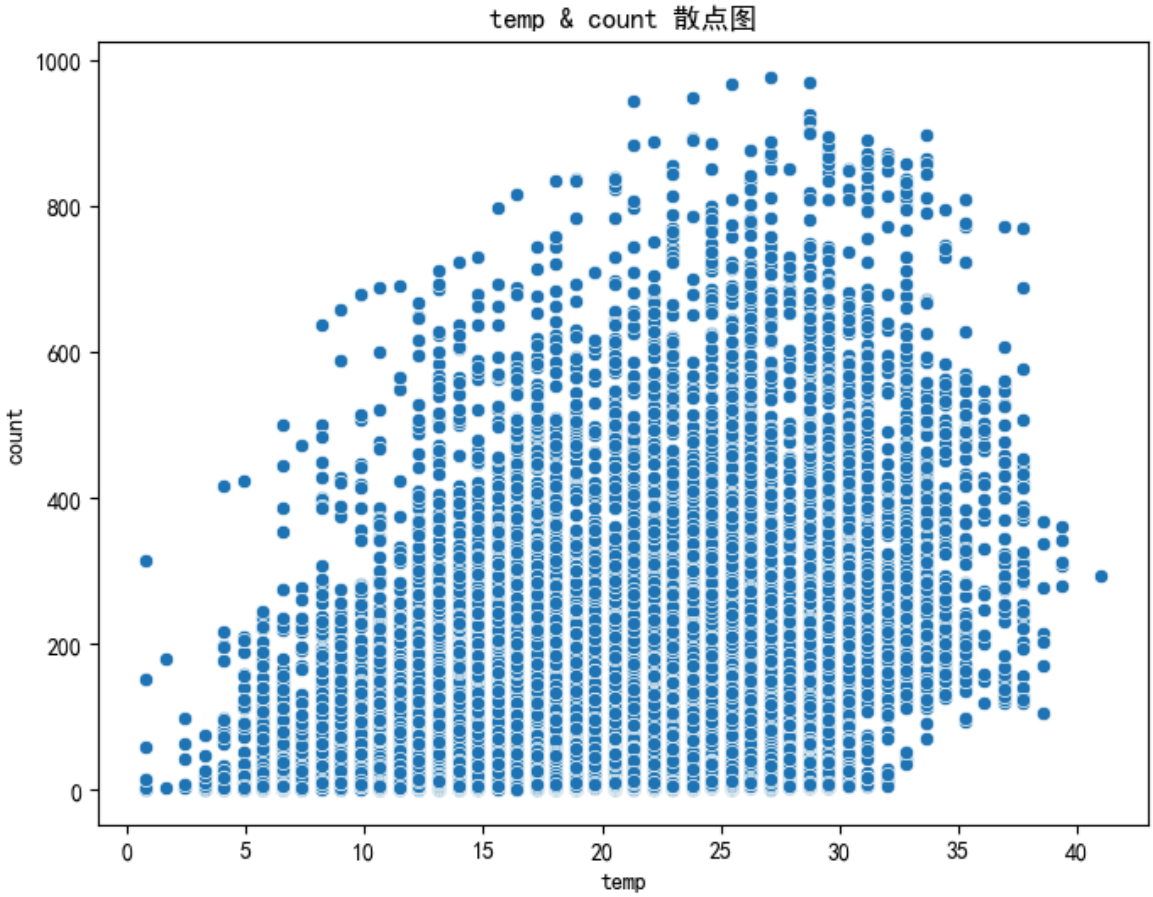
temp & count 散点图
count
temp
0
200
400
600
800
1000
0
5
10
15
20
25
30
35
40

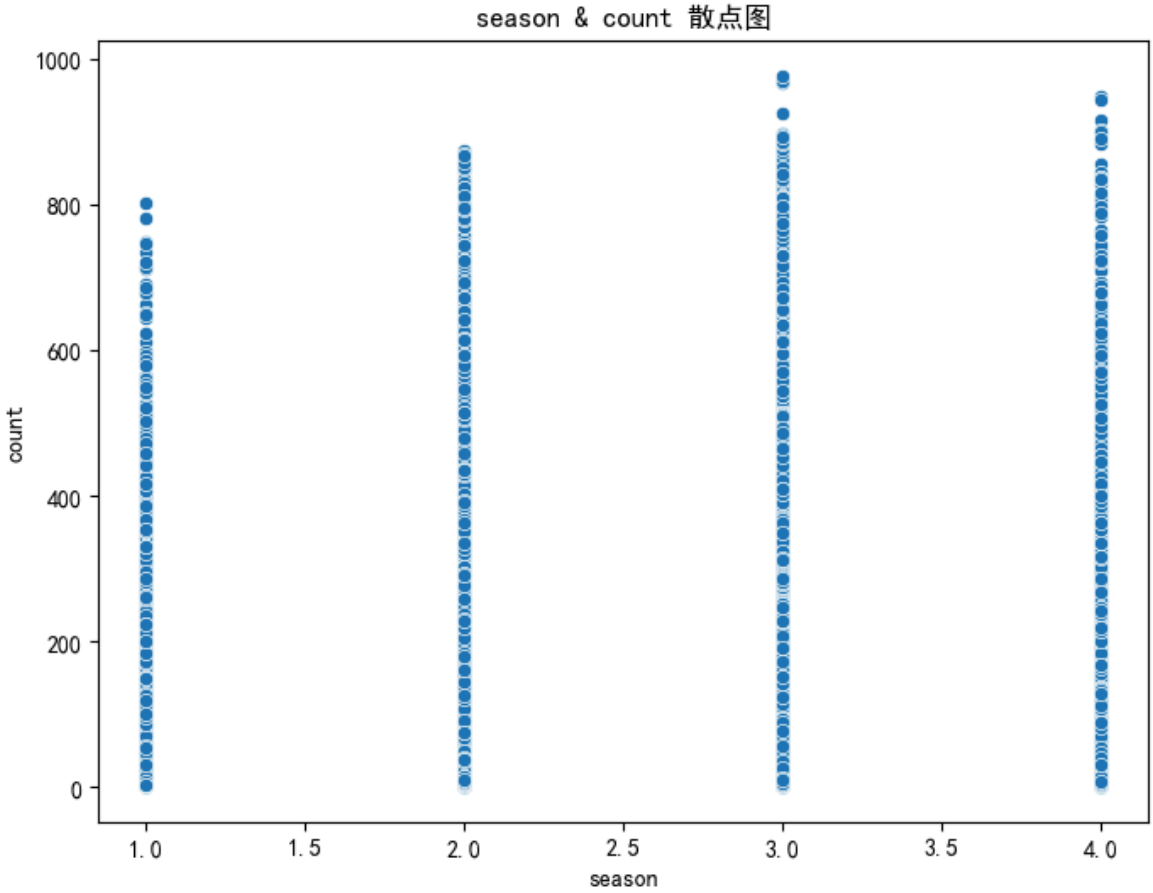
season & count 散点图
count
season
0
200
400
600
800
1000
1.0
1.5
2.0
2.5
3.0
3.5
4.0

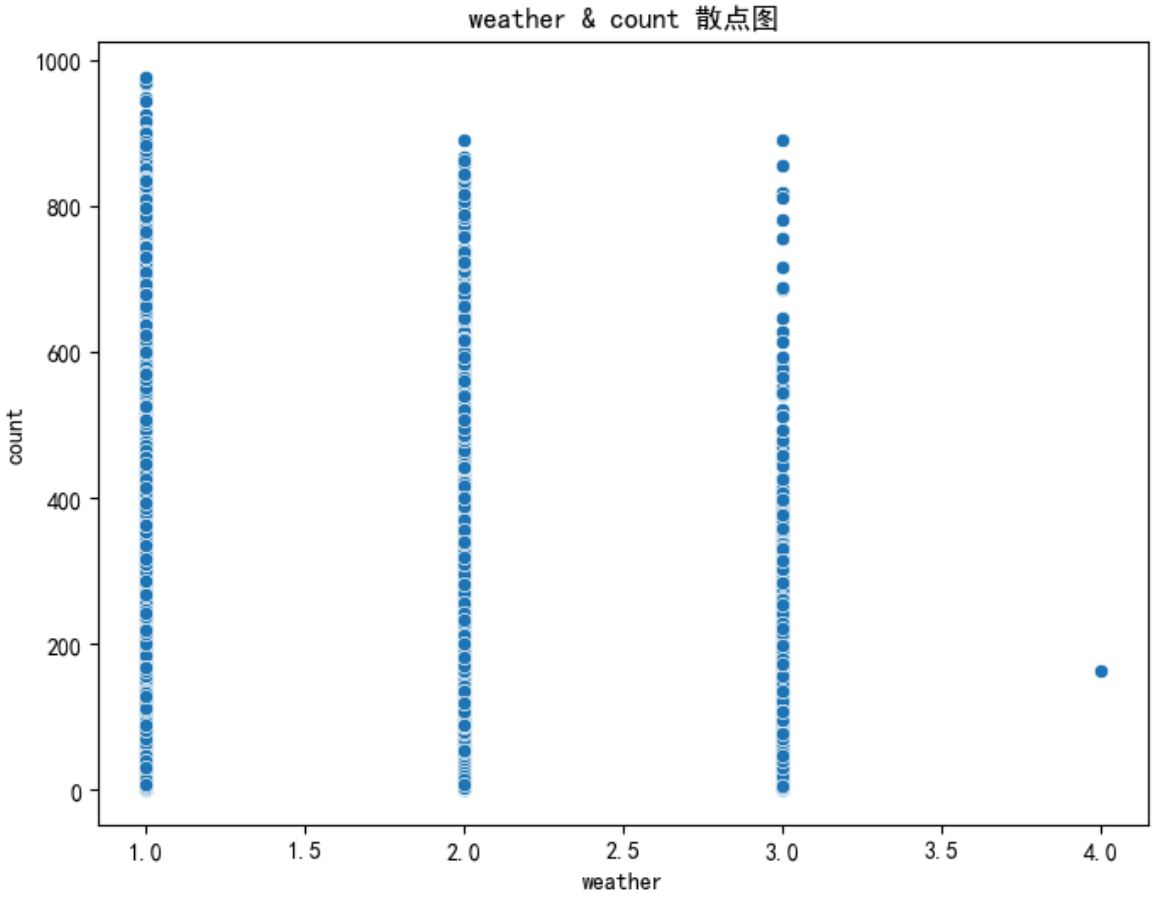

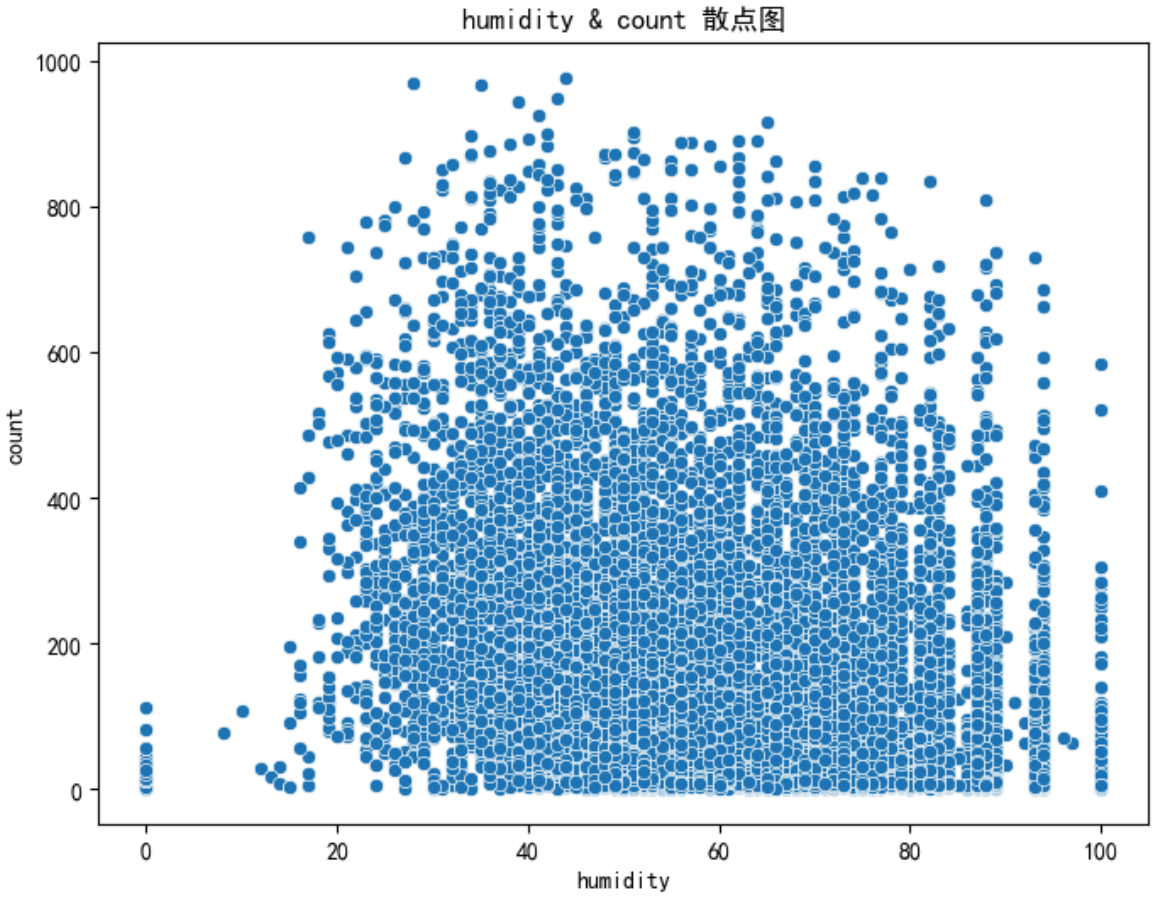

在 [16]…

```
# correlation matrix (ranges from 1 to -1)
bikes.corr()
```

出[16]:

	季节	假期	工作日	天气	临时	atemp	湿度
季节	1.000000	0.029368	-0.008126	0.008879	0.258689	0.264744	0.190610
假期	0.029368	1.000000	-0.250491	-0.007074	0.000295	-0.005215	0.001929
工作日	-0.008126	-0.250491	1.000000	0.033772	0.029966	0.024660	-0.010880
天气	0.008879	-0.007074	0.033772	1.000000	-0.055035	-0.055376	0.406244
临时	0.258689	0.000295	0.029966	-0.055035	1.000000	0.984948	-0.064949
atemp	0.264744	-0.005215	0.024660	-0.055376	0.984948	1.000000	-0.043536
湿度	0.190610	0.001929	-0.010880	0.406244	-0.064949	-0.043536	1.000000
风速	-0.147121	0.008409	0.013373	0.007261	-0.017852	-0.057473	-0.318607
休闲	0.096758	0.043799	-0.319111	-0.135918	0.467097	0.462067	-0.348187
注册	0.164011	-0.020956	0.119460	-0.109340	0.318571	0.314635	-0.265458
计数	0.163439	-0.005393	0.011594	-0.128655	0.394454	0.389784	-0.317371

在 [17]…

```
sns.heatmap(bikes.corr())
```

出[17]: <Axes: >

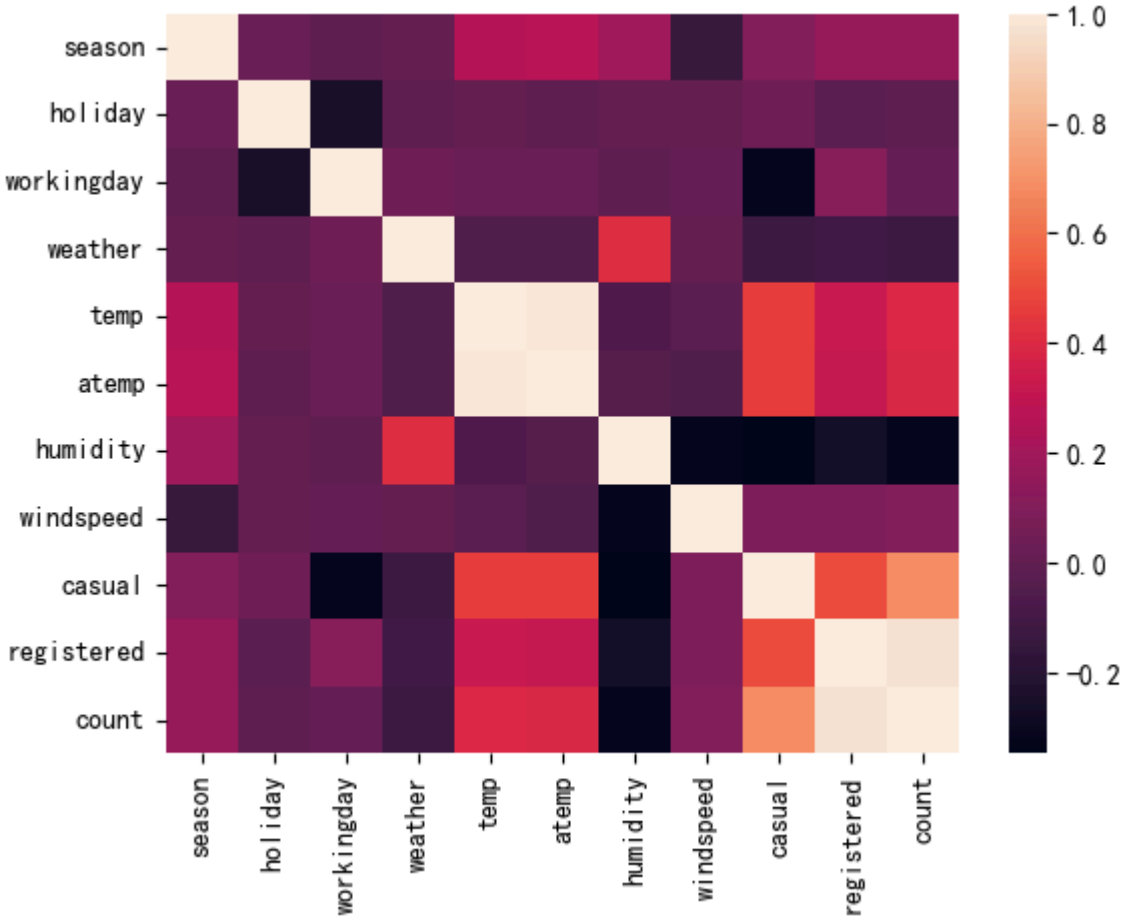

用'temp'，'season'，'weather'，'humidity'四个特征预测单车租赁数'count'

在 [18]…

```python
# create X and y
X = bikes[['temp', 'season', 'weather', 'humidity']]
y = bikes['count']
```

在 [19]…

```python
# import, instantiate, fit
from sklearn.linear_model import LinearRegression
model = LinearRegression()
model.fit(X, y)
```

出[19]:

▾ 线性回归

LinearRegression()

在 [21]…

```python
# print the coefficients
print("特征对应的系数:", model.coef_)
print("模型截距:", model.intercept_)
```

```
特征对应的系数: [ 7.86482499 22.53875753  6.67030204 -3.11887338]
模型截距: 159.52068786129803
```

使用train/test split和RMSE来比较多个不同的模型

在 [28]…

```python
# compare different sets of features
feature_cols1 = ['temp', 'season', 'weather', 'humidity']
feature_cols2 = ['temp', 'season', 'weather']
feature_cols3 = ['temp', 'season', 'humidity']
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error
target_col = 'count'
# 定义一个函数来训练模型并计算 RMSE
def train_and_evaluate(X, y):
    # 划分训练集和测试集
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, ran

    # 创建线性回归模型
    model = LinearRegression()

    # 训练模型
    model.fit(X_train, y_train)

    # 进行预测
    y_pred = model.predict(X_test)

    # 计算 RMSE
    rmse = np.sqrt(mean_squared_error(y_test, y_pred))
    return rmse
# 对每个特征组合进行训练和评估
for i, feature_cols in enumerate([feature_cols1, feature_cols2, feature_cols3],
    X = bikes[feature_cols]
    y = bikes[target_col]
    rmse = train_and_evaluate(X, y)
    print(f"feature_cols{i} 的 RMSE: {rmse}")
```

```
feature_cols1 的 RMSE: 154.88153824675462
feature_cols2 的 RMSE: 164.17140223751377
feature_cols3 的 RMSE: 154.96357288624588
```

补充：处理类别特征

有两种类别特征：

- **有序类别值：** 转换成相应的数字值（例如： small=1， medium=2， large=3）
- **无序类别值：** 使用dummy encoding （0/1编码）

此数据集中的类别特征有：

- **有序类别值：** weather （已经被编码成相应的数字值1,2,3,4）
- **无序类别值：** season （需要进行虚拟编码）， holiday （已经被虚拟编码），workingday （已经被虚拟编码）

在 [29]…

```
# create dummy variables
season_dummies = pd.get_dummies(bikes.season, prefix='season')

# print 5 random rows
season_dummies.sample(n=5, random_state=1)
```

出[29]：

日期时间	season_1	season_2	season_3	season_4
2011-09-05 11:00:00	假	假	真	假
2012-03-18 04:00:00	真	假	假	假
2012-10-14 17:00:00	假	假	假	真
2011-04-04 15:00:00	假	真	假	假
2012-12-11 02:00:00	假	假	假	真

在 [ ] …

```
我们只需要 三个 dummy 变量 (不是四个)(删除第一列是为了消除多重共线性,
让模型的系数估计更加稳定, 同时也能提高模型的解释性),
所以可以删除第一个dummy变量。
```

在 [30]…

```
# drop the first column
season_dummies.drop(season_dummies.columns[0], axis=1, inplace=True)

# print 5 random rows
season_dummies.sample(n=5, random_state=1)
```

出[30]：

日期时间	season_2	season_3	season_4
2011-09-05 11:00:00	假	真	假
2012-03-18 04:00:00	假	假	假
2012-10-14 17:00:00	假	假	真
2011-04-04 15:00:00	真	假	假
2012-12-11 02:00:00	假	假	真

在 [31]…

```
# concatenate the original DataFrame and the dummy DataFrame (axis=0 means rows,
bikes = pd.concat([bikes, season_dummies], axis=1)

# print 5 random rows
bikes.sample(n=5, random_state=1)
```

出[31]:

	季节	假期	工作日	天气	临时	atemp	湿度	风速	休闲	注册	计数	season_2	seas
日期时间													
2011-09-05 11:00:00	3	1	0	2	28.70	33.335	74	11.0014	101	207	308	假	
2012-03-18 04:00:00	1	0	0	2	17.22	21.210	94	11.0014	6	8	14	假	
2012-10-14 17:00:00	4	0	0	1	26.24	31.060	44	12.9980	193	346	539	假	
2011-04-04 15:00:00	2	0	1	1	31.16	33.335	23	36.9974	47	96	143	真	
2012-12-11 02:00:00	4	0	1	2	16.40	20.455	66	22.0028	0	1	1	假	

将编码成的dummy变量加入回归模型的特征，预测单车租赁数

在 [33]…

```
# include dummy variables for season in the model
feature_cols = ['temp', 'season_2', 'season_3', 'season_4', 'humidity']
X = bikes[feature_cols]  # 提取模型所需特征
y = bikes['count']       # 目标变量：单车租赁数

# 2. 划分训练集与测试集
X_train, X_test, y_train, y_test = train_test_split( X, y, test_size=0.2, random

#训练线性回归模型
model = LinearRegression()
model.fit(X_train, y_train)  # 用训练集数据训练模型

# 预测并计算 RMSE（均方根误差）
y_pred = model.predict(X_test)  # 用测试集特征预测结果
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
print(f"含 season 虚拟变量的模型 RMSE: {rmse}")
```

```
含 season 虚拟变量的模型 RMSE: 153.70399462915924
```

和前面的模型进行比较